Universidad Rafael Landívar

Facultad Ingeniería

Ingeniería en Sistemas e Informática

Ciencia de Datos

Inge. Max Cerna

Proyecto 01 – Fase 01 y Fase 02

PROYECTO RED METROPOLITANA

Rochelle Giulianne Esquivel Vargas – 1283220

Susana Paola García García – 1224323

Harriett Alexandra Guzmán López – 1112423

Guatemala, 12 de octubre del 2026

Tabla de contenido

INTRODUCCIÓN **6**

FASE 01 - DESGLOSE DE LA ARQUITECTURA **7**

OBJETIVOS **7**

Objetivo general 7

Objetivos específicos 7

PROBLEMÁTICA **8**

SOLUCIÓN IMPLEMENTADA **9**

METODOLOGÍA Y ARQUITECTURA DEL PROYECTO **10**

Método general de trabajo 10

Arquitectura seleccionada 10

Separación entre las capas 10

Orden de diseño 10

DECISIONES DE INGESTA Y ALMACENAMIENTO BRONZE **11**

Métodos de ingesta por fuente 11

Método elegido para Transurbano 11

Ubicación de la capa Bronze 11

Formato de almacenamiento 11

DECISIONES DE STAGING Y PROCESAMIENTO CDC **11**

Uso de Staging 11

Aplicación de las operaciones CDC 11

Resultado del padrón vigente 12

Catálogos mínimos de usuarios 12

DECISIONES DE INTEGRACIÓN Y CALIDAD EN SILVER **12**

Unificación de formatos 12

Conformación de zonas 12

Estrategia de identidad del usuario 12

Tratamiento de los registros inválidos 13

Historización del padrón 13

DECISIONES DEL MODELO DIMENSIONAL GOLD **13**

Grano de la tabla de hechos principal 13
Separación de las tablas de hechos 13
Dimensiones conformadas 13
Clasificación de las medidas 13

ORQUESTACIÓN PRUEBAS MÉTRICAS E IDEMPOTENCIA 14

Herramienta de transformación 14
Orquestación del flujo 14
Comprobación de idempotencia 14
Métricas documentadas 14

GOBERNANZA SEGURIDAD Y ALCANCE POSTERIOR 14

Definiciones oficiales 14
Responsabilidad y linaje 15
Documentación y reproducibilidad 15
Seguridad y datos personales 15

CONCLUSIÓN 16

RECOMENDACIONES 17

ANEXOS – FASE 01 18

Infraestructura y Servicios 18
Servicios de infraestructura en Docker Desktop 18
Verificación de servicios con Docker Compose 19
Ingesta y Capa Staging 20
Conteo de registros por fuente en Staging 20
Procesamiento CDC y Usuarios 21
Operaciones CDC procesadas 21
Estado final del padrón de usuarios 22
Catálogos mínimos de usuarios por operador 23
Calidad y Conformación en Silver 24
Validación de viajes de MetroRiel 24
Registros de cuarentena por tabla 25
Detalle de cuarentena por motivo de rechazo 26
Modelo Dimensional Gold 27
Conteos del modelo dimensional Gold 27
Orquestación e Idempotencia 28

Anexo de idempotencia del pipeline *28*
ALMACENAMIENTO Y PRUEBAS 29
Tamaño de la capa Bronze *29*
Resultado de las pruebas automatizadas de dbt *29*
Tamaño de las capas almacenadas en PostgreSQL *30*
Medición consolidada de todas las capas *31*
GITHUB 31
FASE 02 – VISUALIZACIÓN Y FEATURES ANALÍTICOS 32
OBJETIVO 32
MODELO ANALÍTICO UTILIZADO EN TABLEAU 32
RESULTADOS DE VISUALIZACIÓN 32
Abordajes por modo *32*
Demanda por zona *32*
Demanda por hora *33*
Usuarios multimodales *33*
Viajes por estación de MetroRiel *33*
Dashboard Red Metropolitana *33*
FEATURES DE MOVILIDAD DEL USUARIO 33
VALIDACIÓN DE DBT 34
INTERPRETACIÓN Y PROPUESTA DE ACCIÓN 34
Interpretación de resultados *34*
Propuesta de acción *35*
CONCLUSIONES 36
RECOMENDACIONES 37
ANEXOS – FASE 02 38
TABLEAU DESKOP 38
Modelo de datos de la Red Metropolitana en Tableau *38*
Distribución de abordajes por modo de transporte *39*
Análisis de la demanda de abordajes por zona *40*
Análisis de la demanda de abordajes por hora *41*
Análisis de usuarios multimodales de la Red Metropolitana *42*
Distribución de viajes por estación de MetroRiel *43*
Análisis de cobertura de transporte por zona *44*
Dashboard interactivo de la Red Metropolitana *45*

PRUEBAS EN PYCHARM 46
Validación de registros de features de movilidad de usuarios *46*
Muestra de características de movilidad generadas por usuario *47*
Ejecución exitosa de los modelos de transformación con dbt *48*
Validación de calidad de datos mediante pruebas dbt *49*
CANTIDAD DE USUARIOS Y MODOS 50
Validación de registros de features de movilidad de usuarios *51*
Muestra de características de movilidad generadas por usuario *52*
Usuario Multimodales *53*
Demanda en zonas 12, 8, 1, 6 y 17 ..... *54*
Demanda total en zonas objetivo del caso MetroRiel *55*
Tablas silver para Feature *56*
Distribución de usuarios según modos de transporte *57*
Demanda total por modo de transporte *58*
Ranking territorial de demanda sin MetroRiel *59*
Conteos de referencia entre Silver y Gold *60*
GITHUB 60

Introducción

Este documento reúne las Anexos técnicas obtenidas durante la implementación y validación de la Fase 01 del Proyecto Red Metropolitana de Transporte. Las capturas respaldan el funcionamiento de la infraestructura, la carga de datos, el procesamiento CDC, las reglas de calidad, el modelo dimensional y la auditoría del pipeline.

Cada Anexo se presenta con un título, una descripción interpretativa y la captura correspondiente. Los valores se explican en relación con su propósito dentro de la arquitectura, de modo que el documento pueda utilizarse como anexo de validación y como referencia para la revisión académica del proyecto.

La conclusión general es que el flujo funciona de extremo a extremo y conserva la trazabilidad de los datos. Las dos ejecuciones evaluadas produjeron los mismos conteos, las reglas de calidad separaron los registros inválidos y las pruebas de dbt finalizaron sin errores.

Fase 01 - Desglose de la arquitectura

La Fase 01 del proyecto Red Metropolitana consiste en construir una arquitectura de datos capaz de integrar información de Transmetro, Transurbano, MetroRiel y Aerometro mediante cargas batch, streaming con Kafka y CDC. Los datos originales se almacenan en la capa Bronze, luego se limpian, normalizan y validan en Silver, mientras que los registros que incumplen las reglas de calidad se trasladan a Cuarentena. Finalmente, la información se organiza en un modelo dimensional Gold con dimensiones y tablas de hechos, utilizando PostgreSQL, dbt y Prefect. Además, se comprueba la calidad, trazabilidad e idempotencia del pipeline mediante pruebas, métricas y dos ejecuciones con resultados consistentes.

Objetivos

Objetivo general

Documentar las decisiones de arquitectura, los métodos aplicados y los resultados que demuestran el funcionamiento de la Fase 01 del pipeline de la Red Metropolitana.

Objetivos específicos

- Explicar la selección de los métodos de ingesta, almacenamiento y transformación.
- Describir el tratamiento del padrón CDC, la identidad y las reglas de calidad.
- Justificar el grano y la estructura del modelo dimensional Gold.
- Presentar las métricas, pruebas y Anexos de idempotencia del pipeline.

Problemática

El sistema de transporte del área metropolitana de Guatemala está conformado por distintos operadores que administran su información de manera independiente. Transmetro, Transurbano, MetroRiel y Aerometro utilizan formatos, estructuras e identificadores diferentes, lo cual dificulta integrar los datos y obtener una visión completa del funcionamiento de la red.

Las fuentes presentan diferencias importantes. Algunas registran abordajes individuales, mientras que MetroRiel almacena viajes completos con entrada y salida. También existen variaciones en los formatos de fecha, zonas, monedas, zonas horarias y llaves de usuario. Por ejemplo, Transurbano registra los montos en centavos, Aerometro utiliza horario UTC y cada operador identifica a sus usuarios de una manera distinta.

Además, el padrón de usuarios de Transmetro contiene operaciones CDC de inserción, actualización y eliminación que deben procesarse respetando su orden. Los registros eliminados no pueden borrarse físicamente porque esto provocaría la pérdida del historial de viajes asociado con cada tarjeta.

También se encontraron problemas de calidad, como validaciones duplicadas, llaves inexistentes, códigos de parada nulos, fechas futuras y viajes de MetroRiel sin estación de salida. Descartar estos datos impediría conocer el origen de los errores y reduciría la trazabilidad del sistema.

Por lo tanto, la problemática principal consiste en la ausencia de una plataforma unificada que permita integrar, limpiar, validar y analizar la información de los cuatro operadores sin perder los datos originales ni el historial de los usuarios.

Solución Implementada

Para resolver la problemática se implementó un pipeline de ingeniería de datos organizado mediante una arquitectura por capas. La solución integra los diferentes métodos de ingesta, conserva los datos originales, aplica reglas de calidad y construye un modelo dimensional preparado para el análisis.

La ingesta se dividió de acuerdo con las características de cada fuente. Las validaciones de Transmetro y los abordajes de Aerometro se procesaron mediante streaming con Kafka, debido a que representan eventos que podrían recibirse continuamente. Los catálogos, los viajes de MetroRiel y las transacciones de Transurbano se procesaron mediante cargas batch. El padrón de usuarios de Transmetro se trató como CDC porque contiene inserciones, actualizaciones y eliminaciones.

Los archivos recibidos se almacenaron en la capa Bronze mediante carpetas y archivos Parquet particionados por fecha. Esta capa conserva la información original y permite reprocesar las fuentes cuando sea necesario. Posteriormente, los datos se cargaron temporalmente en Staging dentro de PostgreSQL.

En Silver se unificaron los formatos de fecha, hora, moneda, zona e identificadores. También se procesó el padrón CDC, se construyeron los catálogos mínimos de usuarios y se aplicaron las reglas de calidad. Los registros inválidos no se eliminaron, sino que fueron trasladados a cuarentena junto con el motivo específico del rechazo.

La capa Gold se construyó exclusivamente a partir de Silver. Se crearon cinco dimensiones conformadas y dos tablas de hechos: una para los abordajes y otra para los viajes completos de MetroRiel. Las llaves originales de los usuarios fueron reemplazadas por identificadores seudonimizados para proteger la información personal.

Las transformaciones y pruebas se desarrollaron con dbt, mientras que Prefect se utilizó para ejecutar y controlar las etapas del pipeline. La infraestructura se levantó con Docker y los resultados de cada corrida se registraron en el esquema de auditoría.

Metodología y arquitectura del proyecto

Las siguientes decisiones responden, una por una, a los criterios indicados en el documento del proyecto. Se presentan en la misma secuencia lógica utilizada para construir y validar la solución.

Método general de trabajo

Se aplicó una metodología de ingeniería de datos por capas. Las fuentes ingresan mediante streaming, batch o CDC; se conservan en Bronze; se cargan temporalmente en Staging; se limpian y conforman en Silver; y finalmente se modelan en Gold para análisis. Cada etapa tiene una responsabilidad definida y puede validarse por separado.

Arquitectura seleccionada

La arquitectura combina Kafka en Docker para streaming, un lake local con archivos Parquet para Bronze, PostgreSQL para Staging, Silver, Gold, cuarentena y auditoría, dbt para las transformaciones y pruebas, y Prefect para la orquestación. Tableau queda establecido como consumidor de Gold para la Fase 02.

Separación entre las capas

Gold nunca consulta Bronze directamente. Los datos siempre pasan por Silver para recibir limpieza, normalización y controles de calidad. Los registros inválidos se almacenan en cuarentena, Bronze se conserva y Staging se vacía al finalizar cada ejecución.

Orden de diseño

El modelo se definió a partir de los procesos de negocio y de la matriz del bus. Este orden permitió identificar primero los granos, las tablas de hechos y las dimensiones conformadas antes de construir físicamente las tablas Gold.

Decisiones de ingesta y almacenamiento Bronze

Métodos de ingesta por fuente

Las validaciones de Transmetro y los abordajes de Aerometro se procesan mediante streaming con Kafka porque representan eventos continuos. Los catálogos y los viajes completos de MetroRiel se cargan por batch. El padrón de usuarios utiliza CDC porque contiene inserciones, actualizaciones y eliminaciones.

Método elegido para Transurbano

Transurbano se procesa mediante batch porque la fuente fue entregada como un archivo completo de transacciones y no como un flujo continuo. Esta decisión simplifica la carga y la hace reproducible, aunque la información se actualiza por corrida y no en tiempo real.

Ubicación de la capa Bronze

Bronze se almacena en un lake local organizado en carpetas y particiones por fecha. Esta alternativa permite conservar los datos tal como llegaron, mantener trazabilidad y volver a procesarlos sin modificar la fuente original.

Formato de almacenamiento

Se seleccionó Parquet porque conserva tipos de datos, ofrece compresión y reduce el espacio utilizado. También permite guardar el contenido anidado de MetroRiel sin imponer inmediatamente una estructura relacional. La medición realizada reportó 67 MB en Bronze.

Decisiones de Staging y procesamiento CDC

Uso de Staging

Staging funciona como una zona temporal de carga. Recibe los archivos de cada ejecución y se vacía cuando finaliza el pipeline. Bronze permanece conservado, por lo que siempre existe una fuente desde la cual reprocesar los datos.

Aplicación de las operaciones CDC

El padrón se procesa respetando el orden de la columna de secuencia. INSERT crea una tarjeta, UPDATE modifica sus atributos y DELETE la marca como inactiva. Los borrados son lógicos para no perder el historial de viajes asociado con la tarjeta.

Resultado del padrón vigente

Se procesaron 31,050 operaciones CDC: 10,800 inserciones, 16,200 actualizaciones y 4,050 eliminaciones. El estado final contiene 17,432 tarjetas, de las cuales 15,096 están activas y 2,336 inactivas.

Catálogos mínimos de usuarios

Aerometro, MetroRiel y Transurbano no entregaron un padrón. Para cada operador se construyó un catálogo con las llaves distintas encontradas en sus operaciones, sin inventar nombres ni otros atributos. Se identificaron 14,496 usuarios de Aerometro, 22,885 de MetroRiel y 36,567 de Transurbano.

Decisiones de integración y calidad en Silver

Unificación de formatos

En Silver se estandarizaron fechas y horas, se convirtió la hora UTC de Aerometro a la hora local de Guatemala y se transformaron los centavos de Transurbano a quetzales. También se limpiaron espacios, identificadores y nombres de operadores.

Conformación de zonas

Las distintas representaciones de una zona se normalizaron para apuntar a una misma llave. Por ejemplo, Z10, Zona 10 y su equivalencia proveniente del campo district se interpretan como la misma zona dentro del modelo integrado.

Estrategia de identidad del usuario

Las llaves de origen se normalizan y se relacionan con su operador. Antes de Gold se genera una llave sustituta seudonimizada mediante un hash determinístico. La limitación es que no existe una tabla oficial que demuestre que tarjetas diferentes pertenecen a la misma persona; por ello, la identificación multimodal es una aproximación declarada.

Tratamiento de los registros inválidos

Los registros que incumplen una regla no se descartan. Se trasladan a cuarentena junto con el motivo de rechazo. Se controlan llaves ausentes o no reconocidas, viajes sin salida, validaciones duplicadas, códigos de parada nulos y fechas futuras. El total documentado es de 18,431 registros.

Historización del padrón

El padrón se historiza con el enfoque SCD Tipo 2. Los cambios generan versiones con un periodo de vigencia y un indicador de registro actual, de manera que sea posible consultar tanto el estado presente como la evolución de los atributos del usuario.

Decisiones del modelo dimensional Gold

Grano de la tabla de hechos principal

El grano de fct_abordajes es un abordaje válido realizado por un usuario, en un modo de transporte, ubicación y fecha y hora determinadas. Cada fila representa un evento individual y no un resumen diario o mensual.

Separación de las tablas de hechos

Se crearon fct_abordajes y fct_viajes_metroriel porque no representan exactamente el mismo proceso. Los primeros tres operadores registran abordajes, mientras que MetroRiel entrega un viaje completo con entrada, salida y duración. Mantener dos hechos evita perder ese detalle.

Dimensiones conformadas

Las tablas de hechos comparten las dimensiones dim_fecha, dim_hora, dim_modo, dim_usuario y dim_zona. Estas dimensiones mantienen definiciones y llaves comunes para comparar operadores sin repetir reglas de interpretación.

Clasificación de las medidas

El monto, la cantidad de abordajes y la cantidad de viajes son medidas aditivas. Los estados o saldos observados a través del tiempo son semi aditivos. Los porcentajes, promedios,

duraciones promedio y usuarios distintos son no aditivos y deben recalcularse para cada nivel de análisis.

Orquestación pruebas métricas e idempotencia

Herramienta de transformación

Se eligió dbt porque permite organizar los modelos SQL, declarar dependencias, ejecutar pruebas y generar linaje. La validación final registró 79 pruebas aprobadas, sin errores, advertencias ni pruebas omitidas.

Orquestación del flujo

Prefect coordina la ingesta hacia Bronze, la carga de Staging, la ejecución de dbt build, el registro de auditoría y la limpieza de Staging. También registra el resultado y la duración de las etapas para facilitar el seguimiento del pipeline.

Comprobación de idempotencia

El pipeline se ejecutó dos veces y conservó los mismos conteos: 1,730,184 registros en Staging, 1,919,887 en Silver, 1,718,037 en Gold y 18,431 en cuarentena. La igualdad demuestra que una nueva corrida no introduce duplicados.

Métricas documentadas

Se reportaron filas por fuente, conteos de Silver y Gold, registros de cuarentena por motivo, operaciones CDC, usuarios activos e inactivos, duración de las corridas y tamaño en disco por capa. Estas cifras convierten las afirmaciones del proyecto en resultados medidos.

Gobernanza seguridad y alcance posterior

Definiciones oficiales

Se define un abordaje como un acceso válido registrado por un operador; un viaje de MetroRiel como un trayecto con entrada y salida; un usuario activo como una tarjeta cuyo último estado CDC es activo; y un registro inválido como aquel que se conserva en cuarentena por incumplir una regla.

Responsabilidad y linaje

El equipo de datos administra las dimensiones de fecha y hora; el área de planificación autoriza cambios en la dimensión zona; operaciones validas los modos de transporte; y gobernanza y seguridad administran la dimensión usuario. El linaje de dbt permite rastrear los modelos hasta las fuentes originales.

Documentación y reproducibilidad

El repositorio contiene requisitos, pasos de instalación, instrucciones para ejecutar el flujo y las decisiones de diseño. El historial de Git conserva los cambios realizados durante el desarrollo y no se limita a una única carga final.

Seguridad y datos personales

Las credenciales se administran con variables de entorno y el repositorio incluye únicamente un archivo de ejemplo. Las llaves se seudonimizan antes de Gold. Los analistas consultan información agregada, mientras que el detalle individual queda restringido a personal autorizado. Se propone conservar el detalle durante 12 meses y después mantener datos agregados o anonimizados.

Conclusión

- La arquitectura implementada permitió integrar correctamente fuentes con estructuras, formatos y niveles de detalle diferentes. La separación en Bronze, Staging, Silver y Gold facilitó controlar el procesamiento y mantener la trazabilidad de los datos.
- Los métodos de ingesta fueron seleccionados según las características de cada fuente. El uso de streaming, batch y CDC permitió representar adecuadamente eventos continuos, archivos periódicos y cambios en el padrón de usuarios.
- La capa Bronze conservó los datos originales en archivos Parquet, lo cual permite realizar nuevos procesamientos sin depender de las tablas transformadas. El tamaño medido de esta capa fue de 67 MB.
- El procesamiento CDC permitió aplicar 31,050 operaciones y construir el estado vigente del padrón. Como resultado, se obtuvieron 15,096 tarjetas activas y 2,336 tarjetas inactivas.
- Las reglas de calidad identificaron 18,431 registros inválidos. Estos datos fueron almacenados en cuarentena con su respectivo motivo, en lugar de ser eliminados silenciosamente.
- El modelo dimensional Gold quedó conformado por cinco dimensiones y dos tablas de hechos. En esta capa se almacenaron 1,718,037 registros preparados para el análisis posterior en Tableau.
- Las 79 pruebas configuradas en dbt finalizaron correctamente, sin errores, advertencias ni pruebas omitidas. Esto respalda la integridad y consistencia de los modelos construidos.
- La idempotencia del pipeline fue comprobada mediante dos ejecuciones consecutivas. Ambas conservaron los mismos conteos en Staging, Silver, Gold y cuarentena, demostrando que una nueva corrida no genera duplicados.
- La Fase 01 proporciona una base técnica completa y reproducible para continuar con la visualización, el análisis de cobertura, la evaluación de la demanda y la construcción de features durante la Fase 02.

Recomendaciones

- Implementar el tablero de la Fase 02 conectándolo exclusivamente con la capa Gold, evitando consultar directamente las fuentes originales, Bronze o Staging.
- Incorporar alertas de frescura que permitan detectar cuando una fuente no haya llegado dentro del periodo esperado o presente una reducción anormal en la cantidad de registros.
- Configurar GitHub Actions para ejecutar automáticamente las pruebas de dbt cada vez que se realice un cambio en el repositorio. Esto permitiría detectar errores antes de integrar nuevas modificaciones.
- Evaluar el uso de modelos incrementales de dbt cuando aumente el volumen de información, de manera que solamente se procesen los registros nuevos o modificados.
- Fortalecer la estrategia de identidad mediante una tabla oficial que relacione las tarjetas de los diferentes operadores. Esto permitiría identificar con mayor precisión a los usuarios multimodales.
- Mantener documentadas las definiciones oficiales de abordaje, viaje, usuario activo, zona y registro inválido para garantizar que todos los integrantes calculen las métricas de la misma manera.
- Asignar responsables para las dimensiones conformadas. Los cambios en zonas, modos, usuarios o reglas de calidad deben ser revisados y autorizados antes de aplicarse en producción.
- Restringir el acceso al detalle individual de los viajes. Los analistas deberían consultar información agregada, mientras que los datos personales solamente deben estar disponibles para usuarios autorizados.
- Definir una política de retención. Se recomienda conservar el detalle individual durante 12 meses y, después de ese periodo, mantener únicamente información agregada o anonimizada.
- Conservar las evidencias de ejecución, los conteos y las métricas de rendimiento para comparar futuras versiones del pipeline y detectar cambios inesperados.

Anexos – Fase 01

Infraestructura y Servicios

Servicios de infraestructura en Docker Desktop

La captura muestra el grupo de contenedores del proyecto en Docker Desktop. Kafka y PostgreSQL se encuentran en ejecución y exponen los puertos 9092 y 5432, respectivamente. Esta Anexo confirma la disponibilidad de la infraestructura requerida para la mensajería y el almacenamiento relacional del pipeline.

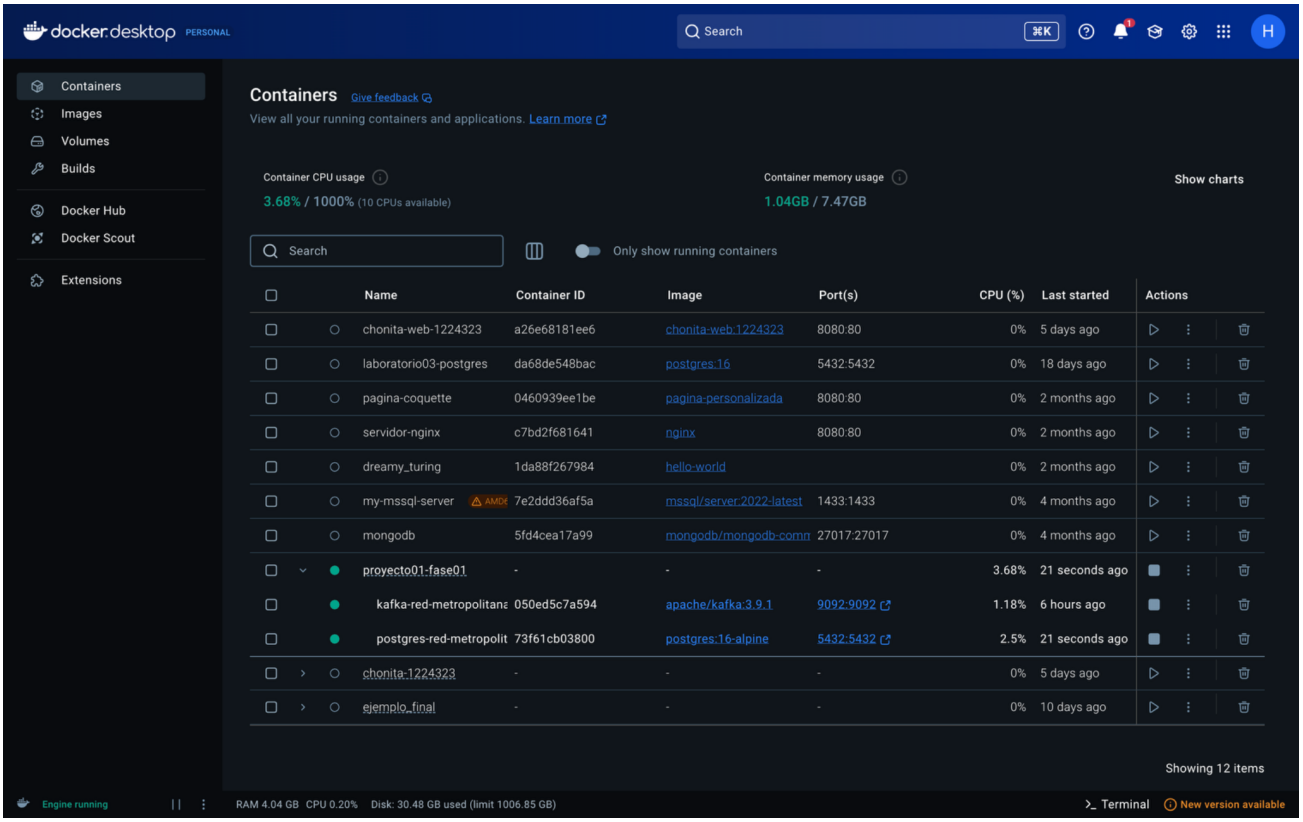

Anexo 1. Contenedores Kafka y PostgreSQL activos en Docker Desktop.

Verificación de servicios con Docker Compose

Se ejecutaron los comandos de Docker Compose para iniciar los servicios y consultar su estado. La salida confirma que Kafka y PostgreSQL fueron creados y levantados con sus puertos configurados, lo que permite reproducir el entorno de trabajo de la Fase 01.

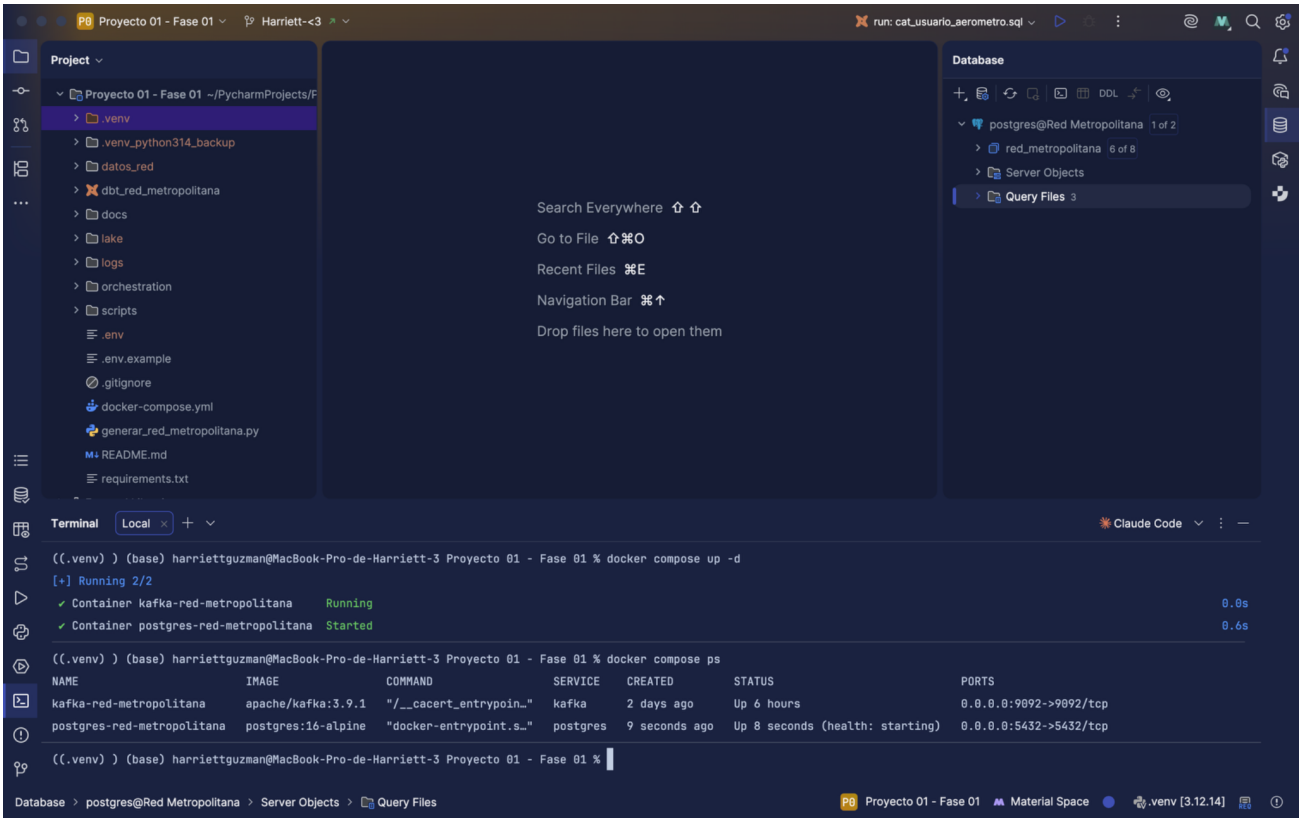

Anexo 2. Inicio y comprobación de los servicios mediante Docker Compose.

Ingesta y Capa Staging

Conteo de registros por fuente en Staging

La consulta valida la carga de las nueve fuentes en el esquema Staging. En conjunto se registran 1,730,184 filas: transacciones, validaciones, viajes, abordajes, catálogos de estaciones y paradas, además del padrón CDC. El total coincide con el volumen de entrada documentado para la fase.

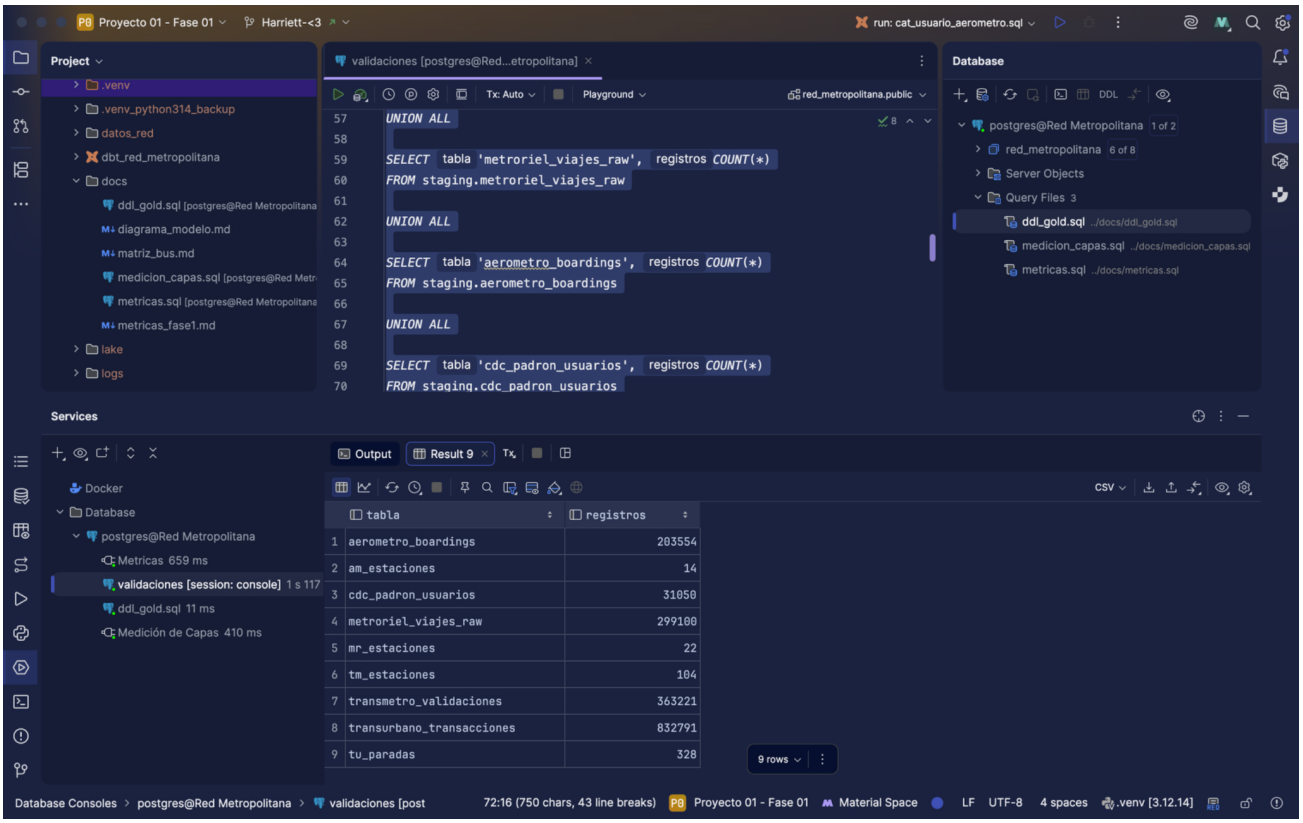

Anexo 3. Distribución de los 1,730,184 registros cargados en Staging.

Procesamiento CDC y Usuarios

Operaciones CDC procesadas

El archivo del padrón contiene 31,050 operaciones de cambio: 10,800 inserciones, 16,200 actualizaciones y 4,050 eliminaciones lógicas. El desglose demuestra que las operaciones CDC fueron identificadas y contabilizadas antes de construir el estado actual de los usuarios.

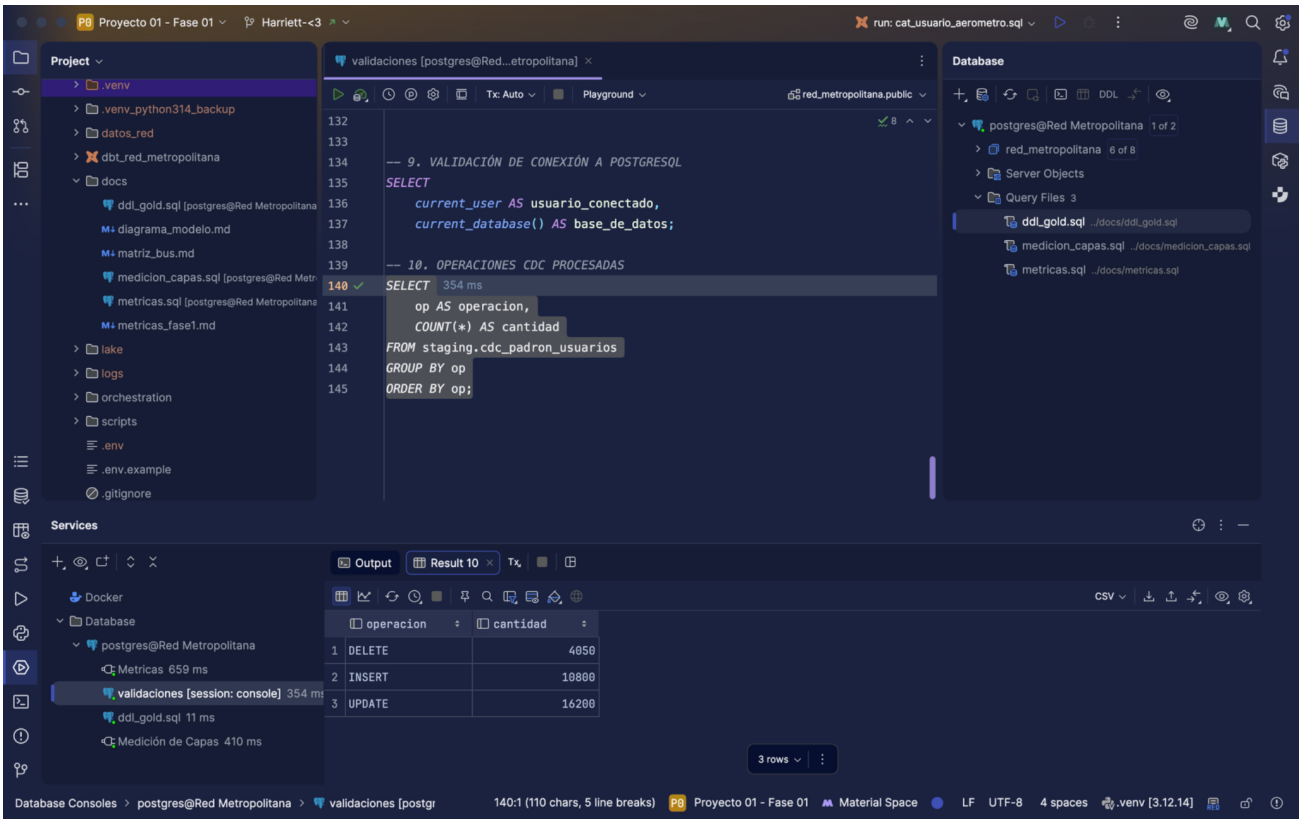

Anexo 4. Conteo de operaciones INSERT, UPDATE y DELETE del padrón CDC.

Estado final del padrón de usuarios

Después de aplicar las operaciones CDC, el padrón conserva 17,432 tarjetas: 15,096 activas y 2,336 inactivas. Las eliminaciones se representan mediante un estado inactivo en lugar de borrar físicamente el registro, preservando así la trazabilidad histórica.

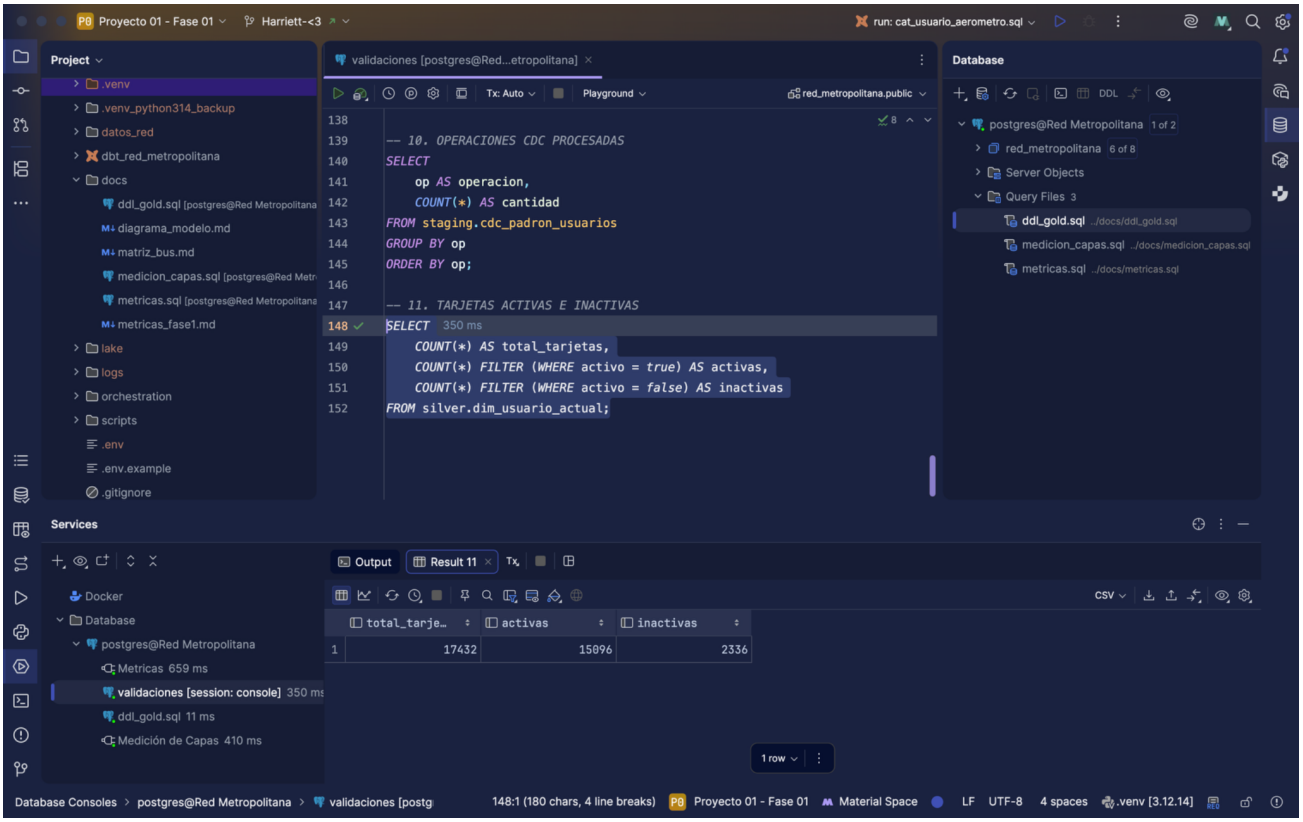

Anexo 5. Cantidad de tarjetas activas e inactivas en Silver.

Catálogos mínimos de usuarios por operador

Los catálogos mínimos reúnen las llaves de usuario distintas detectadas por operador: 14,496 para Aerometro, 22,885 para MetroRiel y 36,567 para Transurbano. Estos conteos sirven como base para conformar identidades entre las distintas fuentes del sistema.

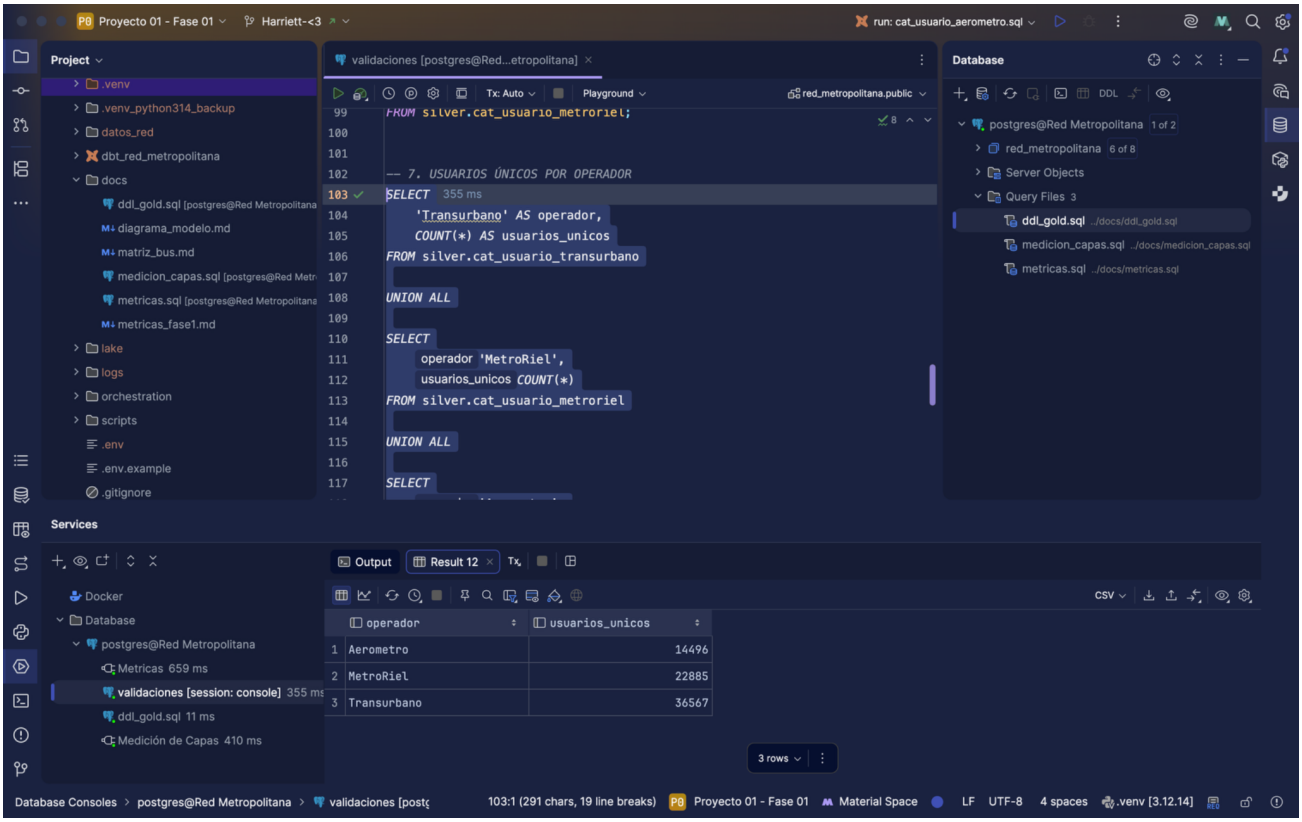

Anexo 6. Usuarios distintos identificados en cada operador.

Calidad y Conformación en Silver

Validación de viajes de MetroRiel

De los 299,100 viajes originales de MetroRiel, 295,511 cumplen las reglas de calidad y pasan a Silver. Los 3,589 registros restantes no poseen salida y se trasladan a cuarentena. La suma de ambos resultados coincide con el total de origen.

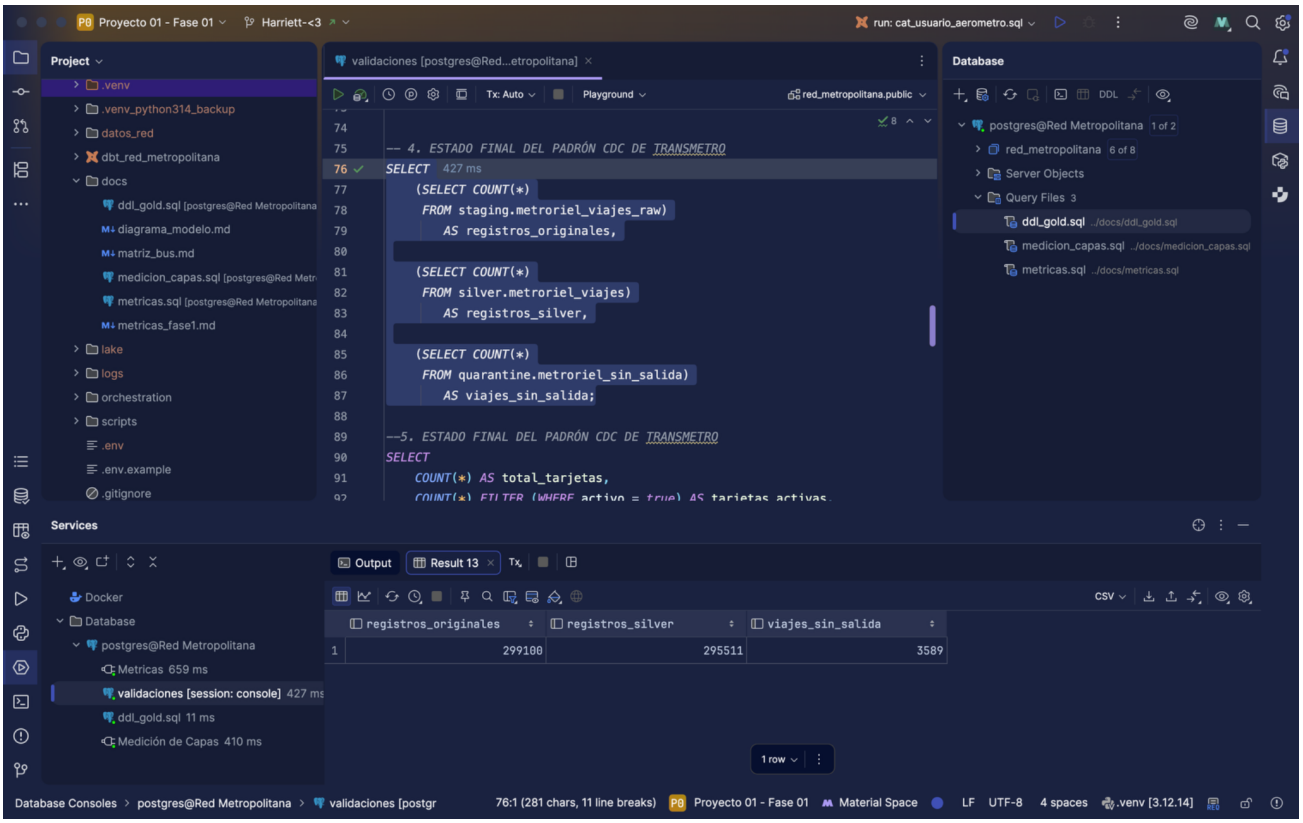

Anexo 7. Conciliación entre viajes originales, válidos y enviados a cuarentena.

Registros de cuarentena por tabla

La consulta consolida 18,431 registros rechazados por las reglas de calidad. La mayor cantidad corresponde a llaves CDC inválidas, seguida por datos inválidos de Transurbano, viajes de MetroRiel sin salida y validaciones duplicadas de Transmetro. Aerometro no presenta registros inválidos.

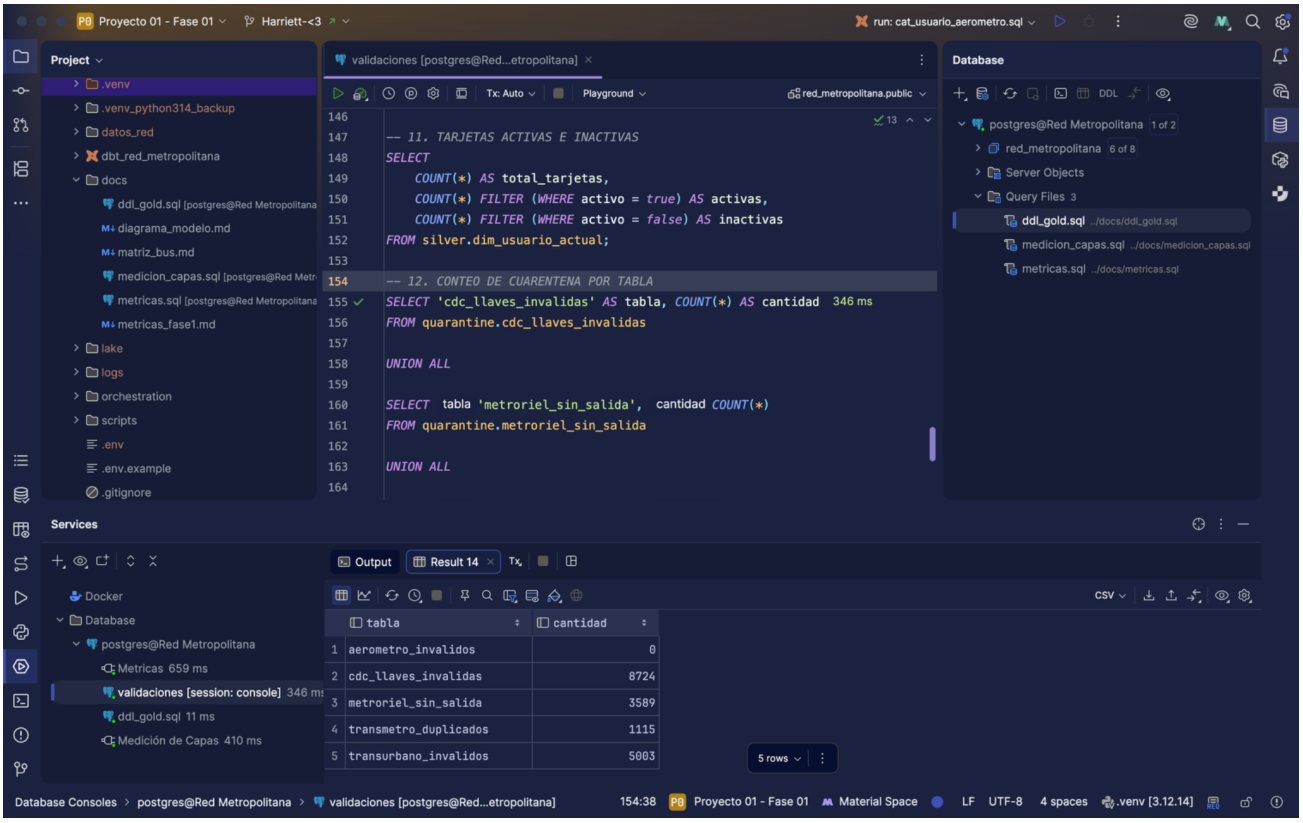

Anexo 8. Conteo total de registros almacenados en cada tabla de cuarentena.

Detalle de cuarentena por motivo de rechazo

El detalle identifica el motivo específico de cada rechazo: llaves ausentes o ajenas al padrón, viajes sin salida, validaciones duplicadas, códigos de parada nulos y fechas futuras. Esta clasificación permite auditar la calidad, explicar las exclusiones y definir acciones de corrección por fuente.

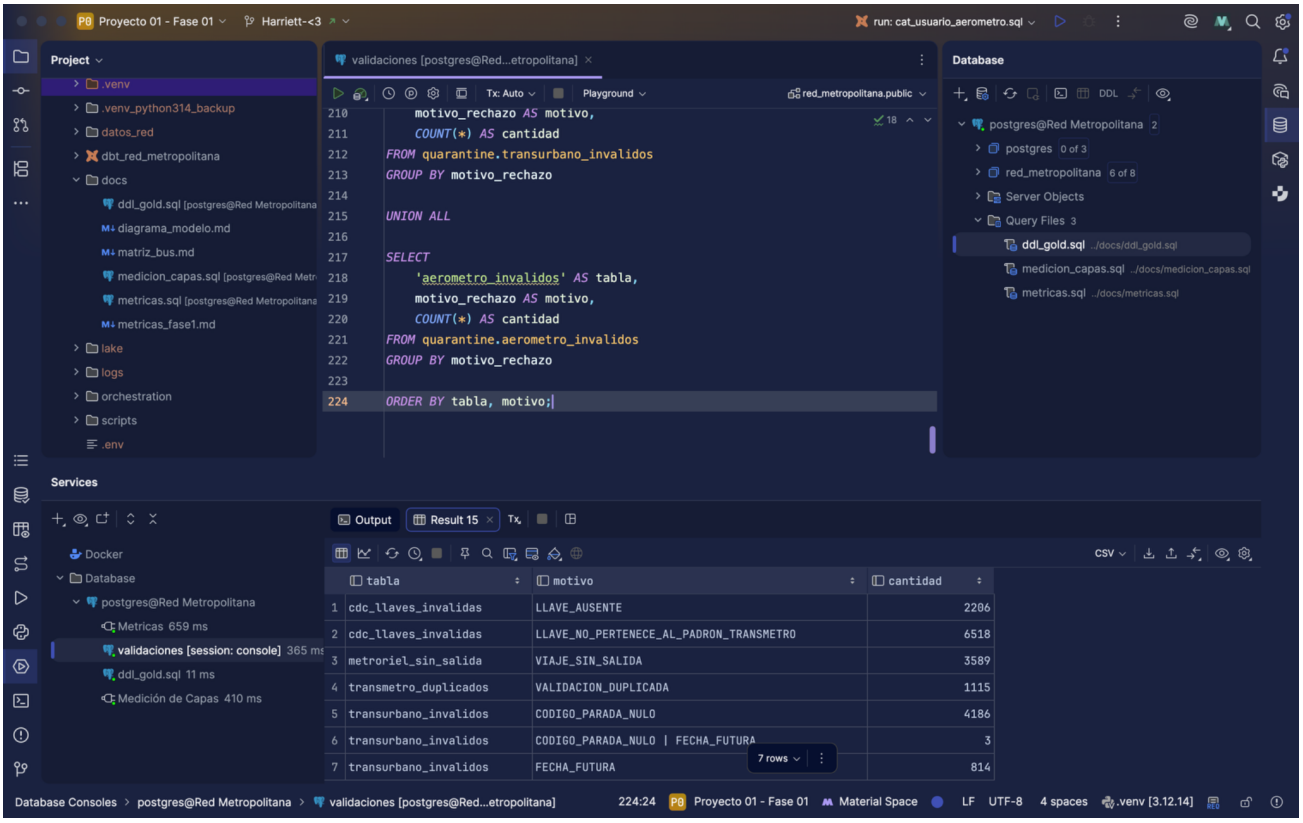

Anexo 9. Distribución de registros de cuarentena según la regla incumplida.

Modelo Dimensional Gold

Conteos del modelo dimensional Gold

La capa Gold contiene cinco dimensiones conformadas y dos tablas de hechos. Destacan 1,352,058 abordajes, 295,511 viajes de MetroRiel y 70,380 usuarios conformados. El total de 1,718,037 registros confirman la construcción del modelo dimensional destinado al análisis.

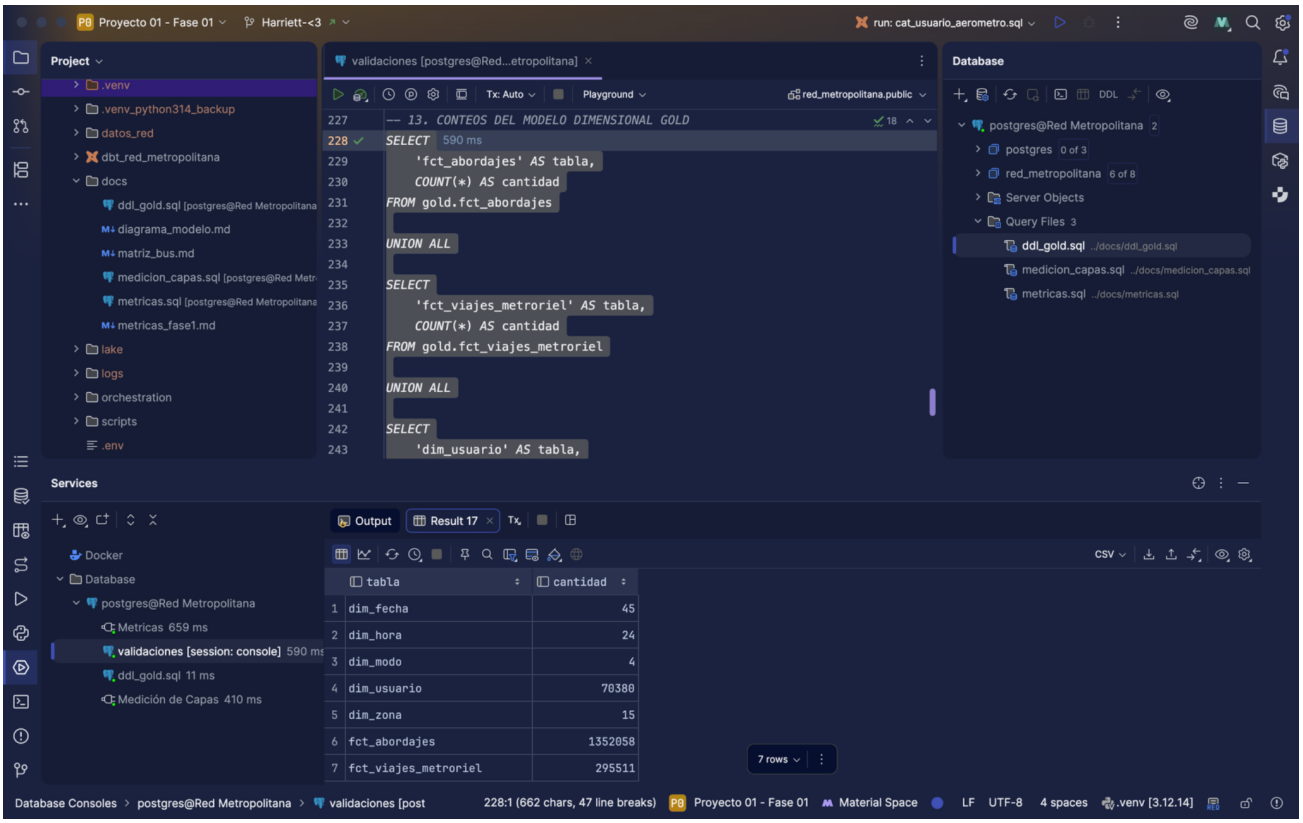

Anexo 10. Cantidad de registros en dimensiones y hechos del esquema Gold.

Orquestación e Idempotencia

Anexo de idempotencia del pipeline

Las dos ejecuciones más recientes finalizaron con estado EXITOSA y conservaron los mismos conteos: 1,730,184 registros en Staging, 1,919,887 en Silver, 1,718,037 en Gold y 18,431 en cuarentena. Las duraciones fueron 71.28 y 72.60 segundos. La igualdad de resultados demuestra que una nueva corrida no introduce duplicados.

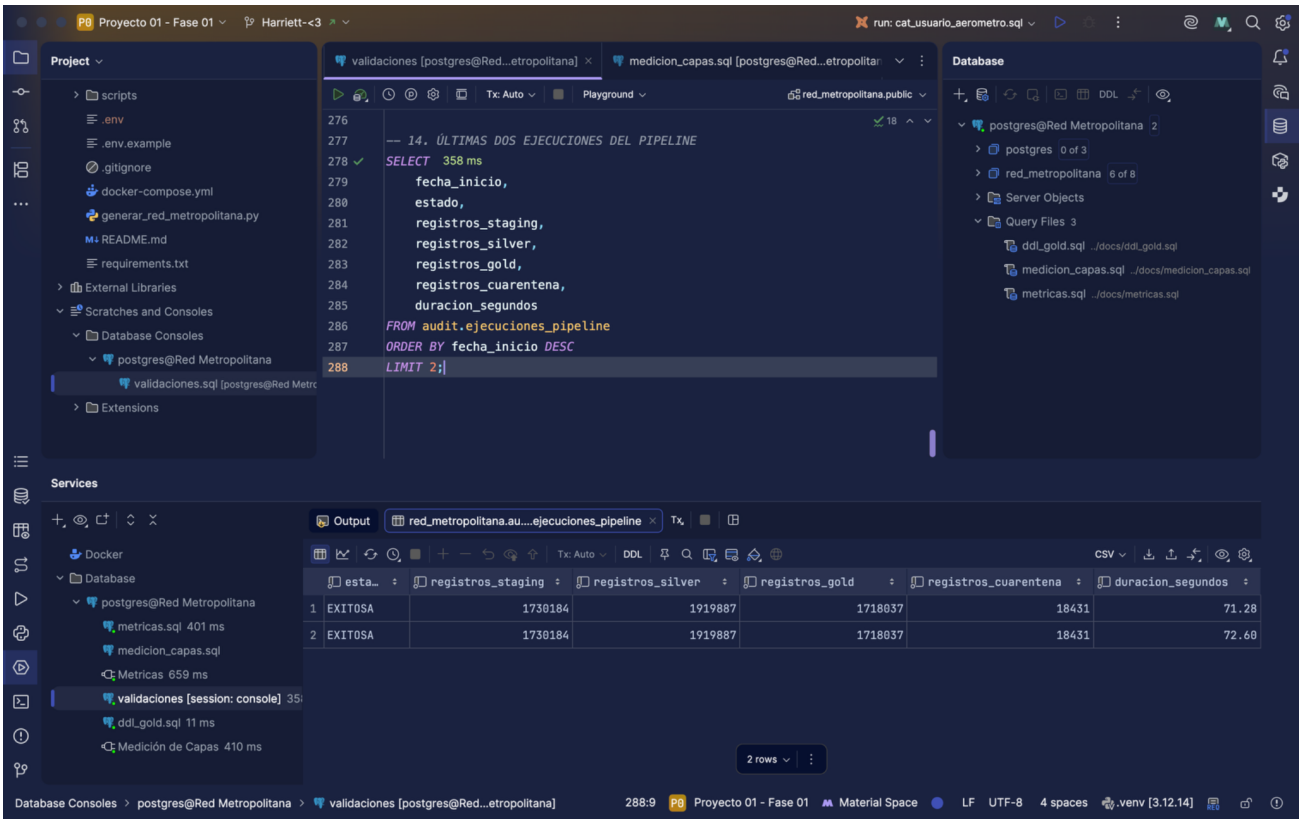

Anexo 11. Dos ejecuciones exitosas con conteos idénticos.

Almacenamiento y Pruebas

Tamaño de la capa Bronze

La capa Bronze se conserva fuera de PostgreSQL, en el sistema de archivos. El comando de medición reporta 67 MB para la carpeta lake/bronze, que contiene los archivos crudos utilizados para trazabilidad y reprocesamiento.

```
((.venv) ) (base) harriettguzman@MacBook-Pro-de-Harriett-3 Proyecto 01 - Fase 01 % du -sh lake/bronze
 67M    lake/bronze
```

Anexo 12. Medición de 67 MB para la capa Bronze.

Resultado de las pruebas automatizadas de dbt

La ejecución de dbt finalizó correctamente: 79 pruebas aprobadas, sin advertencias, errores ni pruebas omitidas. El resultado respalda la validez de las reglas de unicidad, integridad y calidad definidas para los modelos de la Fase 01.

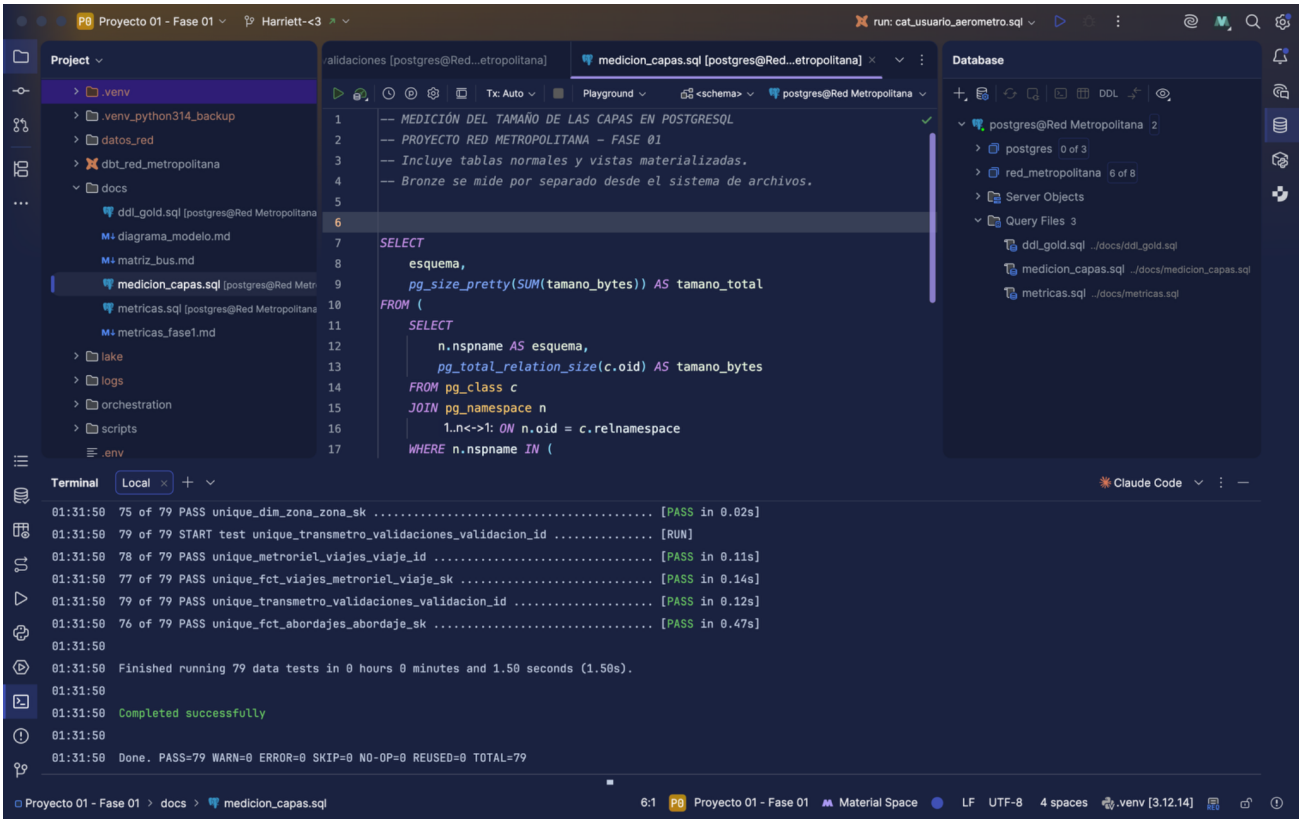

Anexo 13. Resultado PASS=79, WARN=0, ERROR=0 y SKIP=0.

Tamaño de las capas almacenadas en PostgreSQL

La medición inicial calcula el espacio ocupado por tablas y vistas materializadas dentro de PostgreSQL. Los resultados muestran 431 MB en Staging, 276 MB en Silver, 381 MB en Gold, 3,400 kB en cuarentena y 32 kB en Audit. Bronze no aparece aquí porque se almacena en el sistema de archivos.

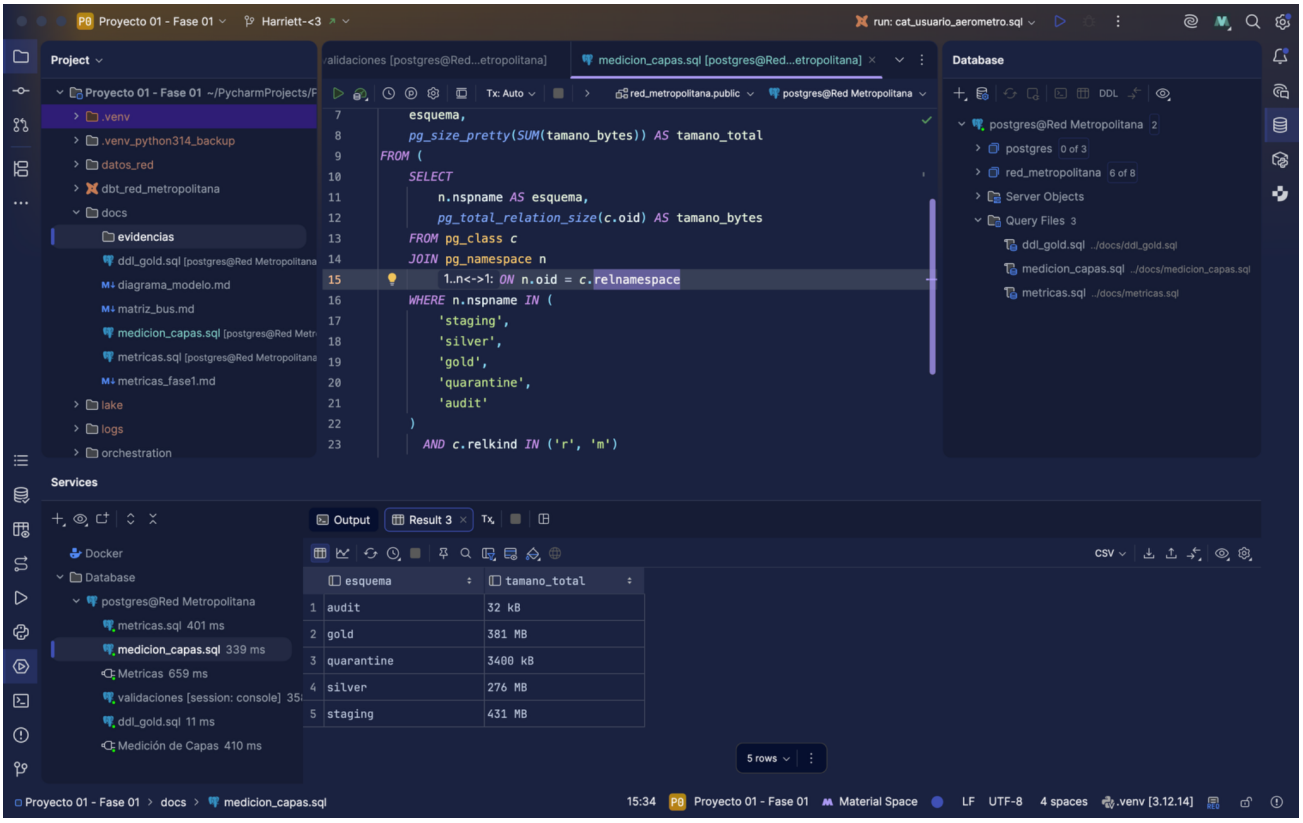

Anexo 14. Medición de los esquemas persistidos en PostgreSQL.

Medición consolidada de todas las capas

La consulta final integra la medición de PostgreSQL con el valor obtenido para Bronze. La columna de fuente distingue el origen de cada dato: sistema de archivos para Bronze y PostgreSQL para las demás capas. De esta manera, el reporte presenta en una sola tabla el tamaño de las seis áreas de almacenamiento del pipeline.

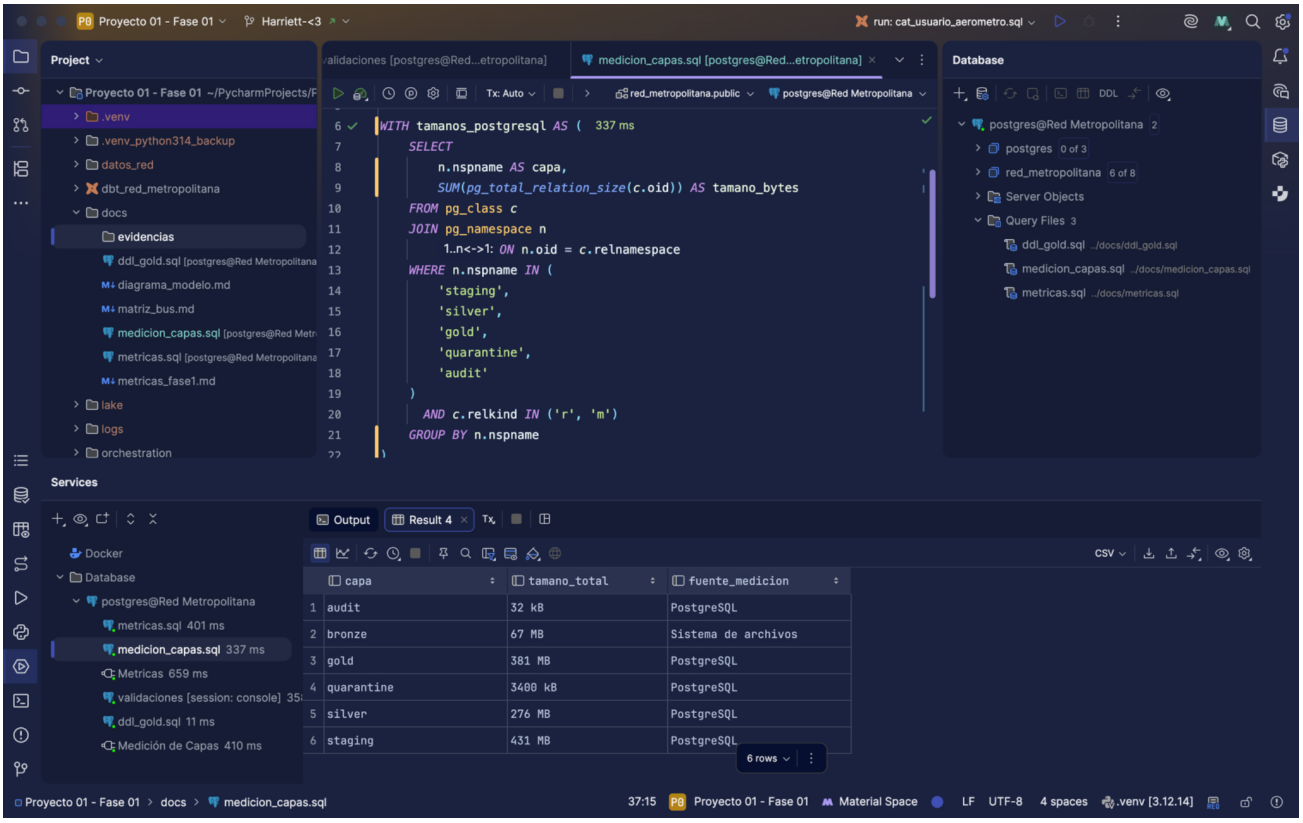

Anexo 15. Resumen consolidado del tamaño y la fuente de medición por capa.

GitHub

https://github.com/harriett-gl/Proyecto01-Fase01.git

Fase 02 – Visualización y Features Analíticos

La Fase 02 amplía la plataforma construida en la Fase 01 mediante dos componentes principales: la explotación analítica de la capa Gold en Tableau y la construcción de una tabla de features orientada al comportamiento de movilidad de los usuarios. La visualización se conecta a PostgreSQL y utiliza las tablas dimensionales y de hechos ya conformadas, evitando consultar directamente Bronze o Staging.

Objetivo

El objetivo de esta fase es convertir los datos integrados y validados en información útil para el análisis de demanda, cobertura y comportamiento de los usuarios. Para ello se construyeron visualizaciones por modo, zona y hora; se analizaron los viajes de MetroRiel; se consolidó un dashboard de la Red Metropolitana; y se creó el modelo features.features_usuario_movilidad para disponer de variables reutilizables en análisis posteriores.

Modelo analítico utilizado en Tableau

Tableau se conectó a la base de datos red_metropolitana y utilizó como fuente principal gold.fct_abordajes, relacionada con las dimensiones dim_fecha, dim_hora, dim_modo, dim_usuario y dim_zona. Para el análisis específico de MetroRiel se utilizó gold.fct_viajes_metroriel. Esta estructura conserva la separación definida en el modelo dimensional y permite analizar los hechos desde dimensiones conformadas.

Resultados de visualización

Abordajes por modo

La comparación por modo muestra 786,398 abordajes para Transurbano, 362,106 para Transmetro y 203,554 para Aerómetro. En conjunto, la visualización permite identificar que Transurbano concentra la mayor cantidad de abordajes dentro de los tres modos representados en la tabla de hechos principal.

Demanda por zona

La demanda territorial presenta diferencias entre modos y zonas. Mixco destaca por combinar actividad de los tres operadores y alcanza valores visibles de 50,598 abordajes de

Transurbano, 24,263 de Transmetro y 57,907 de Aerómetro. La matriz de cobertura también evidencia que Aerómetro se concentra en un subconjunto de zonas, mientras Transmetro y Transurbano presentan presencia más amplia en las zonas representadas.

Demanda por hora

La distribución horaria evidencia dos picos principales. El mayor se observa alrededor de las 7:00 con 162,014 abordajes y el segundo alrededor de las 17:00 con 137,152. Estos resultados son consistentes con periodos de alta movilidad y permiten orientar decisiones de capacidad y operación hacia las franjas de mayor presión sobre la red.

Usuarios multimodales

El análisis de usuarios multimodales agrupa a los usuarios según la cantidad de modos identificados. La gráfica muestra una reducción del número de usuarios conforme aumenta la cantidad de modos utilizados: el grupo de un solo modo es el más numeroso, seguido por los usuarios con dos modos y, finalmente, los usuarios identificados en tres modos.

Viajes por estación de MetroRiel

Los 295,511 viajes válidos de MetroRiel se distribuyen de forma relativamente homogénea entre las 22 estaciones de entrada. Los conteos visibles se encuentran aproximadamente entre 13.2 mil y 13.8 mil viajes por estación, lo que facilita comparar estaciones y detectar concentraciones o desviaciones operativas.

Dashboard Red Metropolitana

Las hojas fueron integradas en un dashboard único denominado Red Metropolitana. El tablero reúne abordajes por modo, demanda por zona, demanda por hora, usuarios multimodales, viajes por estaciones de MetroRiel y cobertura por zona. También incorpora filtros de modo y zona para explorar los resultados de forma interactiva.

Features de movilidad del usuario

Se creó el modelo dbt features.features_usuario_movilidad, materializado como tabla en el esquema features. El modelo integra eventos de Transmetro y MetroRiel y genera variables agregadas por usuario, entre ellas total de eventos, días activos, cantidad de modos identificados, zonas distintas y métricas horarias. La tabla resultante contiene 66,140 registros de usuarios con características de movilidad preparadas para análisis posteriores.

Validación de dbt

La ejecución completa de dbt finalizó satisfactoriamente con 29 modelos construidos, sin errores. Posteriormente se ejecutaron 82 pruebas de datos y todas finalizaron con estado PASS, sin advertencias, errores ni pruebas omitidas. Esta ampliación respecto de la Fase 01 incorpora las validaciones asociadas a los nuevos modelos de la Fase 02 y confirma que la construcción analítica mantiene las reglas de calidad definidas en el proyecto.

Interpretación y propuesta de acción

Los resultados permiten priorizar acciones operativas en tres frentes. Primero, la capacidad debería revisarse especialmente alrededor de las 7:00 y 17:00, que concentran los picos observados. Segundo, zonas con demanda combinada elevada, como Mixco, pueden considerarse prioritarias para coordinación entre modos y evaluación de cobertura. Tercero, la tabla de features permite segmentar usuarios por intensidad, diversidad modal, actividad territorial y patrón horario, creando una base para futuros modelos de segmentación, predicción de demanda o análisis de comportamiento.

Interpretación de resultados

Los resultados obtenidos permiten identificar patrones relevantes dentro de la Red Metropolitana. La demanda presenta concentraciones importantes en horarios de alta movilidad, especialmente alrededor de las 7:00 y 17:00 horas, lo que evidencia períodos críticos para la operación del sistema.

En las zonas analizadas también se observan diferencias importantes en la cantidad de abordajes. Entre las zonas objetivo evaluadas, la Zona 17 presenta 94,799 abordajes, seguida de la Zona 12 con 93,933, Zona 1 con 83,367, Zona 8 con 80,157 y Zona 6 con 71,840.

El análisis de multimodalidad identificó 36,829 usuarios multimodales. De la distribución general, 33,551 usuarios utilizan un modo de transporte, 26,833 utilizan dos modos y 9,996 utilizan tres modos. Estos resultados permiten analizar no solamente la demanda individual de cada servicio, sino también la interacción de los usuarios con diferentes modos de la red.

Propuesta de acción

Se propone priorizar la capacidad operativa de la Red Metropolitana durante los horarios de mayor demanda, principalmente alrededor de las 7:00 y 17:00 horas. Asimismo, las zonas con mayor concentración de abordajes deben considerarse prioritarias para ajustes de capacidad y planificación.

La información de usuarios multimodales puede utilizarse para mejorar la integración entre los diferentes servicios de transporte, identificando usuarios que dependen de dos o más modos. Esto permitiría orientar futuras decisiones de conexión, frecuencia y cobertura con base en patrones reales de movilidad.

Conclusiones

- La segunda fase permitió profundizar el análisis de la Red Metropolitana mediante la creación de características orientadas al comportamiento de los usuarios y a sus patrones de movilidad, aprovechando la información previamente integrada y depurada.
- El análisis de multimodalidad permitió identificar 36,829 usuarios multimodales, evidenciando que una parte importante de los usuarios utiliza más de un modo de transporte. Además, se identificaron 33,551 usuarios con un modo, 26,833 con dos modos y 9,996 con tres modos, proporcionando una visión más completa de la interacción entre los distintos servicios.
- El análisis territorial permitió determinar diferencias relevantes en la demanda de las zonas objetivo. La Zona 17 registró la mayor demanda con 94,799 abordajes, seguida de Zona 12 con 93,933, Zona 1 con 83,367, Zona 8 con 80,157 y Zona 6 con 71,840, facilitando la identificación de áreas prioritarias para la planificación.
- La implementación de modelos y pruebas en dbt permitió mantener la calidad de los datos utilizados en esta fase. Las validaciones realizadas sobre el modelo de características de movilidad finalizaron correctamente, incluyendo controles de valores nulos, unicidad y consistencia de los campos principales.
- En conjunto, la Fase 02 transformó los datos procesados en información útil para la toma de decisiones, permitiendo analizar demanda, multimodalidad, zonas y períodos de mayor actividad dentro de la Red Metropolitana.

Recomendaciones

- Priorizar la capacidad operativa y disponibilidad de los servicios en las zonas y horarios que presentan mayor demanda, utilizando los resultados obtenidos como apoyo para la planificación de recursos.
- Fortalecer la integración entre los diferentes modos de transporte, especialmente considerando los 36,829 usuarios multimodales, con el objetivo de facilitar conexiones y mejorar la experiencia de movilidad de quienes utilizan varios servicios.
- Mantener y ampliar las pruebas automatizadas de dbt, incorporando nuevas validaciones conforme se agreguen modelos o características, para asegurar la confiabilidad y consistencia de la información.
- Utilizar los indicadores obtenidos en dashboards que permitan visualizar de forma sencilla la demanda por zona, modo de transporte, horarios y comportamiento multimodal, facilitando el análisis por parte de los responsables de la operación.
- Continuar utilizando la arquitectura desarrollada en las fases anteriores como base para análisis más avanzados, incorporando posteriormente modelos predictivos que permitan anticipar cambios en la demanda y apoyar una planificación más eficiente de la Red Metropolitana.

Anexos – Fase 02

Tableau Deskop

Modelo de datos de la Red Metropolitana en Tableau

La imagen muestra el modelo de datos utilizado en Tableau, donde la tabla de hechos fct_abordajes se relaciona con las dimensiones de fecha, hora, modo, usuario y zona. Esta estructura permite analizar los abordajes desde distintas perspectivas manteniendo un modelo organizado y consistente.

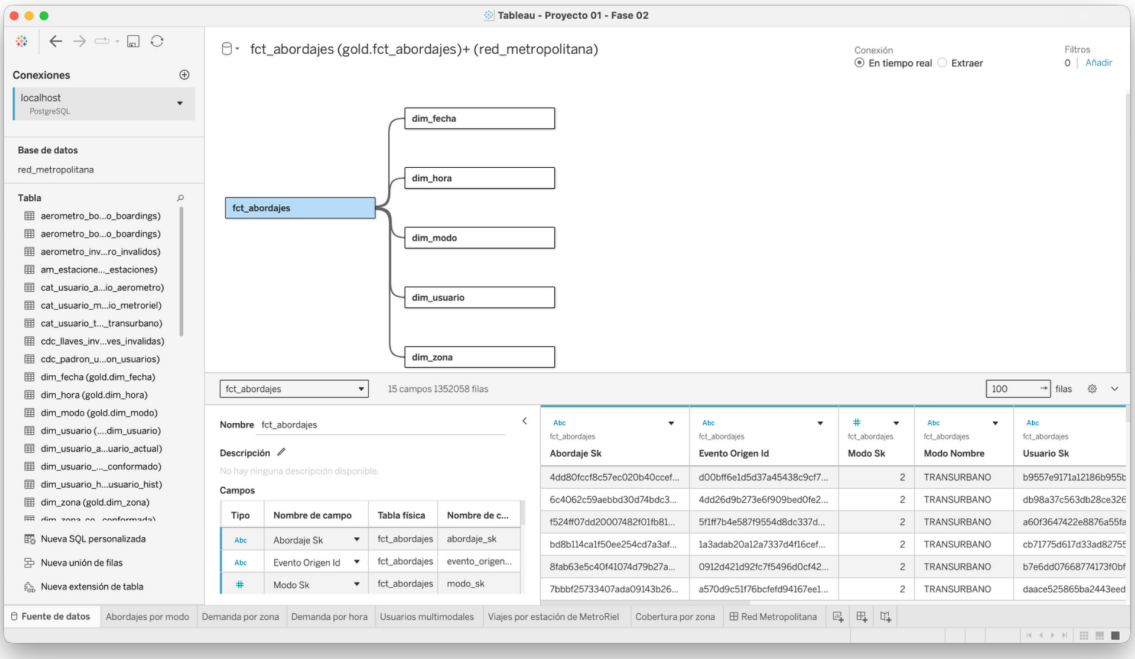

Anexo 16. Modelo de datos de fct_abordajes y dimensiones conformadas en Tableau.

Distribución de abordajes por modo de transporte

La visualización compara la cantidad total de abordajes por modo de transporte. Se observa que Transurbano registra la mayor demanda con 786,398 abordajes, seguido de Transmetro con 362,106 y Aerómetro con 203,554.

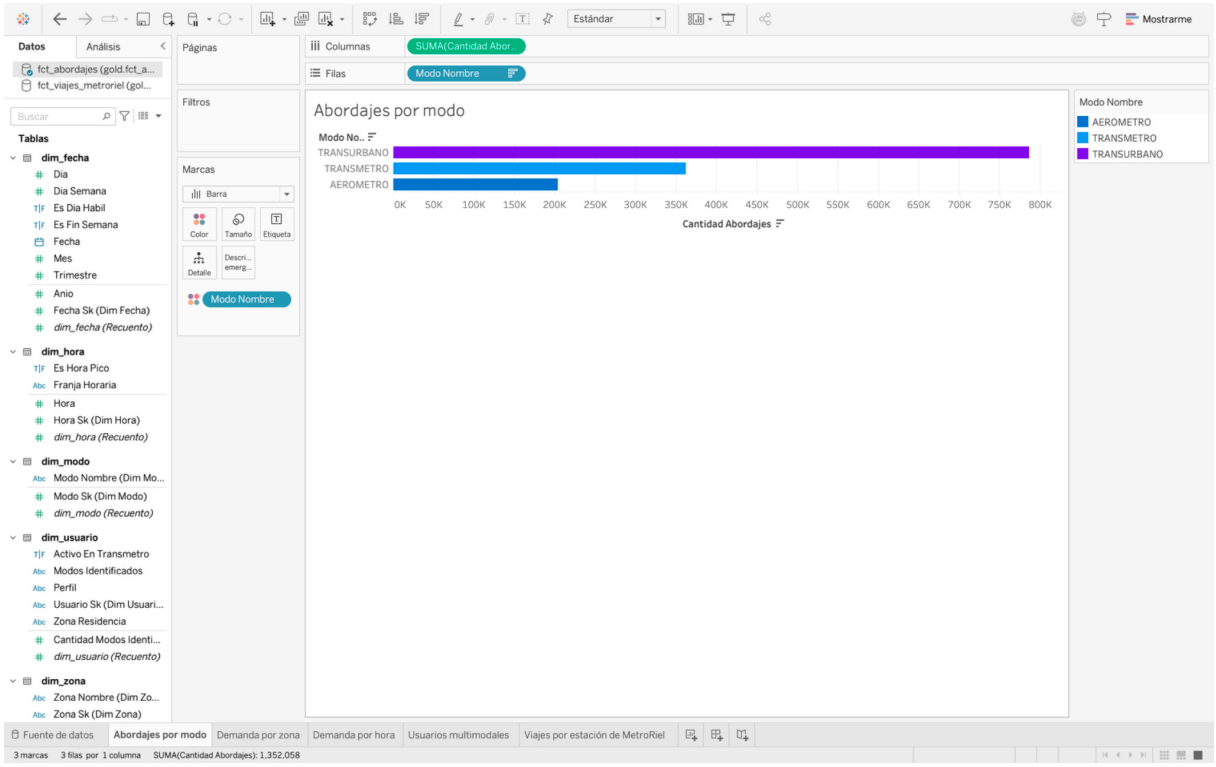

Anexo 17. Visualización de abordajes por modo de transporte.

Análisis de la demanda de abordajes por zona

La gráfica presenta la demanda de abordajes distribuida por zona y modo de transporte. Permite identificar las zonas con mayor concentración de usuarios y comparar la participación de Transurbano, Transmetro y Aerómetro en cada territorio.

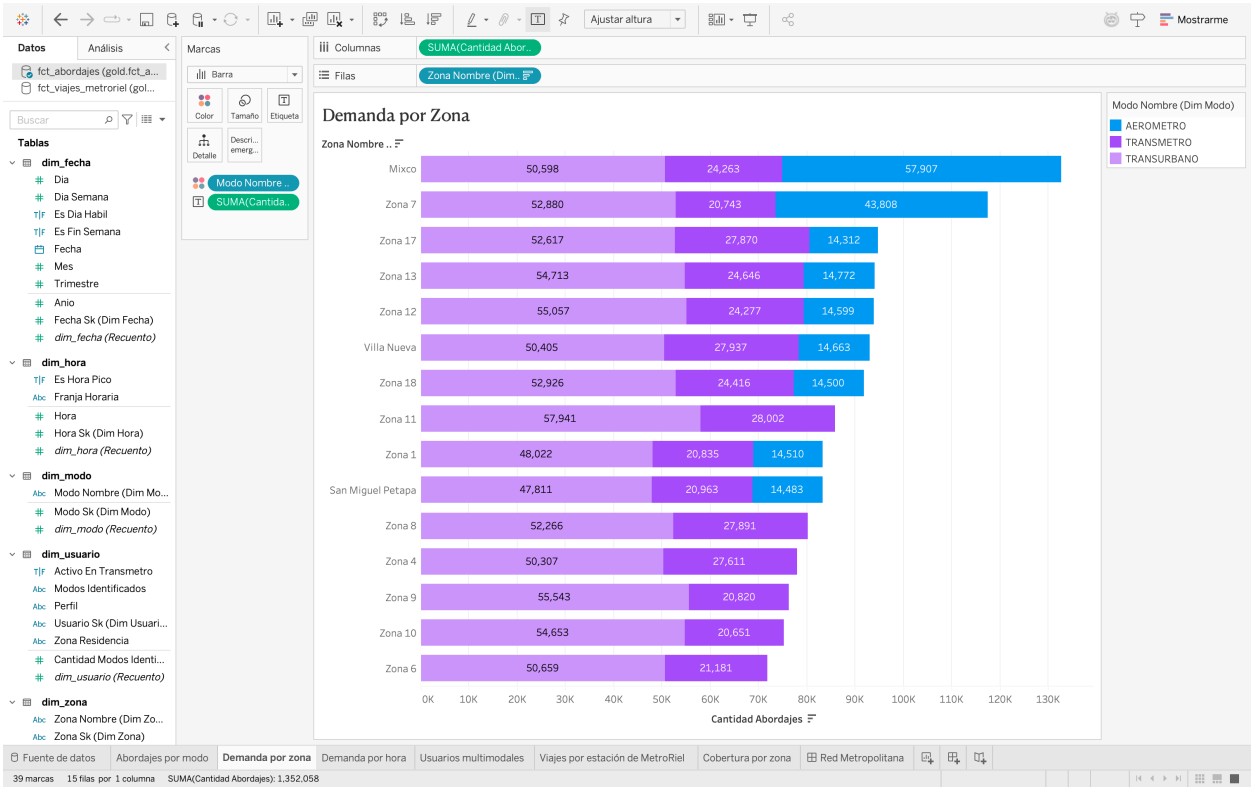

Anexo 18. Demanda por zona y distribución por modo.

Análisis de la demanda de abordajes por hora

La gráfica de demanda por hora permite identificar los momentos de mayor utilización de la red. Destacan dos picos principales: aproximadamente a las 7:00 con 162,014 abordajes y a las 17:00 con 137,152.

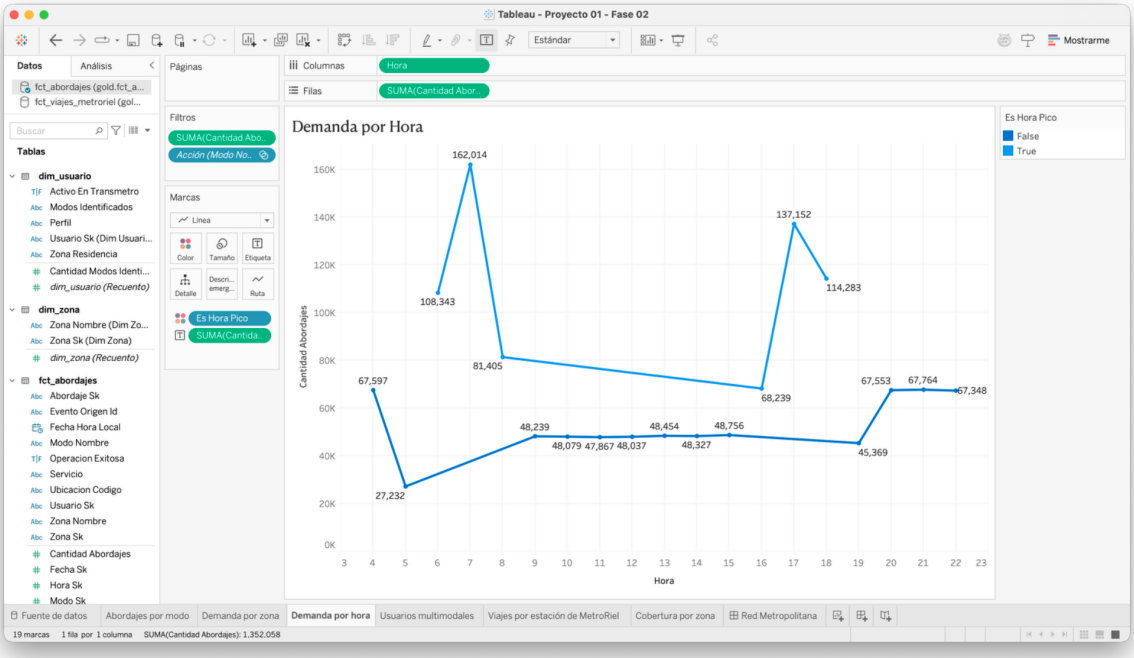

Anexo 19. Demanda por hora y picos de movilidad.

Análisis de usuarios multimodales de la Red Metropolitana

La visualización agrupa a los usuarios según la cantidad de modos de transporte identificados en su movilidad. Se observa que la cantidad de usuarios disminuye conforme aumenta el número de modos utilizados, permitiendo reconocer el comportamiento multimodal dentro de la red.

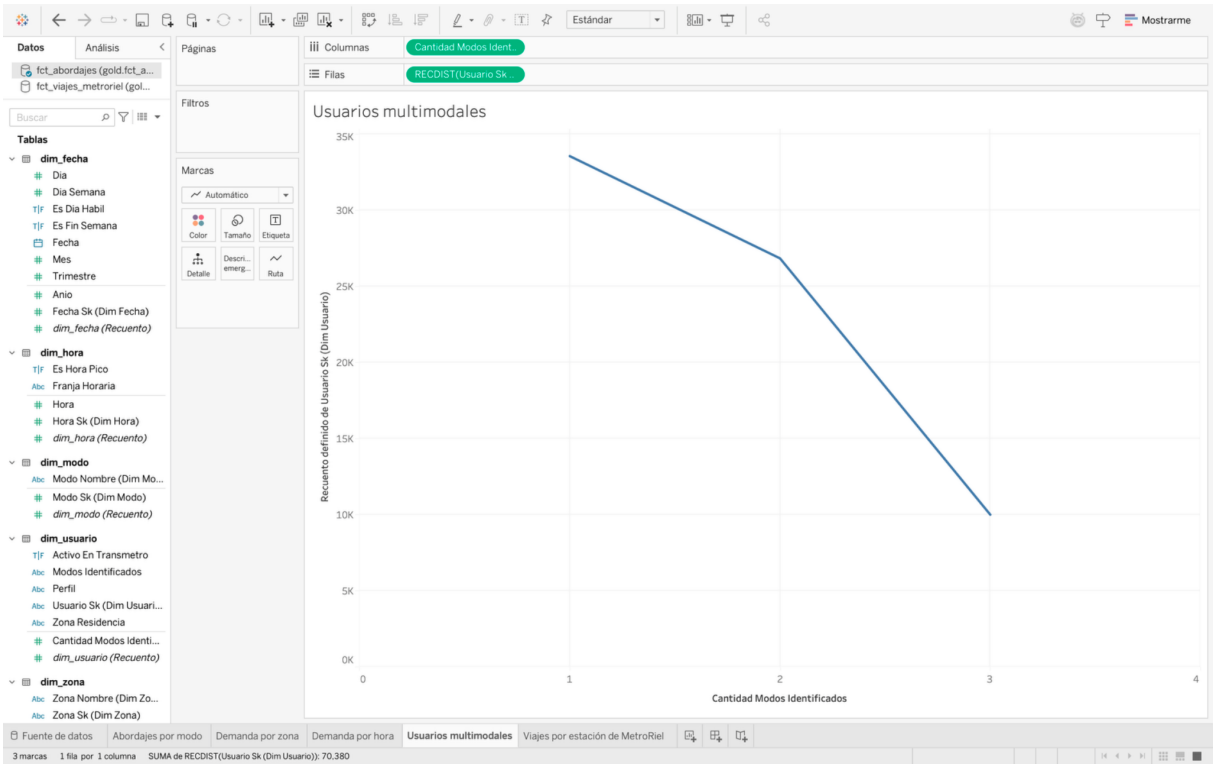

Anexo 20. Distribución de usuarios según cantidad de modos identificados.

Distribución de viajes por estación de MetroRiel

La gráfica muestra la distribución de los viajes válidos de MetroRiel según la estación de entrada. Los valores presentan un comportamiento relativamente uniforme entre las estaciones, lo que facilita comparar la demanda y detectar posibles diferencias operativas.

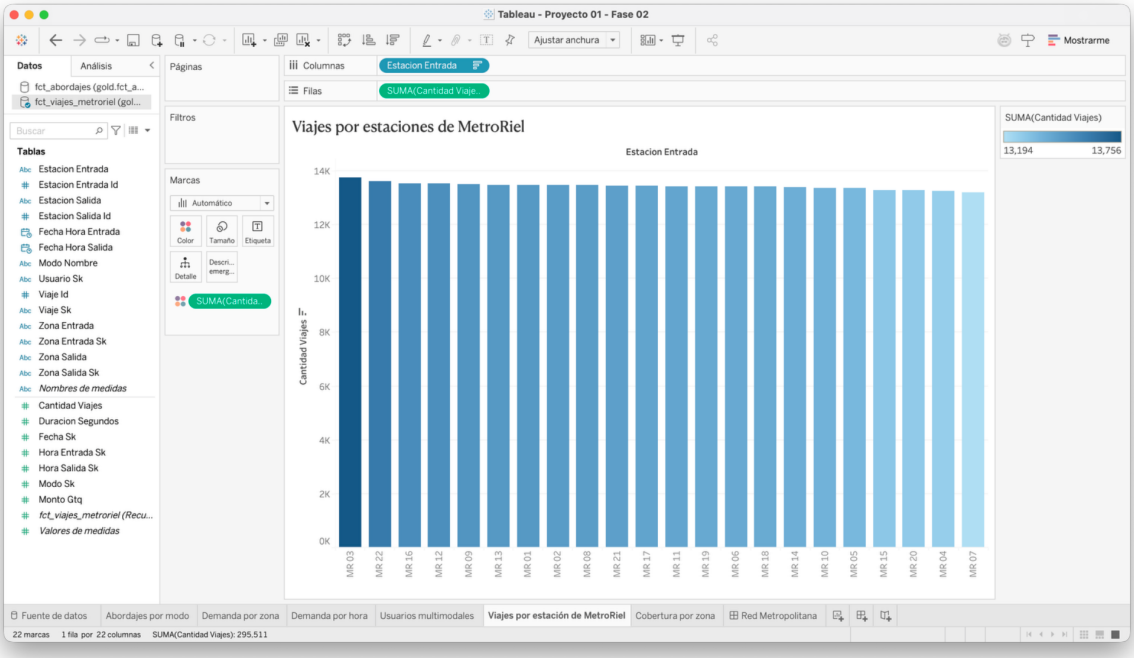

Anexo 21. Viajes por estación de entrada de MetroRiel.

Análisis de cobertura de transporte por zona

La matriz de cobertura relaciona las zonas con los distintos modos de transporte. La intensidad de los valores permite reconocer rápidamente qué zonas cuentan con mayor presencia y demanda de Aerómetro, Transmetro y Transurbano.

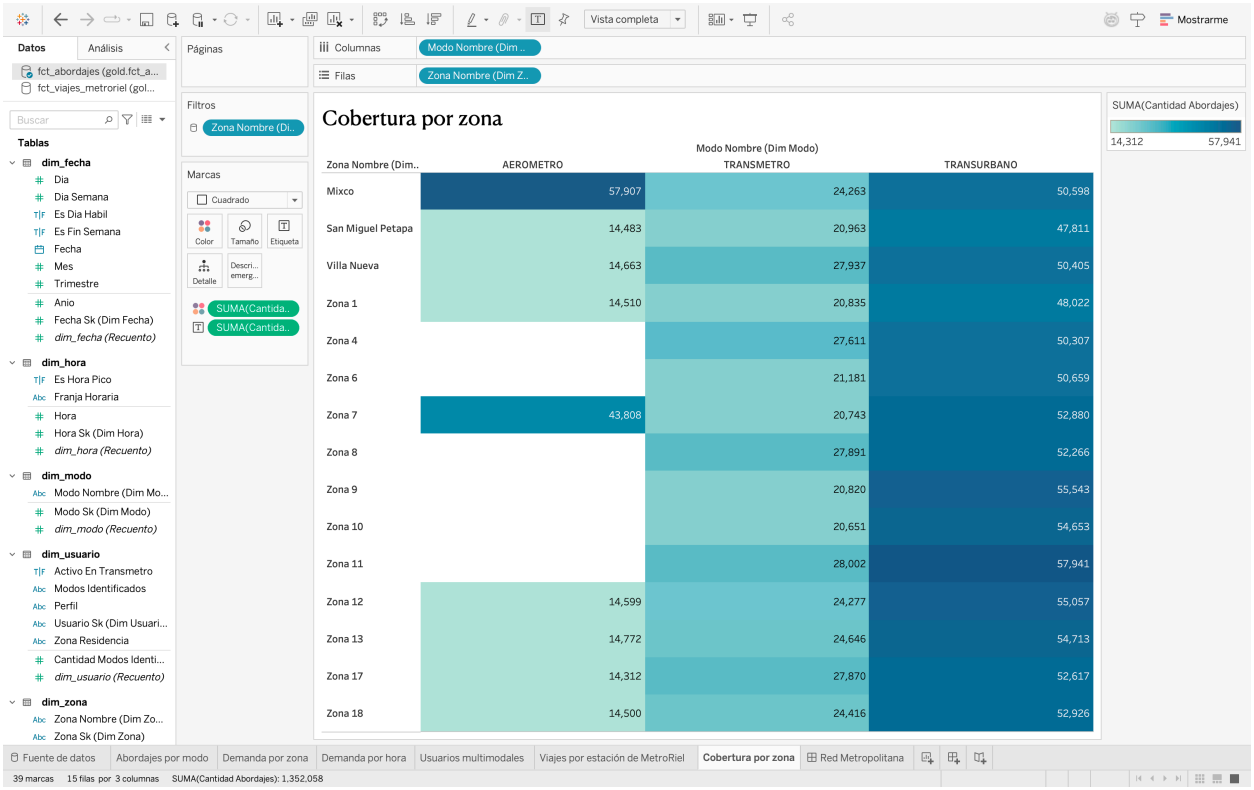

Anexo 22. Matriz de cobertura por zona y modo.

Dashboard interactivo de la Red Metropolitana

El dashboard Red Metropolitana integra en una sola vista los principales indicadores de la Fase 02: abordajes por modo, demanda por zona y hora, usuarios multimodales, viajes de MetroRiel y cobertura territorial. Los filtros permiten explorar los resultados de manera interactiva.

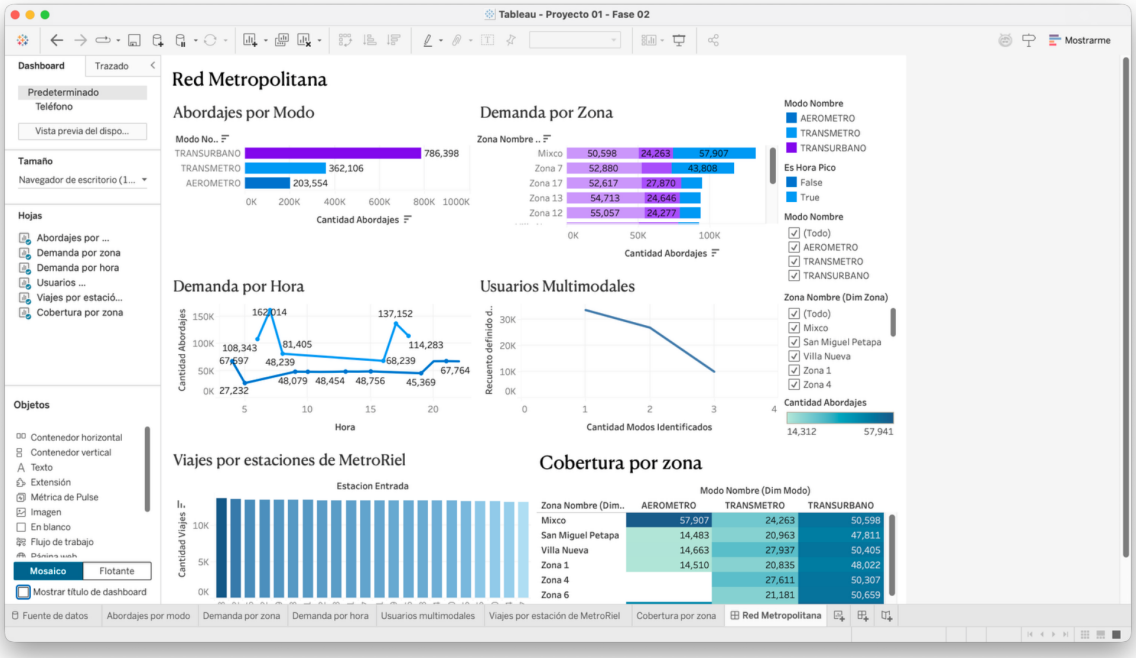

Anexo 23. Dashboard consolidado de la Red Metropolitana.

Pruebas en Pycharm

Validación de registros de features de movilidad de usuarios

La consulta ejecutada en PostgreSQL valida la creación de la tabla features.features_usuario_movilidad y confirma un total de 66,140 registros. Esta evidencia demuestra que las variables analíticas por usuario fueron generadas y almacenadas correctamente.

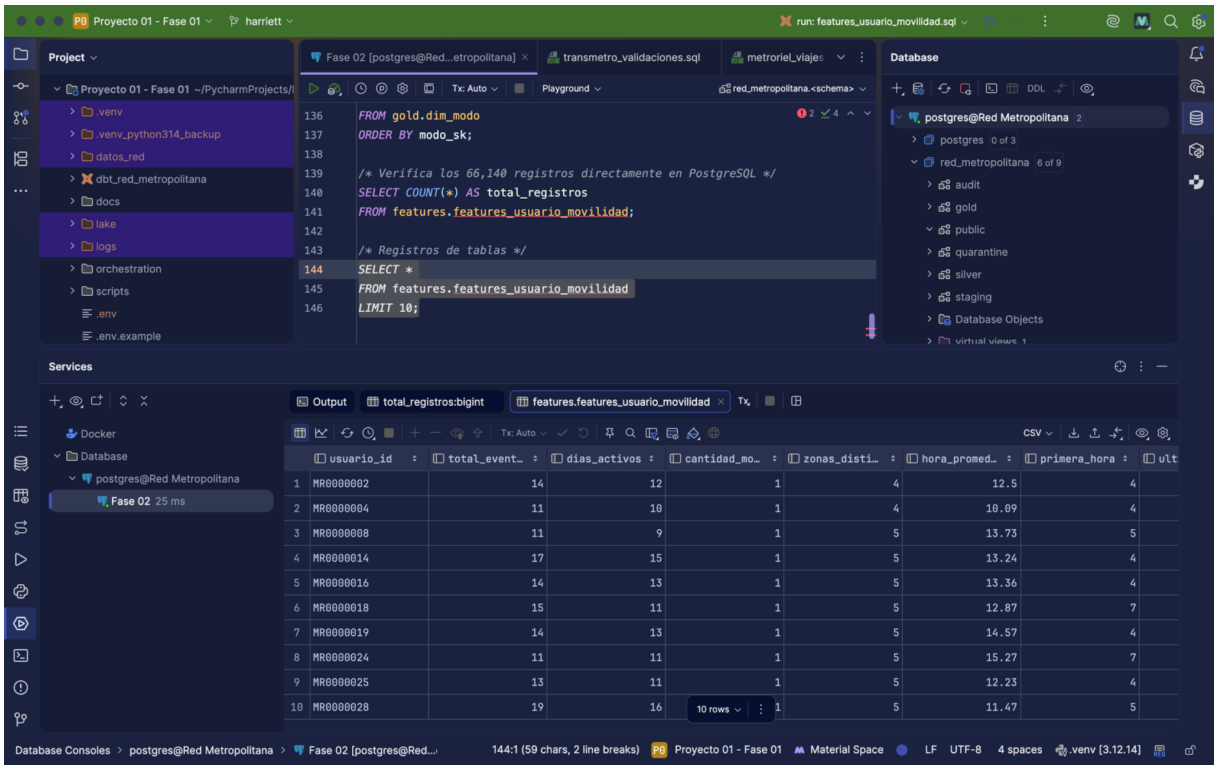

Anexo 24. Conteo de 66,140 registros en features_usuario_movilidad.

Muestra de características de movilidad generadas por usuario

La consulta presenta una muestra de los registros generados en features_usuario_movilidad. Se observan variables como identificador de usuario, total de eventos, días activos, cantidad de modos, zonas distintas y métricas horarias, utilizadas para caracterizar los patrones de movilidad.

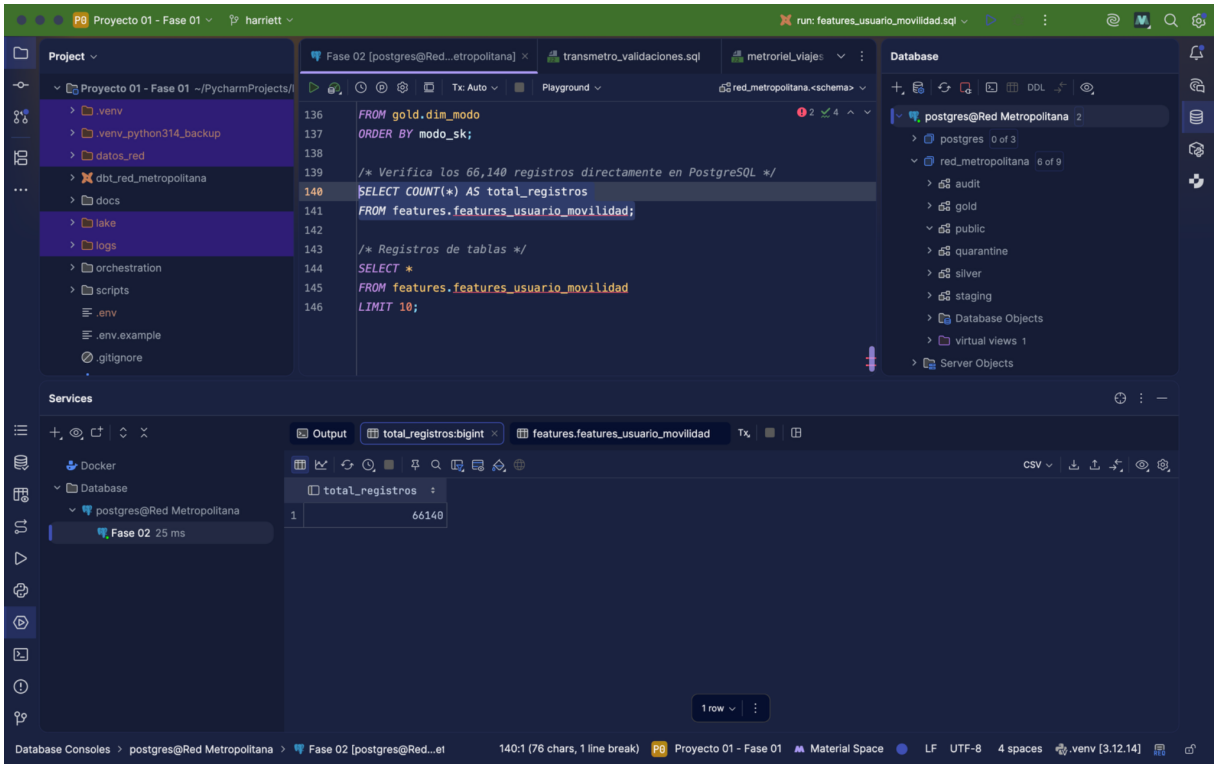

Anexo 25. Muestra de registros y variables de features_usuario_movilidad.

Ejecución exitosa de los modelos de transformación con dbt

La captura evidencia la ejecución completa de los modelos mediante dbt, donde se procesaron correctamente 29 modelos de datos correspondientes a las diferentes capas del proyecto. El proceso finalizó con el mensaje “Completed successfully”, registrando PASS=29, WARN=0 y ERROR=0, lo que confirma que las transformaciones y modelos de la Red Metropolitana fueron generados exitosamente y sin errores.

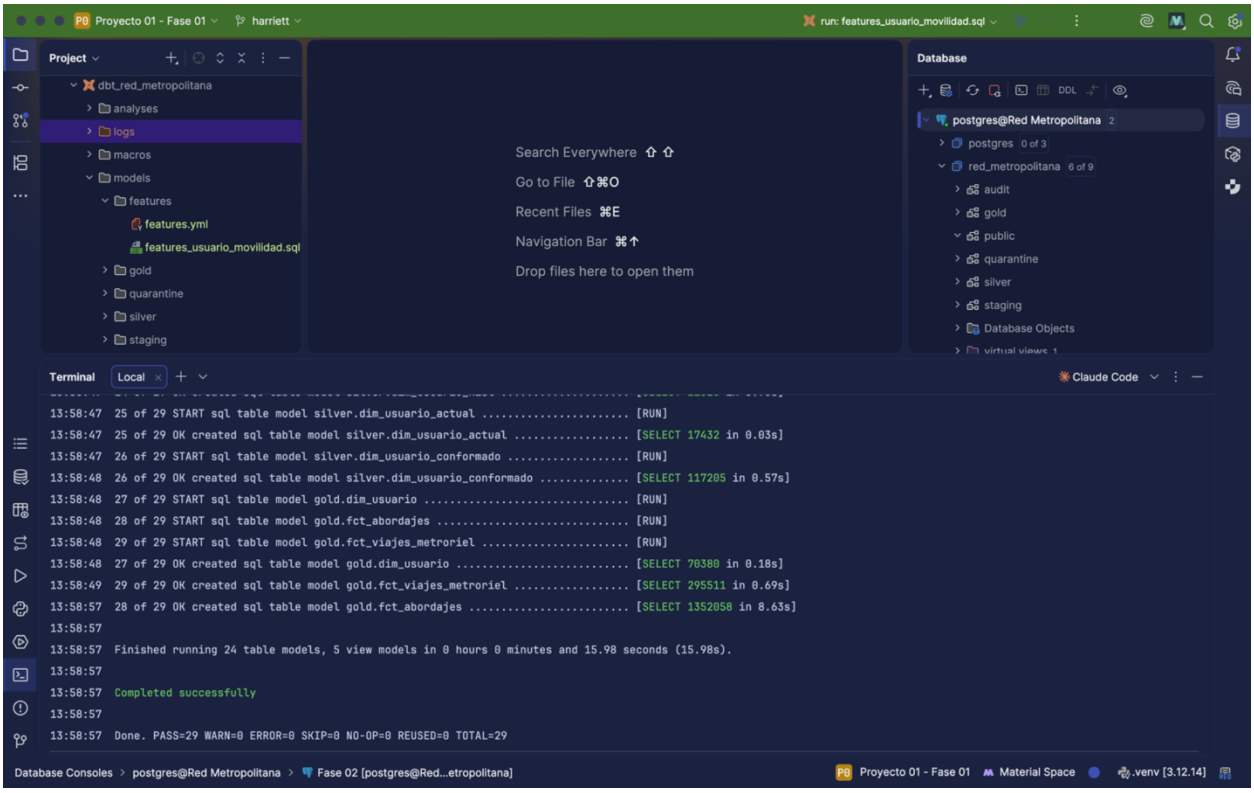

Anexo 26. ejecución exitosa de 29 modelos, sin errores.

Validación de calidad de datos mediante pruebas dbt

La ejecución de las pruebas automatizadas de dbt permitió verificar la integridad, consistencia y calidad de los modelos de datos de la Red Metropolitana. Se ejecutaron 115 pruebas, todas con estado PASS, sin advertencias, errores ni pruebas omitidas. Los resultados confirman el cumplimiento de las reglas de validación configuradas para los modelos del proyecto.

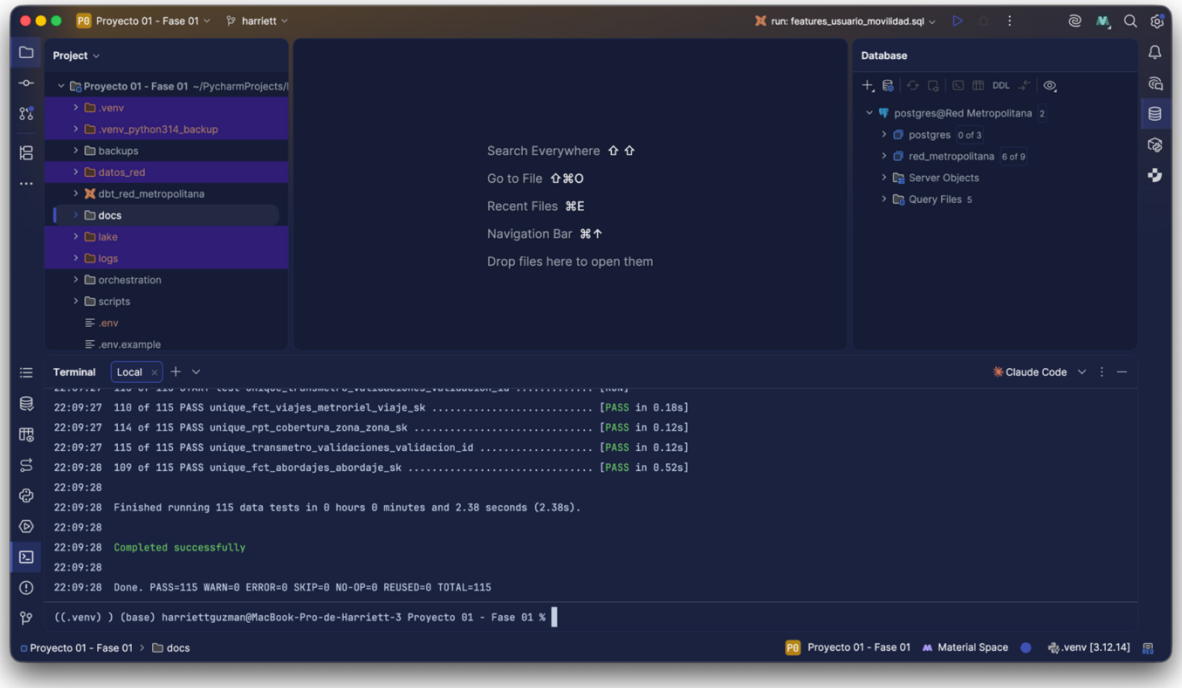

Anexo 27. Resultado de las 115 pruebas automatizadas de dbt.

Cantidad de usuarios y modos

Se valida el modelo features.features_usuario_movilidad, obteniendo 33,551 usuarios asociados a un modo de transporte, 26,833 asociados a dos modos y 9,996 asociados a tres modos. Los resultados confirman que la característica cantidad_modos fue generada correctamente a partir de la dimensión consolidada de usuarios.

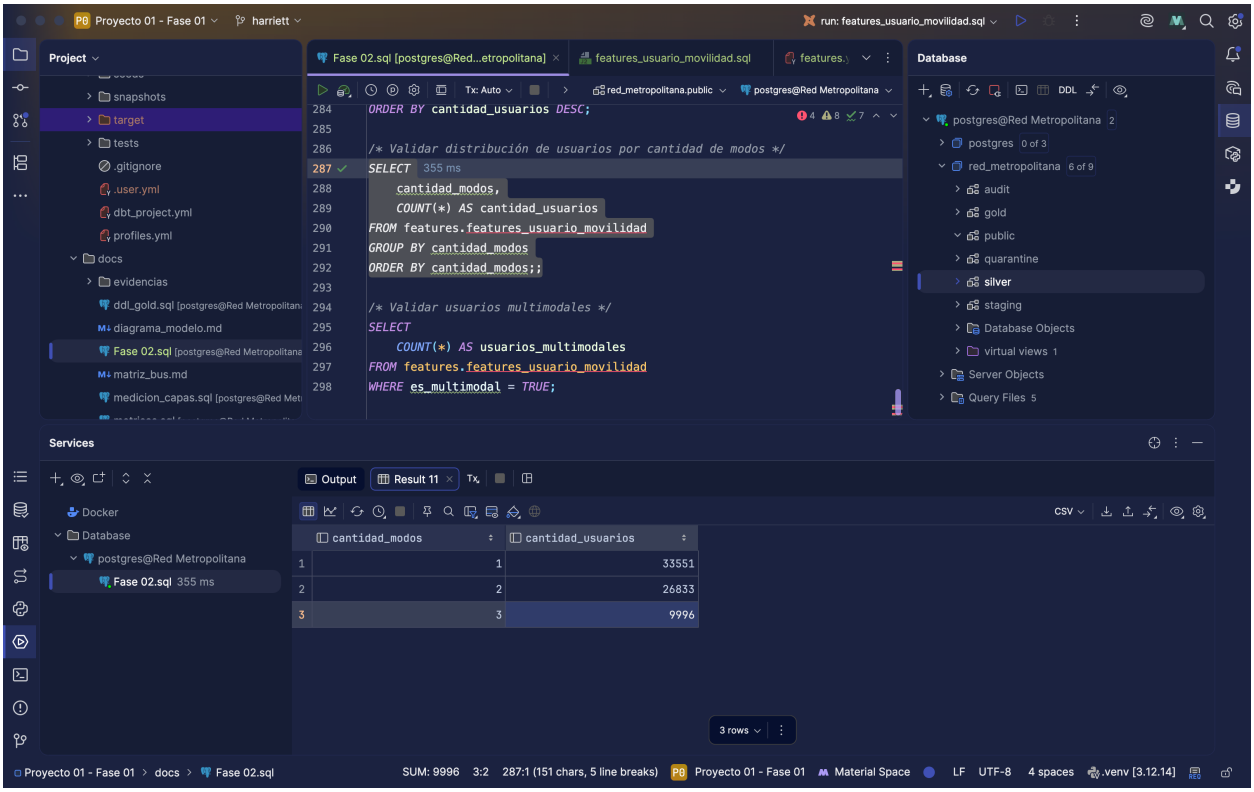

Anexo 28. Validación de distribución de usuarios por cantidad de modos.

Validación de registros de features de movilidad de usuarios

La consulta ejecutada en PostgreSQL valida la creación de la tabla features.features_usuario_movilidad y confirma un total de 66,140 registros. Esta evidencia demuestra que las variables analíticas por usuario fueron generadas y almacenadas correctamente.

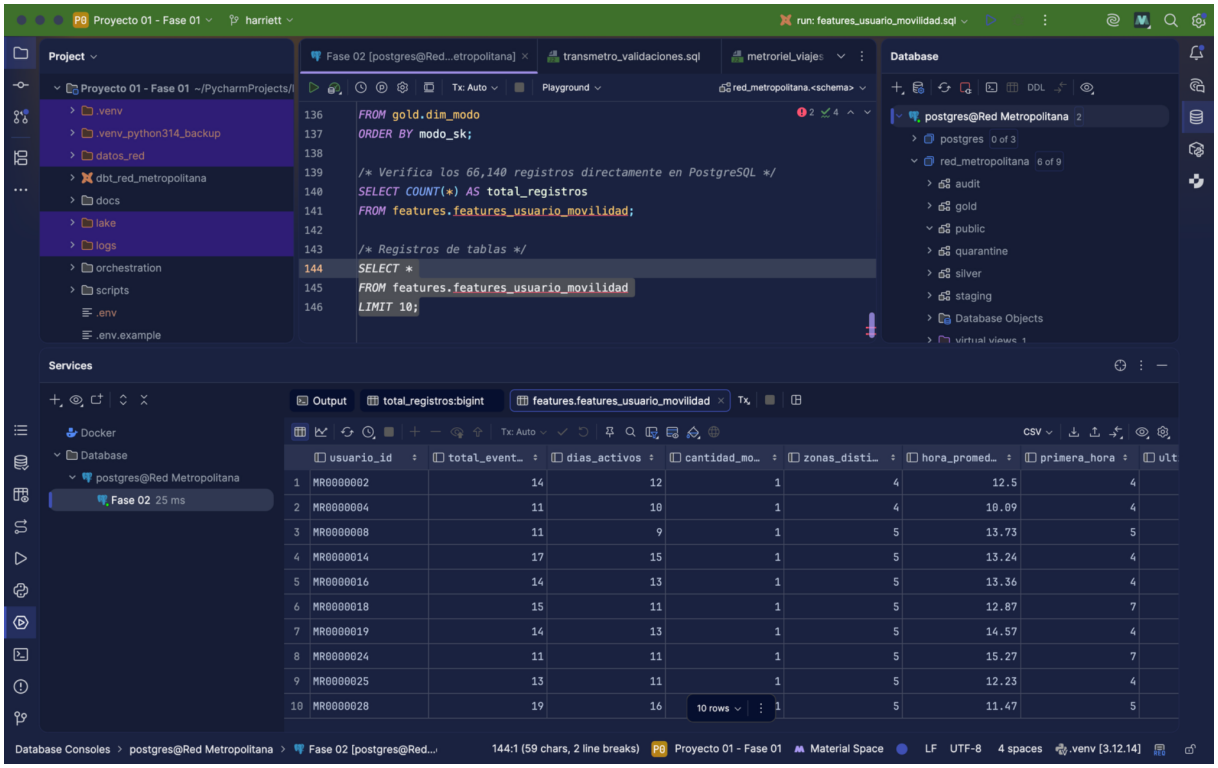

Anexo 29. Conteo de 66,140 registros en features_usuario_movilidad.

Muestra de características de movilidad generadas por usuario

La consulta presenta una muestra de los registros generados en features_usuario_movilidad. Se observan variables como identificador de usuario, total de eventos, días activos, cantidad de modos, zonas distintas y métricas horarias, utilizadas para caracterizar los patrones de movilidad.

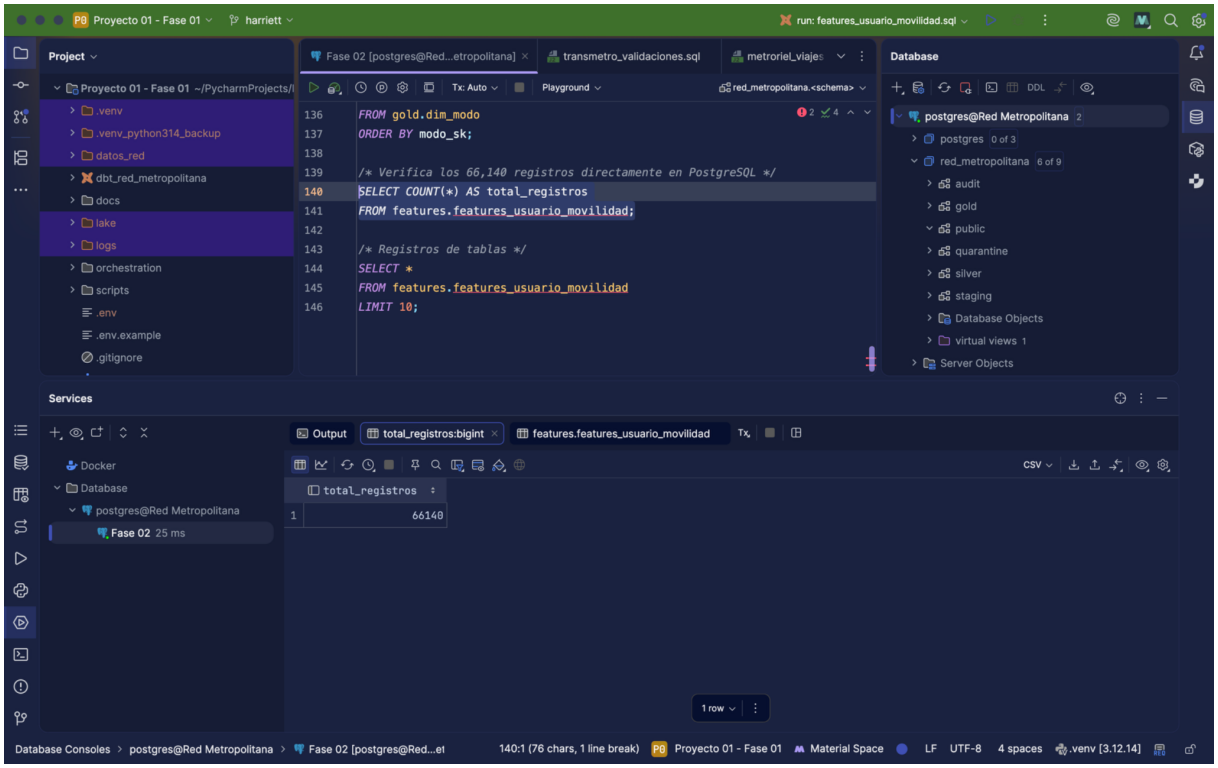

Anexo 30. Muestra de registros y variables de features_usuario_movilidad.

Usuario Multimodales

Se valida la característica es_multimodal, identificando un total de 36,829 usuarios que utilizan dos o más modos de transporte. El resultado coincide con la suma de los usuarios asociados a dos y tres modos, confirmando la consistencia del modelo de features.

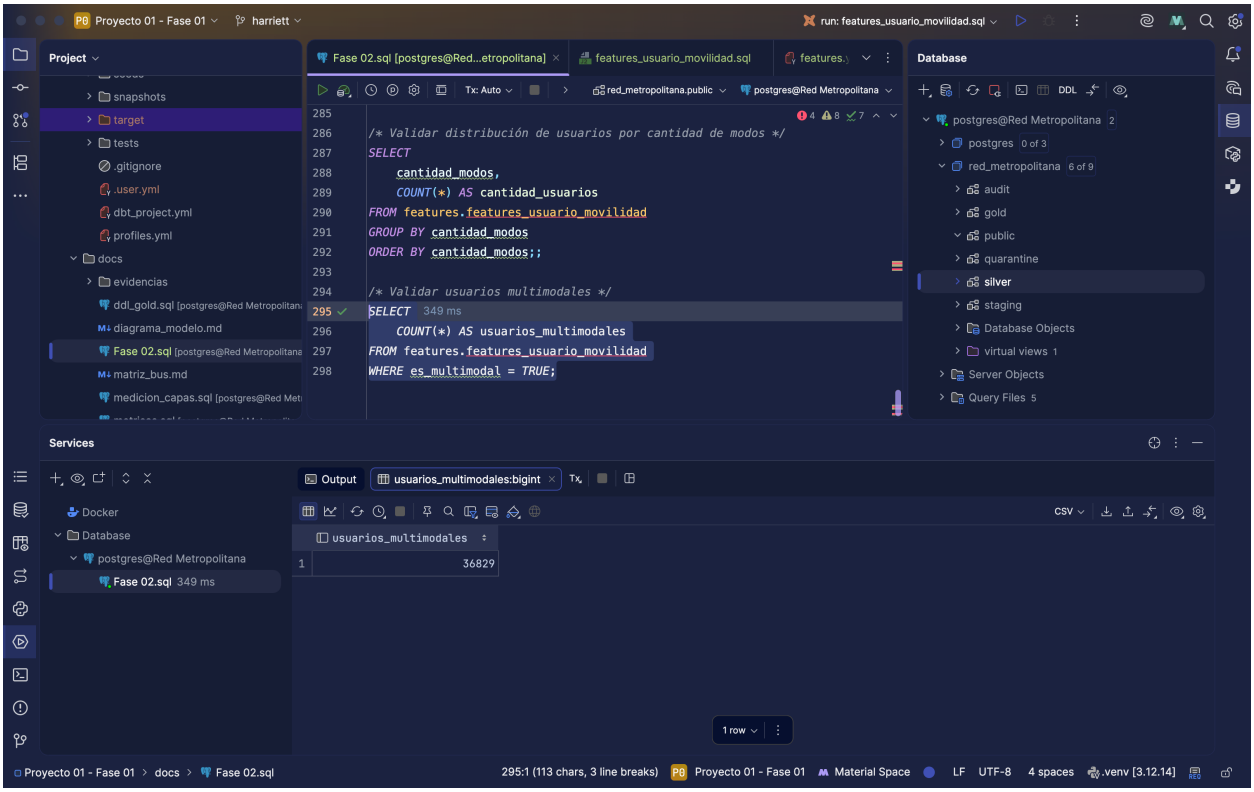

Anexo 31. Validación de distribución de usuarios por cantidad de modos.

Demanda en zonas 12, 8, 1, 6 y 17

Las zonas objetivo presentan una demanda considerable; sin embargo, MetroRiel no registra abordajes en ellas dentro de la información integrada. Por ello, los datos sugieren una brecha entre la demanda observada y la cobertura actual de este modo.

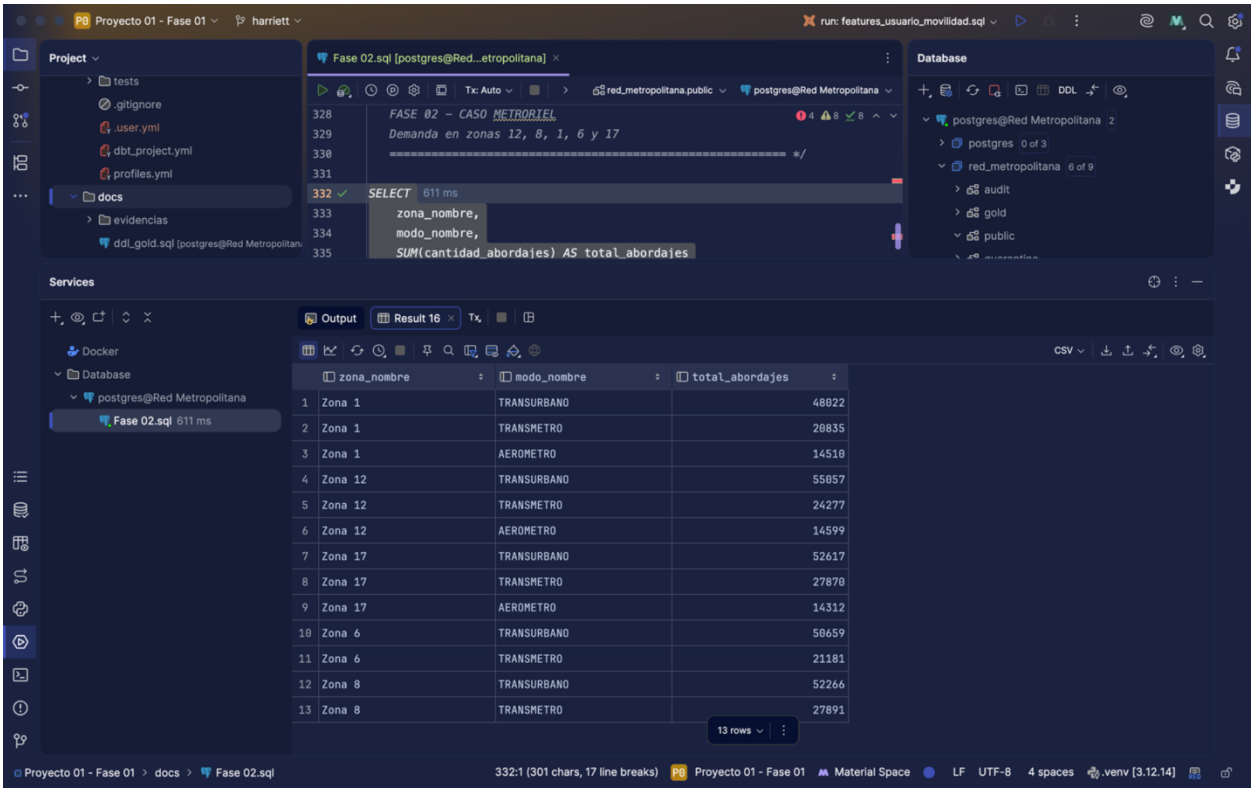

Anexo 32. Caso Metroriel demandas de zonas.

Demanda total en zonas objetivo del caso MetroRiel

La consulta consolida la cantidad de abordajes registrados en las cinco zonas objetivo del análisis de MetroRiel. La Zona 17 presenta la mayor demanda con 94,799 abordajes, seguida de la Zona 12 con 93,933. Los resultados evidencian una concentración importante de demanda de movilidad en las zonas analizadas y proporcionan una base cuantitativa para evaluar la propuesta de MetroRiel.

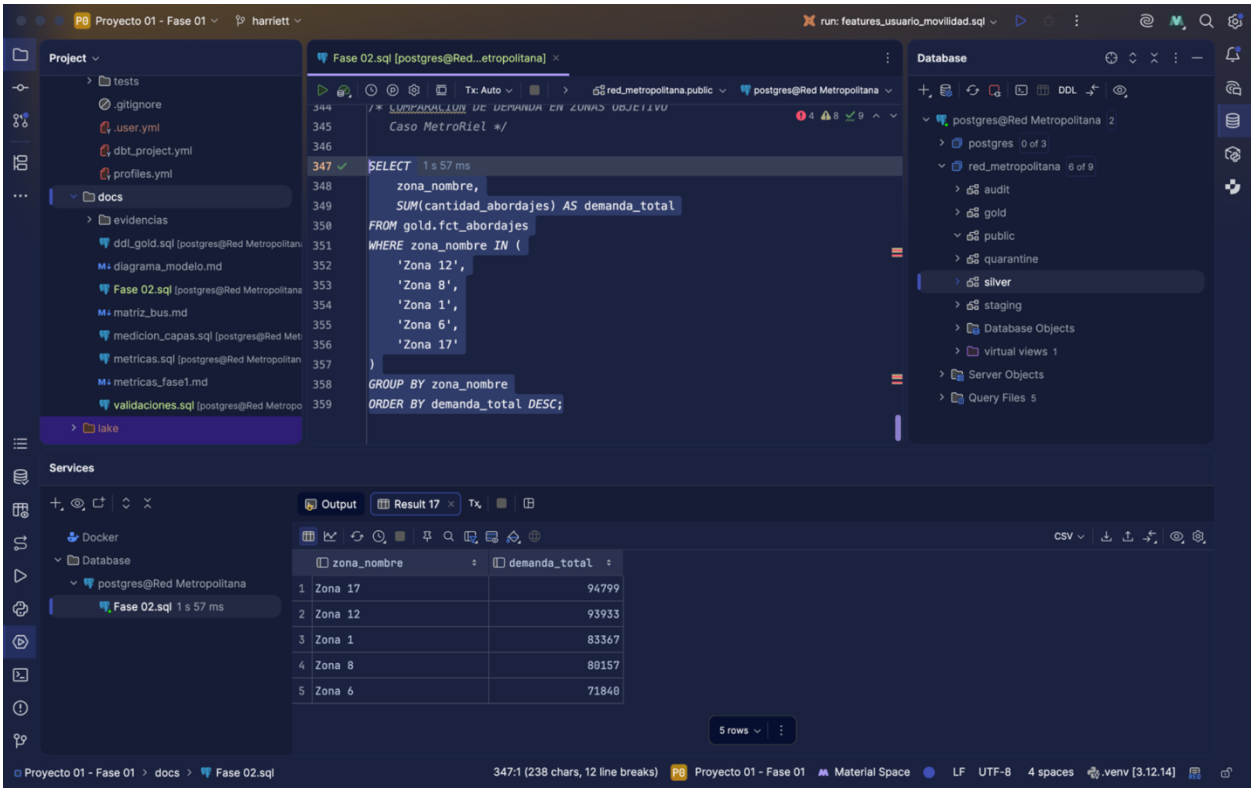

Anexo 33. Comparación de demanda en zonas

Tablas silver para Feature

Se verificaron las tablas disponibles en la capa Silver que sirven como fuente para la construcción de las features de movilidad. La consulta permite identificar las columnas y tipos de datos de las tablas correspondientes a AeroMetro, MetroRiel, Transmetro y Transurbano, además de la dimensión de usuarios conformada. Esta validación confirma que los datos necesarios se encuentran estructurados y disponibles para generar características relacionadas con el comportamiento y la movilidad de los usuarios.

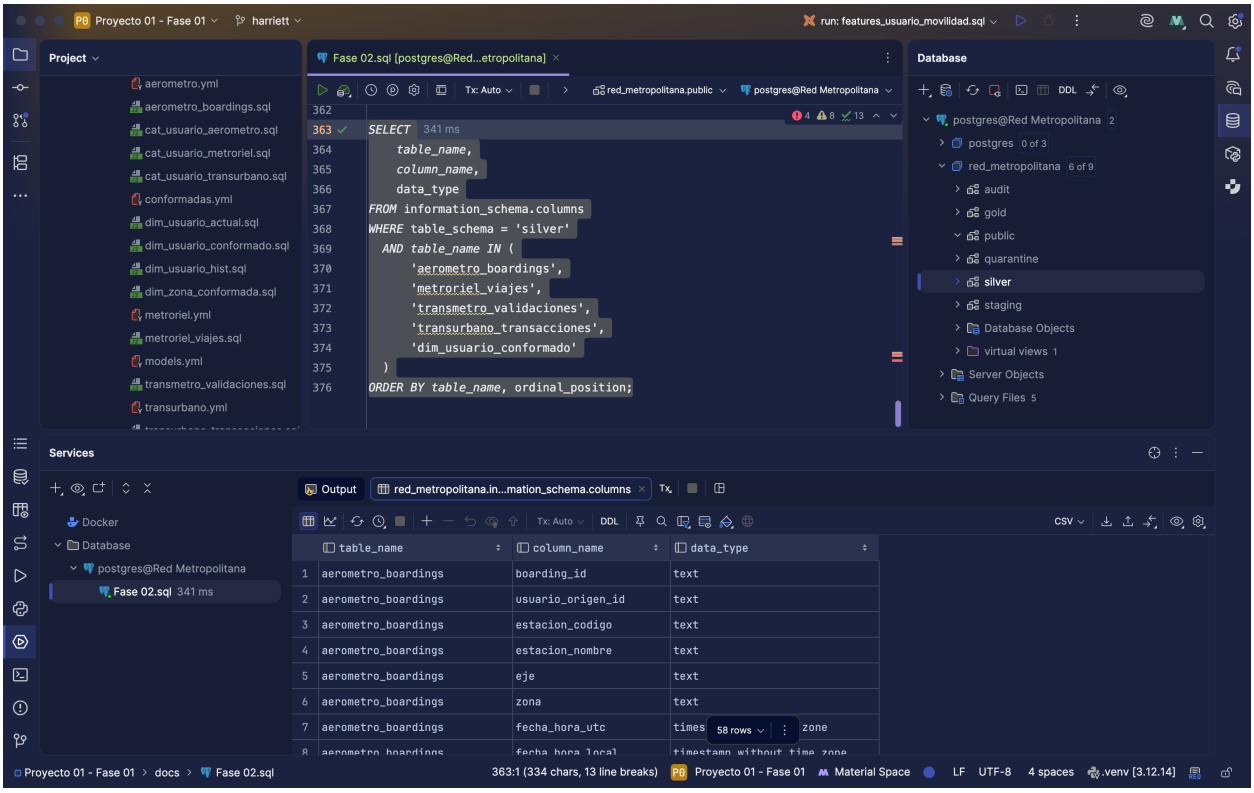

Anexo 34. Silver para Feature

Distribución de usuarios según modos de transporte

La consulta agrupa los usuarios de la dimensión Gold según la cantidad de modos identificados: 33,551 usuarios registran un modo, 26,833 registran dos y 9,996 registran tres. En total se contabilizan 70,380 usuarios; 36,829 corresponden a usuarios multimodales (dos o más modos).

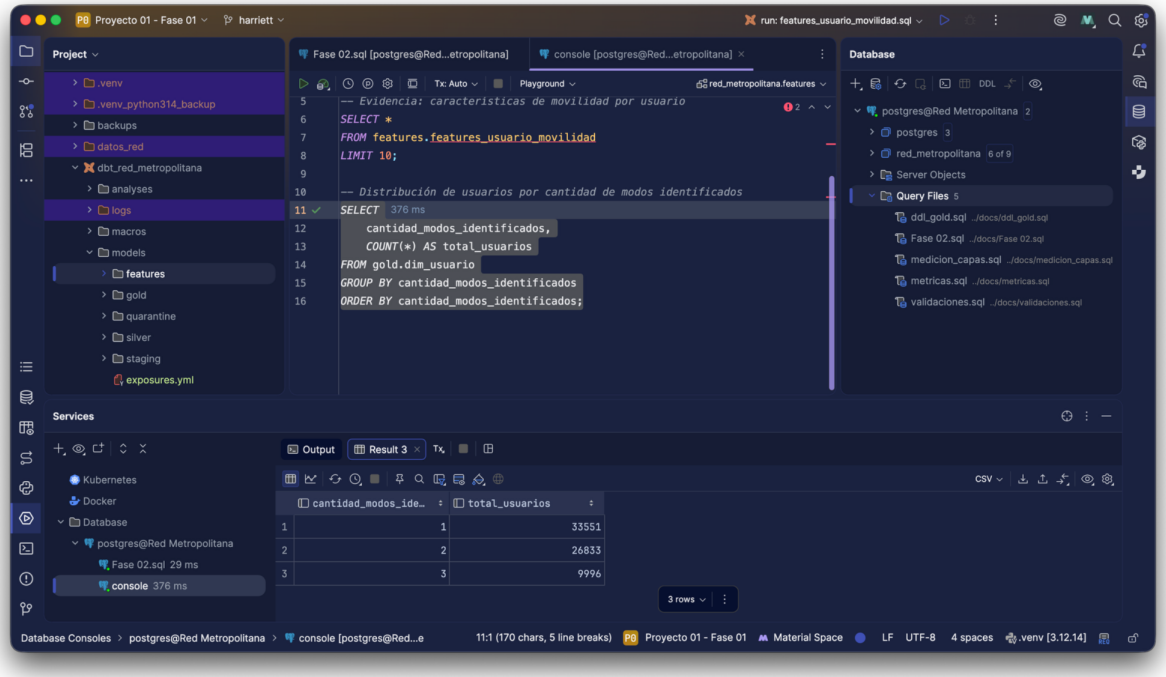

Anexo 33. Distribución de usuarios por cantidad de modos de transporte.

Demanda total por modo de transporte

La consulta sobre gold.rpt_demanda_red muestra la demanda agregada por operador: Transurbano registra 786,398 abordajes, Transmetro 362,106, MetroRiel 295,511 y AeroMetro 203,554. La comparación permite reconocer el peso relativo de cada modo dentro de los registros consolidados.

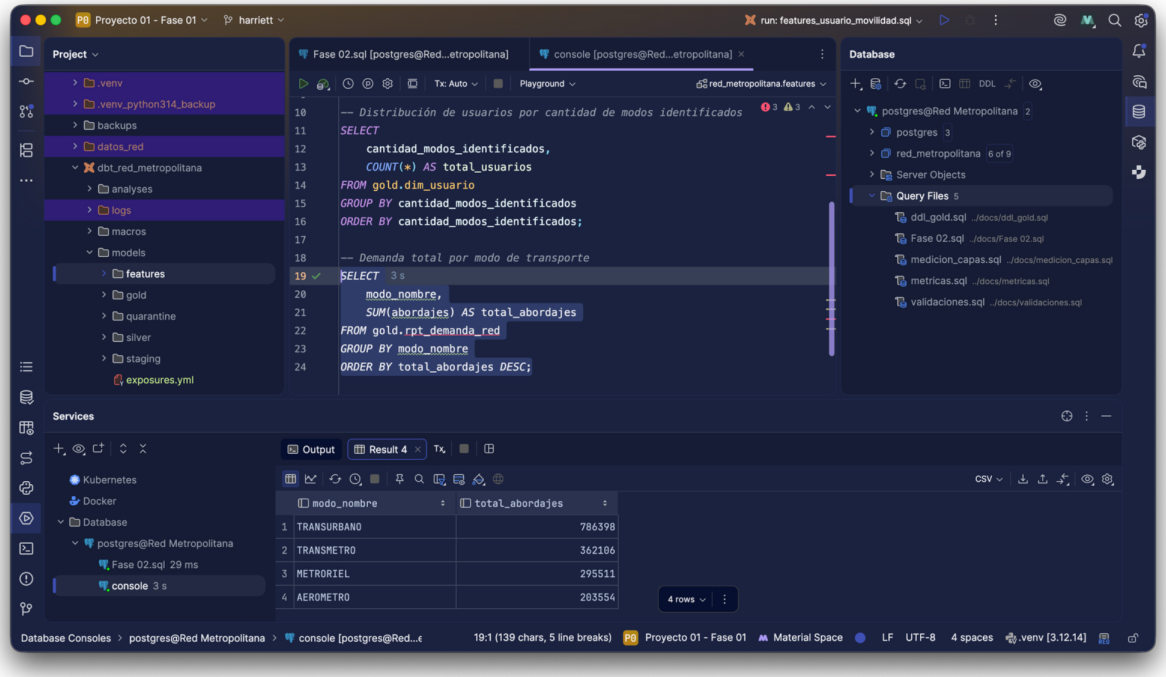

Anexo 34. Comparación de abordajes por modo de transporte.

Ranking territorial de demanda sin MetroRiel

La consulta ordena las 16 zonas de acuerdo con la demanda existente sin MetroRiel e identifica si cada zona forma parte del trazado. En las primeras posiciones figuran Mixco (132,768), Zona 7 (117,431) y Zona 17 (94,799). La columna en_trazado_metroriel permite contrastar la demanda territorial con la cobertura proyectada.

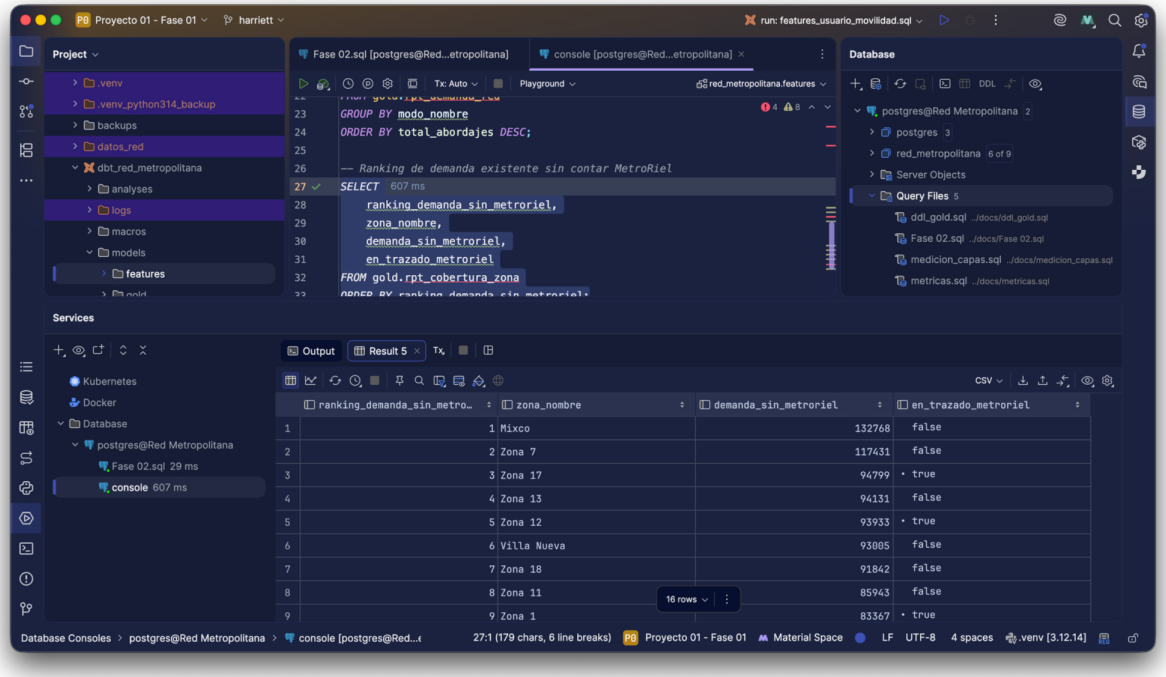

Anexo 35. Ranking de demanda por zona y presencia en el trazado de MetroRiel.

Conteos de referencia entre Silver y Gold

La consulta muestra 362,106 registros de validaciones de Transmetro en Silver y 1,352,058 registros en gold.fct_abordajes. Los conteos corresponden a conjuntos de diferente alcance: Silver incluye las validaciones de un operador y Gold integra abordajes de la red. Por ello, esta captura documenta los volúmenes, pero no representa una conciliación uno a uno.

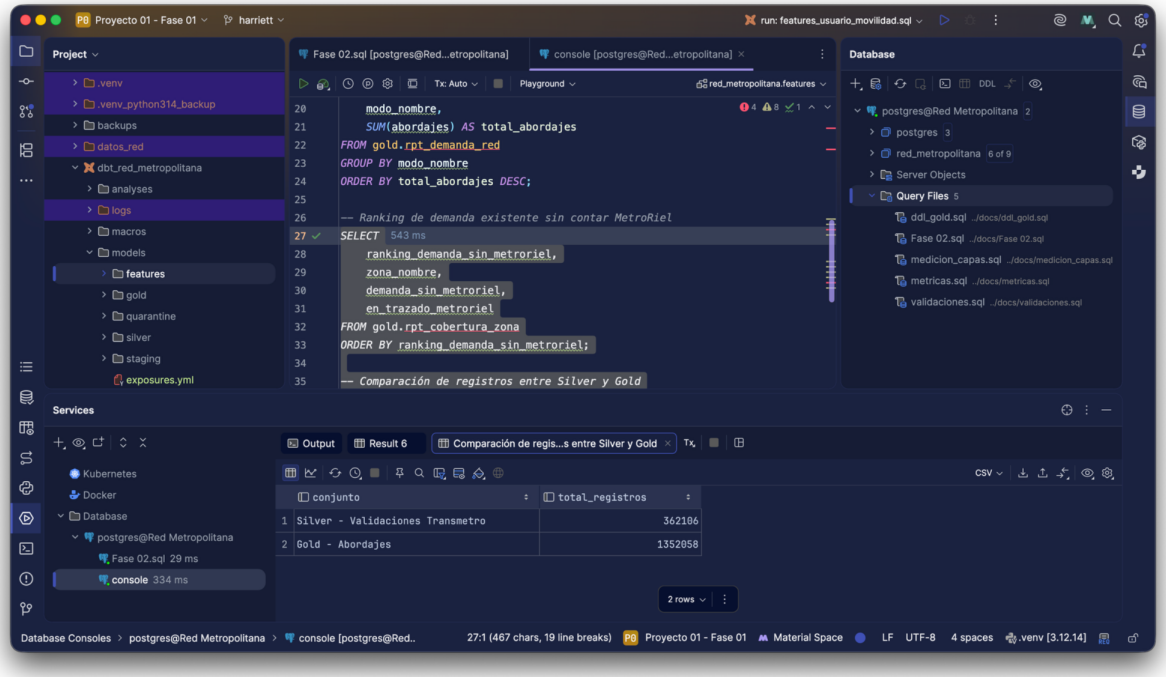

Anexo 36. Conteos de registros de Silver Transmetro y Gold abordajes.

GitHub

https://github.com/harriett-gl/Proyecto01-Fase01.git