Universidad Rafael Landívar

Facultad Ingeniería

Ingeniería en Sistemas e Informática

Ciencia de Datos

Inge. Max Cerna

Proyecto 02

Agencia Metropolitana de Transporte

Rochelle Giulianne Esquivel Vargas – 1283220

Susana Paola García García – 1224323

Harriett Alexandra Guzmán López – 1112423

Guatemala, 02 de noviembre del 2026

Agencia Metropolitana de Transporte

Objetivo y alcance

Predecir la probabilidad de que una unidad deje de utilizar la red de transporte durante los 30 días posteriores a una fecha de corte, utilizando exclusivamente información anterior a dicho corte. Se documentan los apartados 1.1 a 1.4 exigidos para la Fase 1.

Requisitos del docente y estado

Sección	Requisito	Estado verificable
1.1	Comando único, 9 conteos y tiempos por etapa	Pipeline reconstruido en entorno aislado; 3,405,575 registros reconciliados, 188.49 s. Adjuntar tabla de nueve fuentes y tiempos.
1.2	Definición de unidad, etiqueta, población y costo	Poblaciones A/B validadas. Falta medir y documentar el costo de la unidad y enlaces de Aerómetro.
1.3	Tres cortes, diccionario Silver y prueba de recorte	Tres cortes y 14 features comprobados; auditoría A reportada con 0 diferencias. Revisar dependencia Gold frente a exigencia Silver.
1.4	Dos baselines, L1/L2, cinco folds, λ y coeficientes	Resultados CV existentes; falta confirmar medias/desviaciones de los dos baselines y explicar cinco coeficientes con sus valores.

Sección 1.1: carga de datos nuevos desde cero

Se ejecutó python scripts/run_pipeline_p2.py --mode rebuild-dbt en un entorno de prueba independiente, sin sobrescribir la base original. Se reconciliaron 3,405,575 registros entre datos de entrada, Bronze y staging; la ejecución tomó 188.49 segundos. El proceso construyó 33 modelos dbt y superó 128 pruebas.

Importante: el informe de entrega debe incluir la tabla de nueve archivos con conteos esperados, cargados y diferencia, así como el desglose de segundos por etapa desde pipeline_timings.csv. El comando único debe figurar también en README.

Sección 1.2: unidad, etiqueta y población

Unidad utilizada en las tablas: usuario_sk, identificador de usuario conformado. Se debe explicar formalmente si representa persona o tarjeta y cuantificar el costo de esa decisión.

En particular, el enunciado solicita explicar cómo se trata Aerómetro y cuántas tarjetas no se pudieron enlazar cuando se elige persona.

Etiqueta: churn_label = 1 cuando la unidad elegible no registra ningún viaje válido durante los 30 días desde el corte; churn_label = 0 cuando registra al menos uno. Para C la etiqueta queda vacía porque no se dispone de todo el período futuro.

Corte	Fecha	Población	Abandonos	Activos	Tasa positiva
A	2026-07-01	59,796	7,396	52,400	$\frac{7,396}{59,796} = (12.37\ \%)$
B	2026-07-31	58,372	6,671	51,701	$\frac{6,671}{58,372} = 11.43\ \%$
C	2026-08-30	57,925	No disponible	No disponible	No calculable

Sección 1.3: features y auditoría de fuga

La tabla churn.churn_features contiene 18 columnas: tres de identificación (cut_name, cutoff_date, usuario_sk), catorce características predictivas y churn_label. Los tres cortes suman 176,093 filas. Los conteos por corte coinciden exactamente con churn_population_labels. No se encontraron claves duplicadas ni filas sin población asociada.

Las características se calculan con ventanas históricas de hasta 28 días. La auditoría de recorte del corte A reportó 59,796 filas comparadas y cero diferencias; adjuntar comando y salida original como prueba reproducible. El enunciado exige fuentes Silver: revisar y corregir las referencias a Gold antes de declarar conformidad.

Sección 1.4: baselines y regresión logística

Se entrenó únicamente con el corte A usando validación cruzada estratificada de cinco folds, con random_state=42. La métrica principal es PR-AUC (average precision), adecuada para detectar la clase positiva minoritaria, sin que la abundancia de negativos oculte el rendimiento.

Modelo	PR-AUC media (A)	ROC-AUC (A)	Observación
Logística L2, C=0.001	0.429148	0.835311	Mejor configuración observada

Logística L1, C=0.01	0.428200	0.833428	Castigo alternativo
Baseline frecuencia	0.262542	0.744014	Puntaje de una característica
Baseline constante	0.123687	0.500000	Tasa positiva uniforme

Para L2, desviación estándar de PR-AUC en validación: 0.014108. El parámetro de regularización cumple $\lambda = 1/C$; por tanto, $C=0.001$ equivale a $\lambda=1000$. La gráfica regularization_curve_A.png y los cinco coeficientes de mayor contribución deben insertarse con sus valores y explicación del signo. No corresponde utilizar el corte B para ajustar la Fase 1.

Nota de separación temporal: aunque existe una evaluación posterior de B como parte del avance global, no se presenta como selección de hiperparámetros ni como evidencia de validación de la Fase 1.

Anexos

GitHub

https://github.com/harriett-gl/Proyecto-02-CD.git

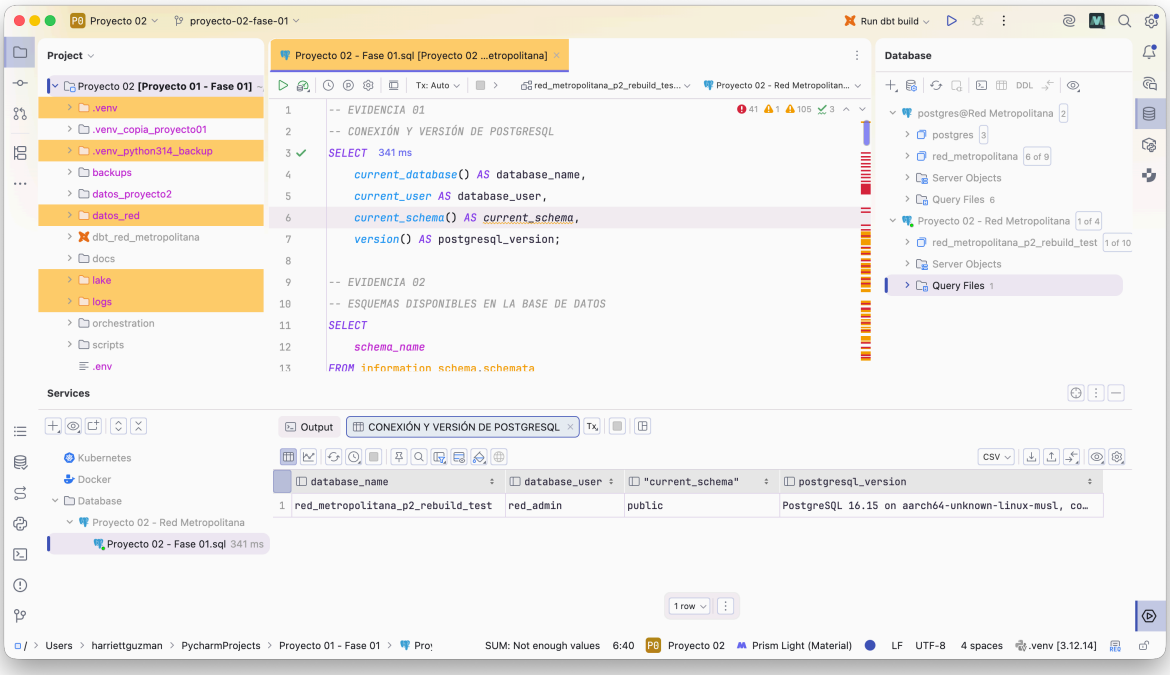
Canva

https://canva.link/oxbspyilz7va7g7

Las evidencias 01–10 se documentan con títulos y explicación. Las capturas de las primeras diez consultas se incorporan desde los archivos enviados previamente. Las evidencias 11–25 incluyen las capturas aportadas y verificadas.

Evidencia 01. Conexión a PostgreSQL

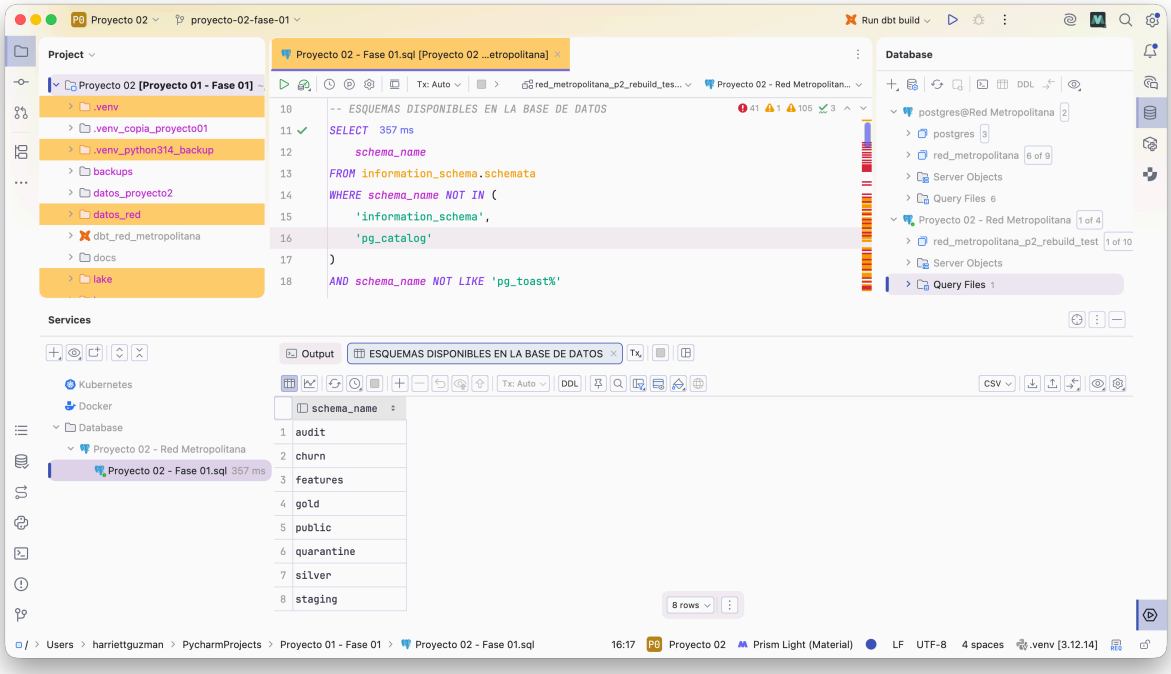
La consulta muestra la conexión activa con PostgreSQL y permite identificar la base de datos y la versión del motor utilizada. Esta verificación confirma que el entorno está disponible antes de ejecutar las consultas de control del proyecto.



Anexo 1. Captura original aportada anteriormente.

Evidencia 02. Esquemas disponibles

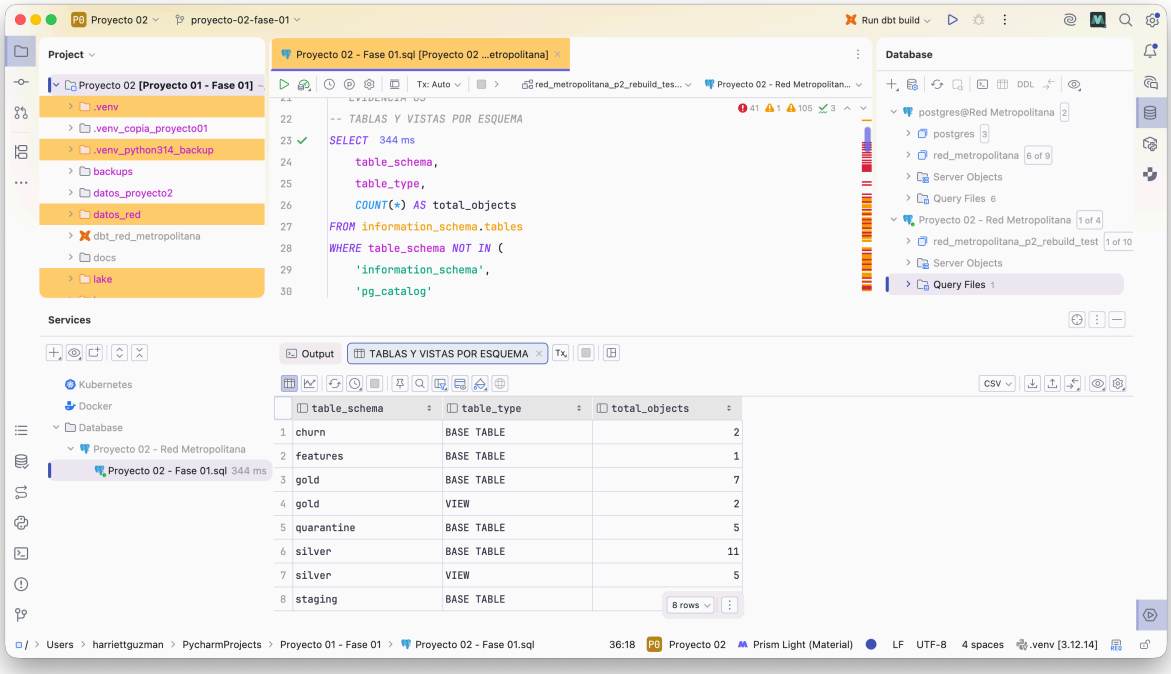
Se consulta el catálogo de PostgreSQL para identificar los esquemas existentes. El resultado permite comprobar la organización de los datos por etapas, entre ellas staging, silver, gold y churn.



Anexo 2. Captura original aportada anteriormente.

Evidencia 03. Cantidad de tablas y vistas por esquema

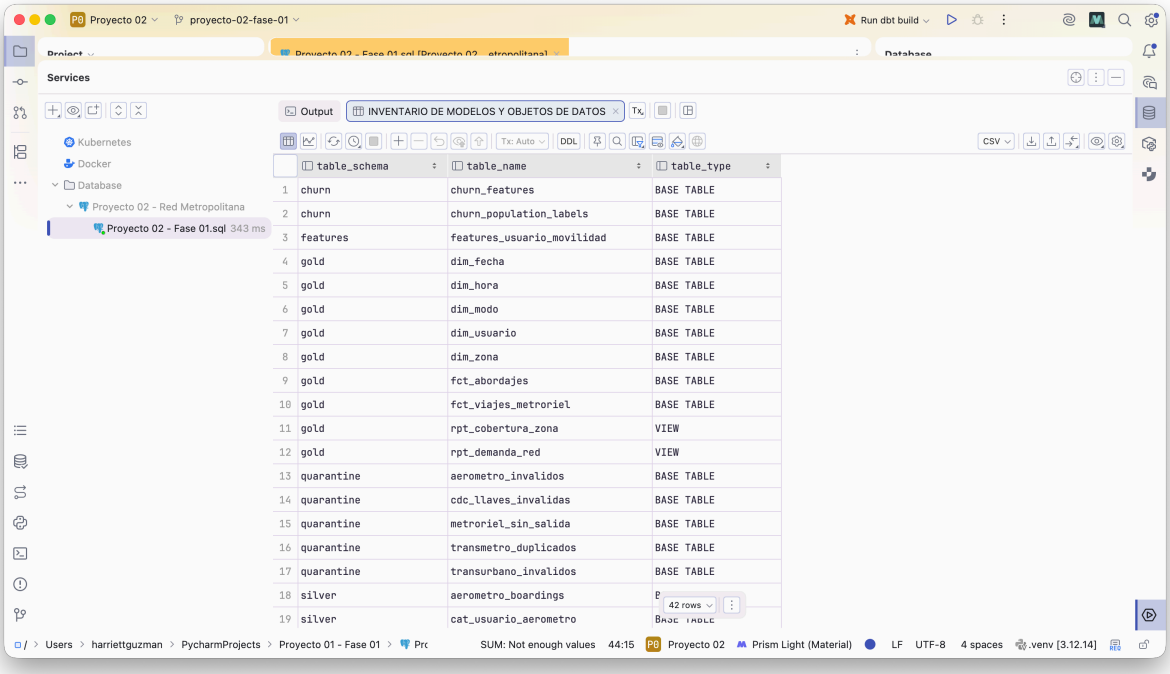
La consulta agrupa los objetos de la base de datos según su esquema y tipo. Sirve para revisar cuántas tablas y vistas están registradas en cada etapa del procesamiento y verificar su estructura general.



Anexo 3. Captura original aportada anteriormente.

Evidencia 04. Inventario de tablas y vistas

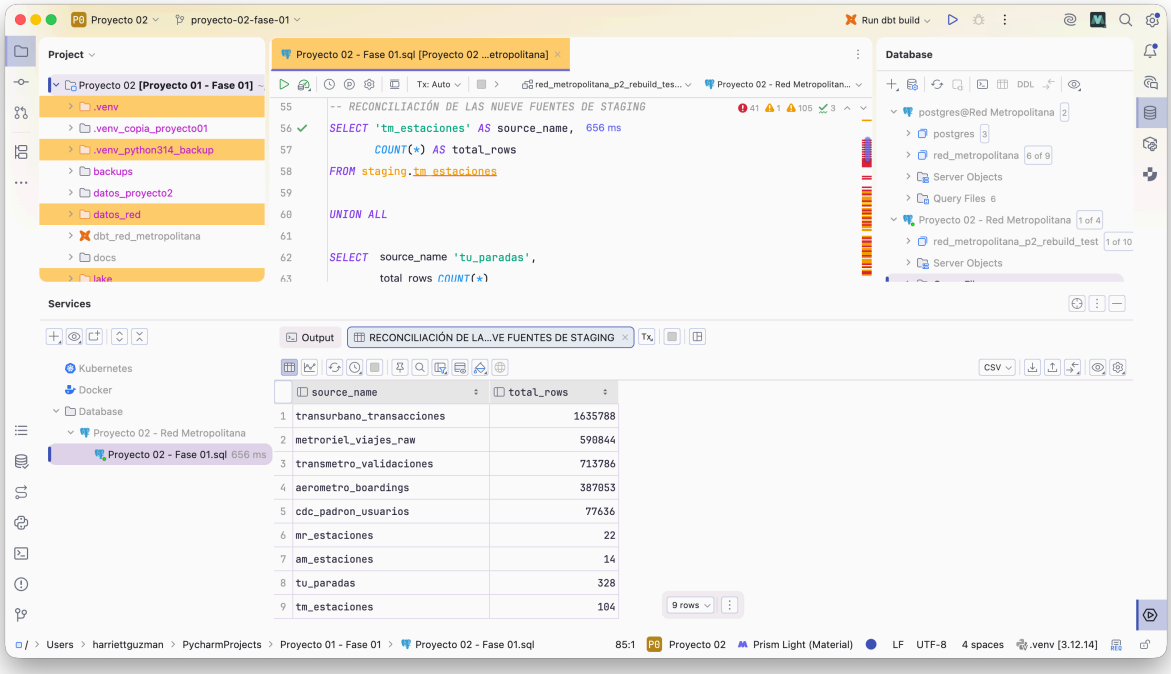
Se muestra el listado de objetos creados en los distintos esquemas, incluyendo sus nombres y tipos. Este inventario facilita comprobar qué tablas y vistas están disponibles para las siguientes validaciones.



Anexo 4. Captura original aportada anteriormente.

Evidencia 05. Reconciliación de las nueve fuentes

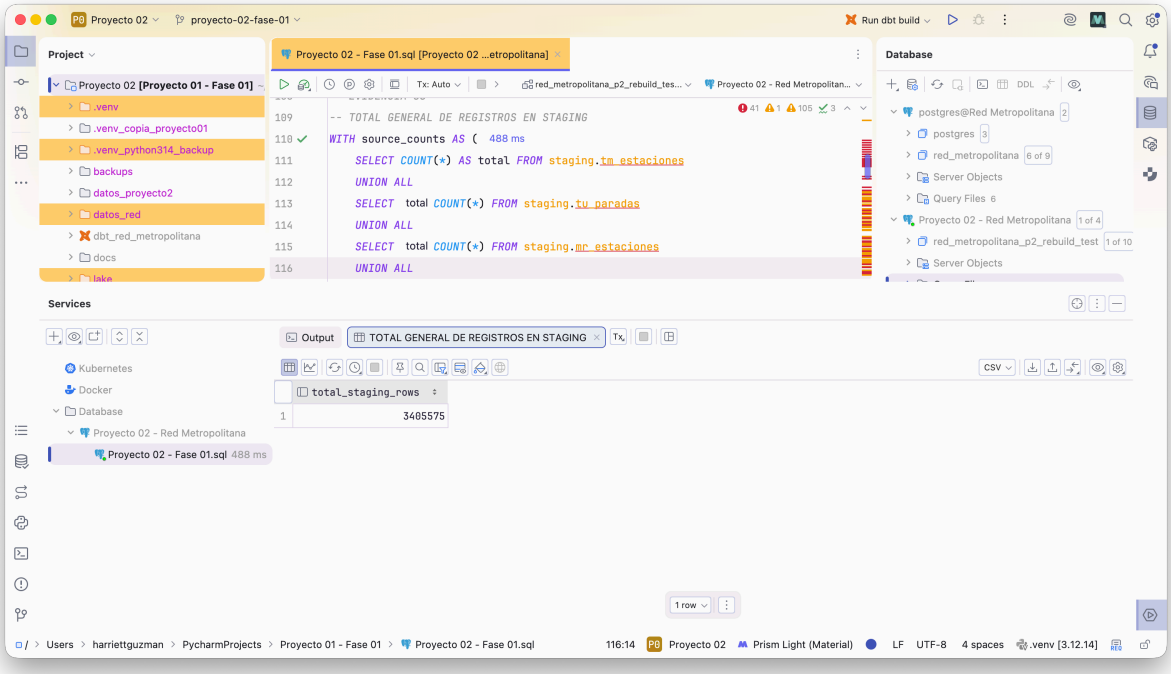
La consulta presenta los conteos de registros correspondientes a las nueve fuentes de datos cargadas en staging. Estos resultados se utilizan para contrastar la información recibida con la procesada y detectar posibles diferencias de carga.



Anexo 5. Captura original aportada anteriormente.

Evidencia 06. Total de registros en staging

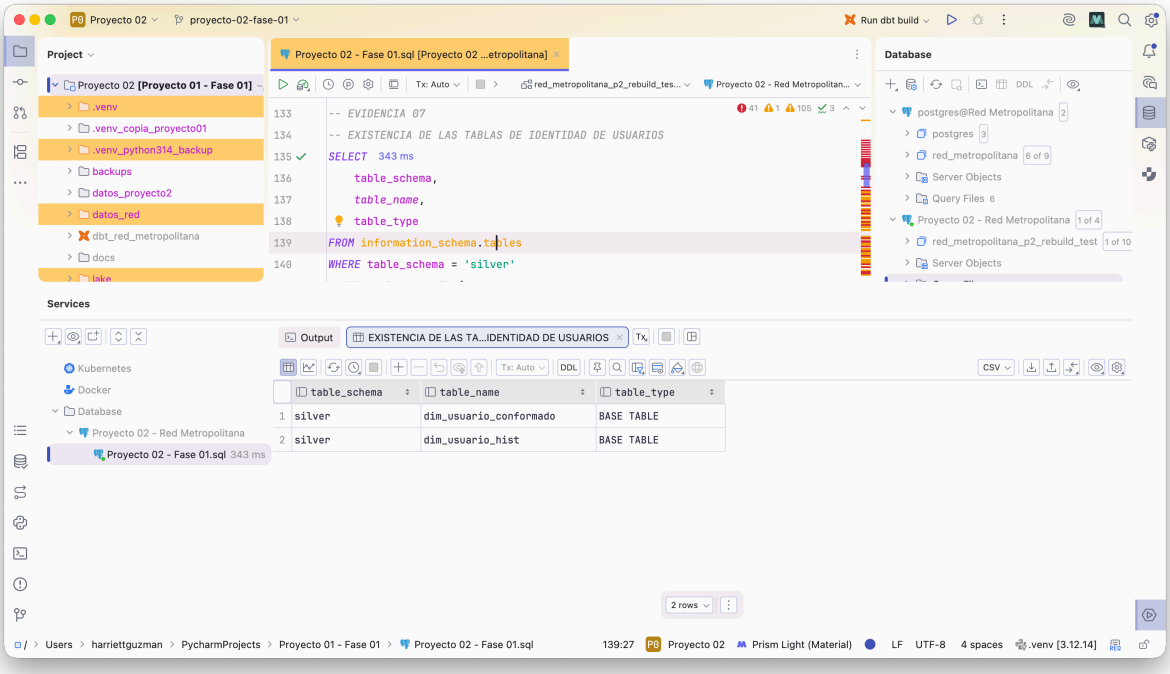
Se obtiene el total consolidado de registros almacenados en las tablas de staging. El resultado permite comprobar el volumen general de datos incorporado antes de continuar con las transformaciones.



Anexo 6. Captura original aportada anteriormente.

Evidencia 07. Tablas de identidad en Silver

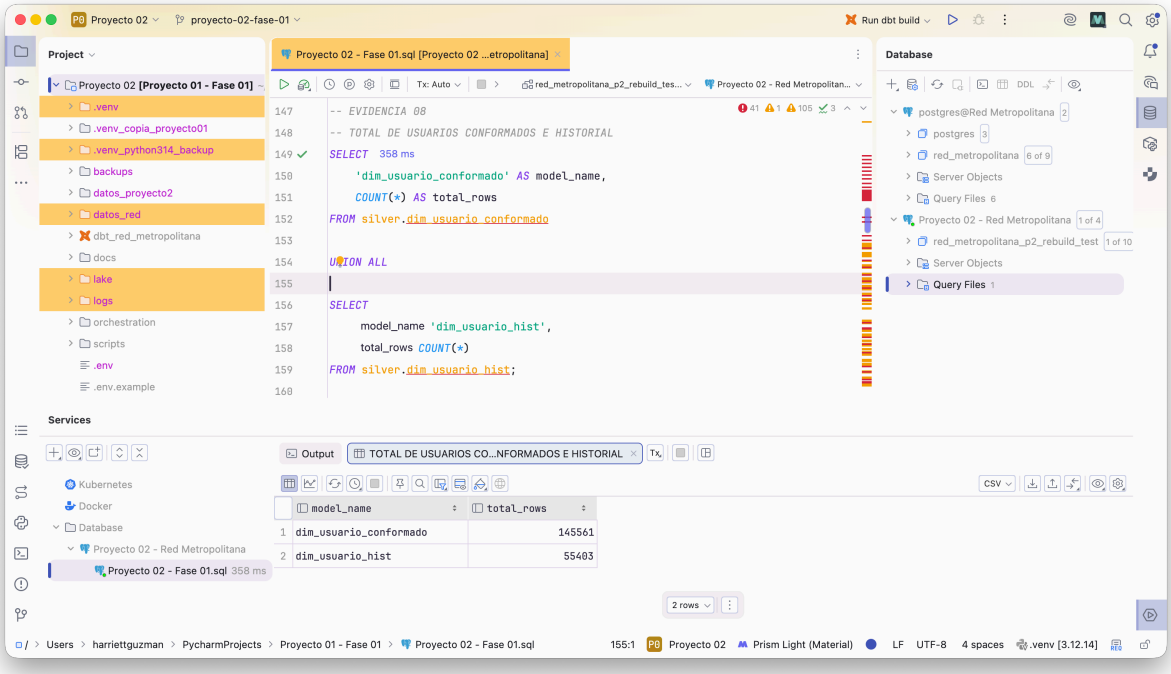
Se identifican las tablas del esquema silver relacionadas con la identidad de los usuarios, como la dimensión conformada y su historial. Estas estructuras permiten trabajar con identificadores consistentes y conservar información sobre cambios.



Anexo 7. Captura original aportada anteriormente.

Evidencia 08. Registros de identidad e historial

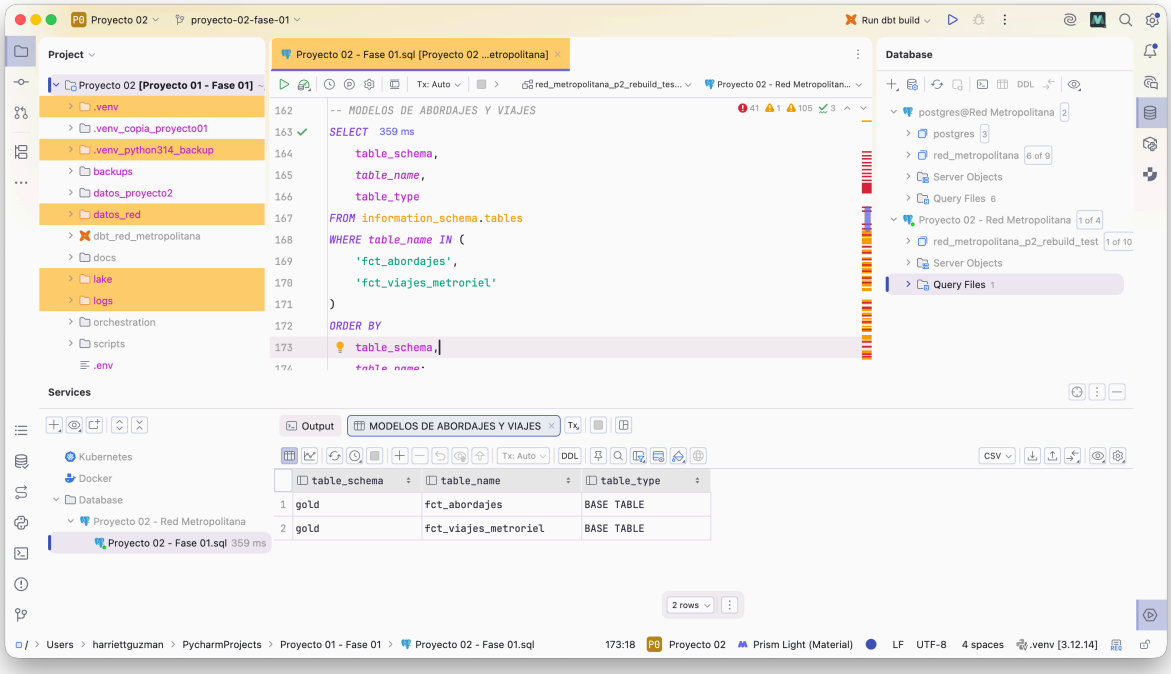
La consulta contabiliza los registros de las tablas de identidad y de historial del esquema silver. Esto ayuda a comprobar que ambas estructuras contienen datos y están disponibles para la construcción de la población de análisis.



Anexo 8. Captura original aportada anteriormente.

Evidencia 09. Modelos de abordajes y viajes en Gold

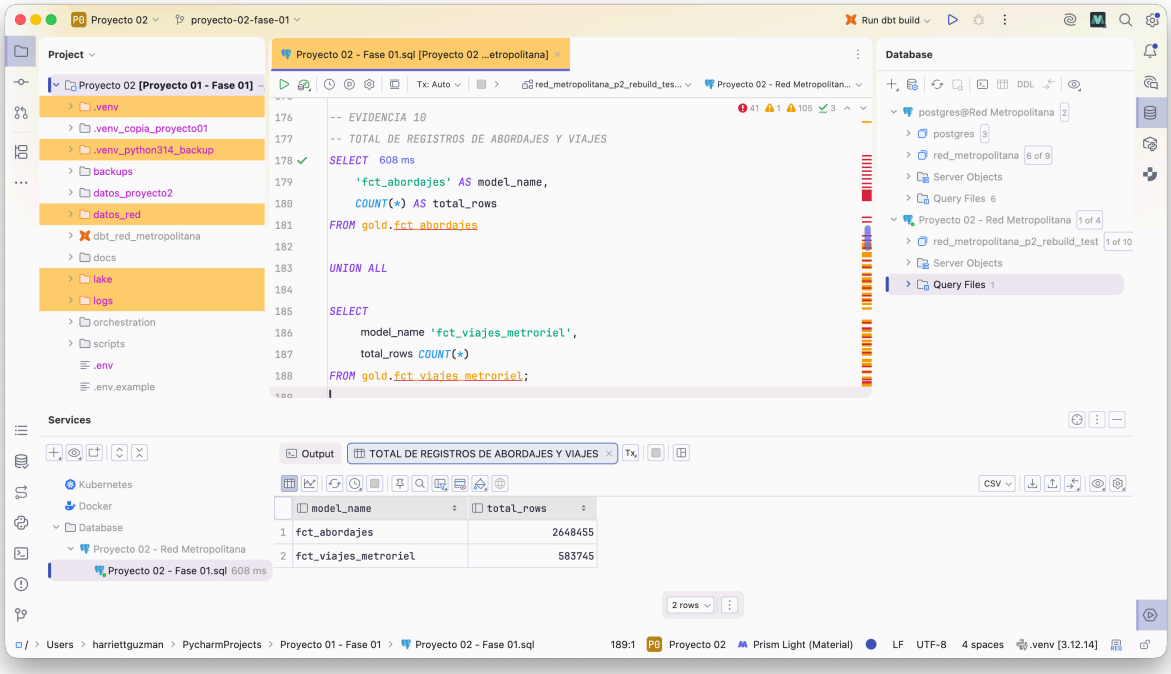
Se listan los modelos del esquema gold que contienen información de abordajes y viajes. Su presencia confirma que existen fuentes consolidadas para analizar la actividad de transporte de los usuarios.



Anexo 9. Captura original aportada anteriormente.

Evidencia 10. Volumen de abordajes y viajes en Gold

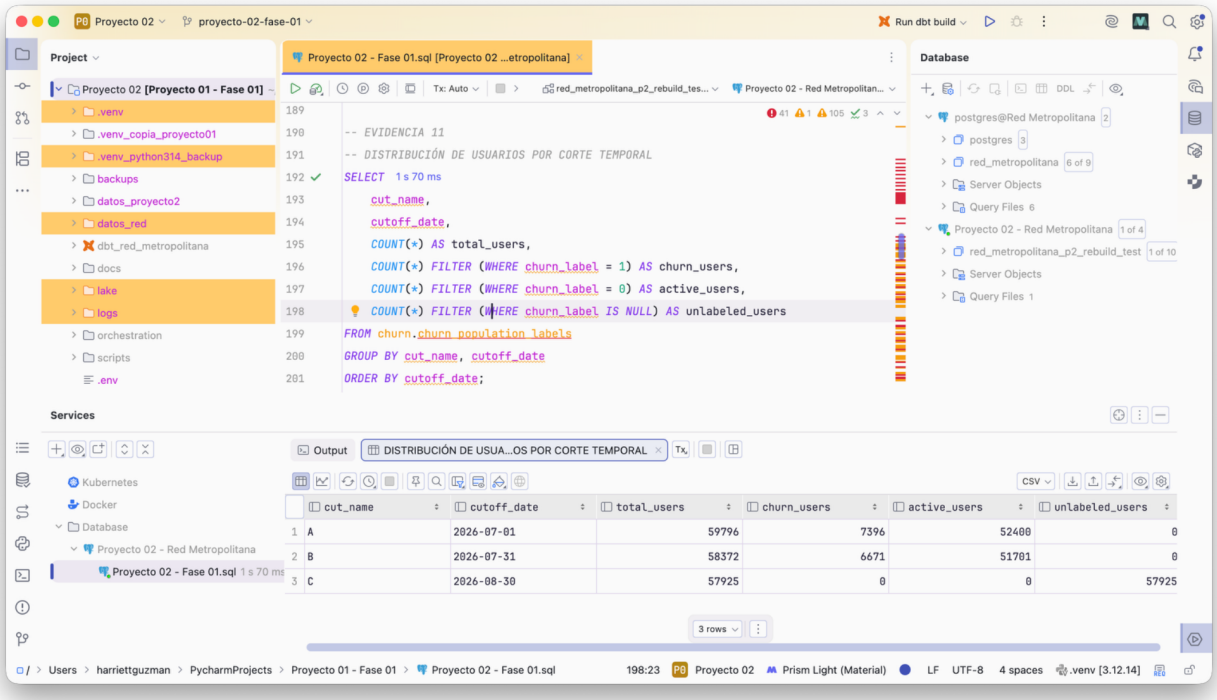
Se comparan los totales de registros de los modelos de abordajes y viajes del esquema gold. La evidencia permite dimensionar los eventos de movilidad disponibles para elaborar las variables y etiquetas de abandono.



Anexo 10. Captura original aportada anteriormente.

Evidencia 11. Distribución de usuarios por corte

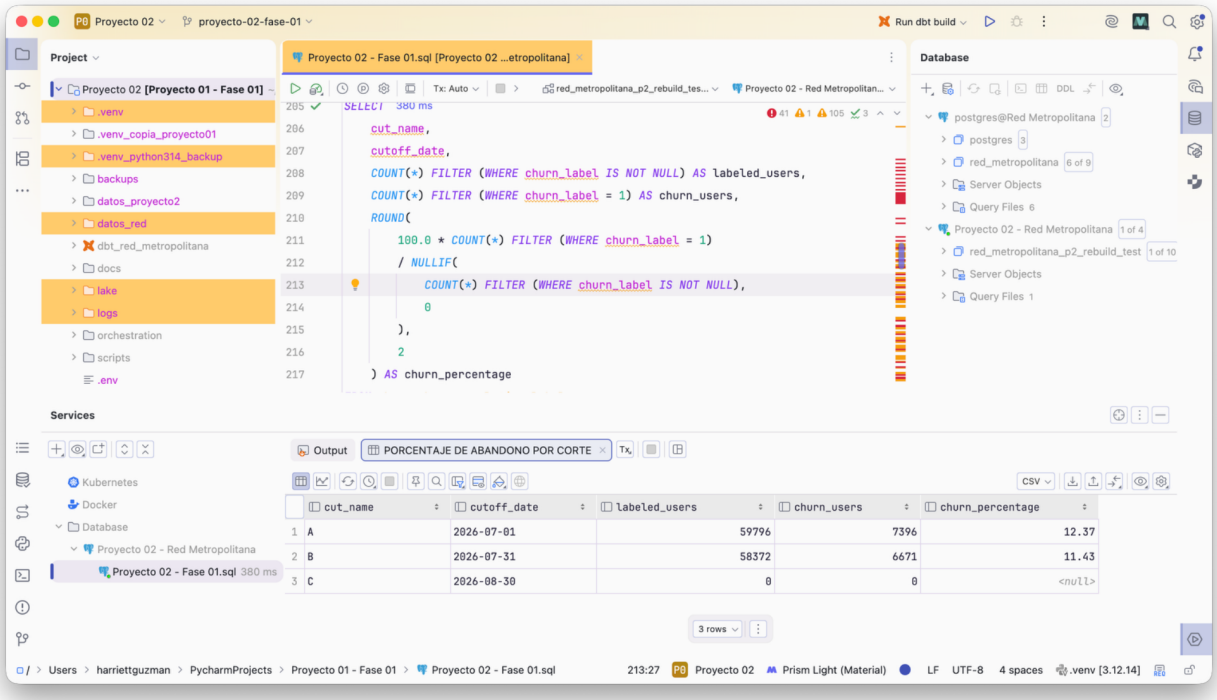
Se contabilizan las unidades de análisis de cada fecha de corte: 59,796 usuarios en A, 58,372 en B y 57,925 en C. Estos conteos establecen el tamaño de las poblaciones utilizadas para entrenamiento, evaluación temporal y predicción.



Anexo 11. Captura de ejecución en PyCharm y PostgreSQL.

Evidencia 12. Porcentaje de abandono por corte

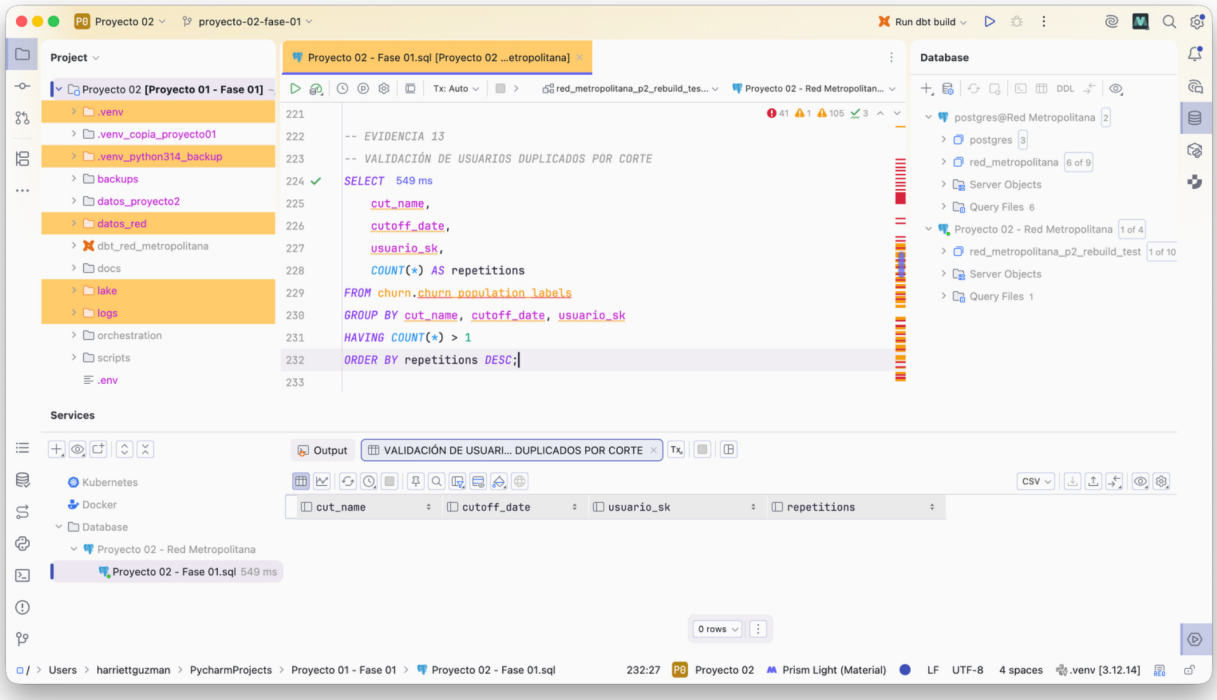
Se calcula la proporción de usuarios etiquetados con abandono: 12.37 % en A y 11.43 % en B. El corte C no presenta una tasa calculable porque su período futuro de observación todavía no dispone de etiquetas.



Anexo 12. Captura de ejecución en PyCharm y PostgreSQL.

Evidencia 13. Usuarios duplicados por corte

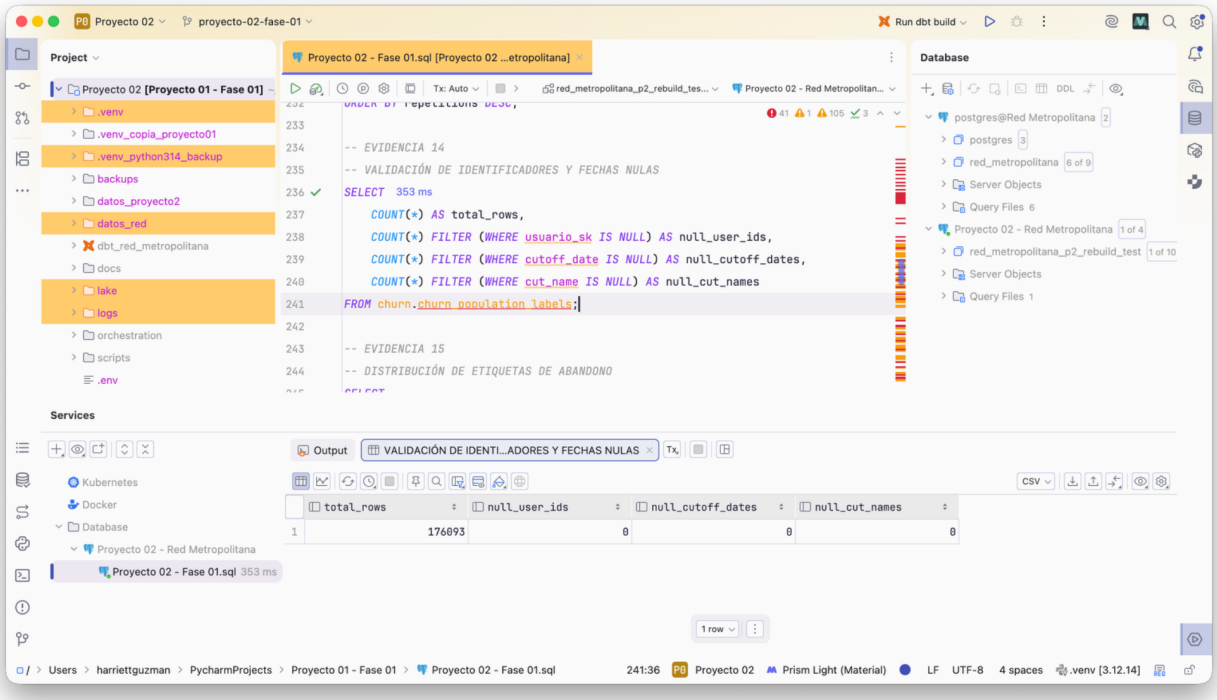
La consulta busca identificadores de usuario repetidos dentro de una misma fecha de corte. Al no devolver registros, respalda que cada usuario aparece una sola vez por corte en la tabla de población.



Anexo 13. Captura de ejecución en PyCharm y PostgreSQL.

Evidencia 14. Identificadores y fechas nulas

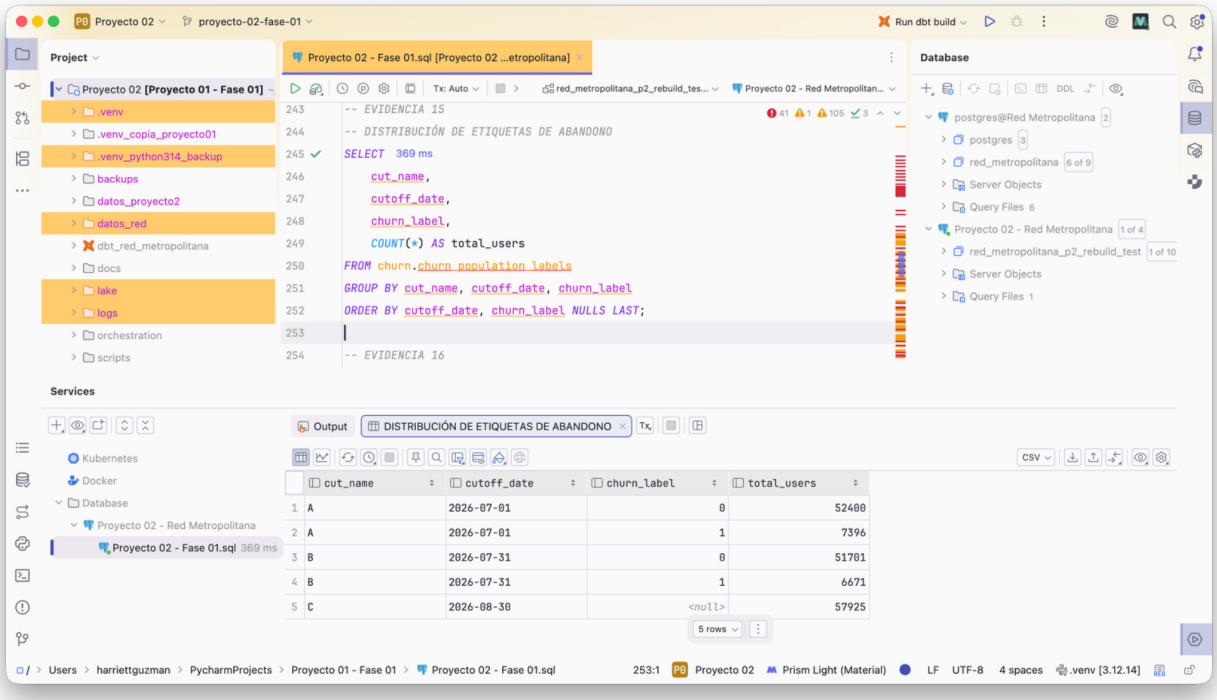
Se revisan las 176,093 filas de población para detectar valores nulos en el identificador del usuario, la fecha y el nombre del corte. Los tres controles devuelven cero, lo que respalda la integridad de los campos básicos.



Anexo 14. Captura de ejecución en PyCharm y PostgreSQL.

Evidencia 15. Distribución de etiquetas

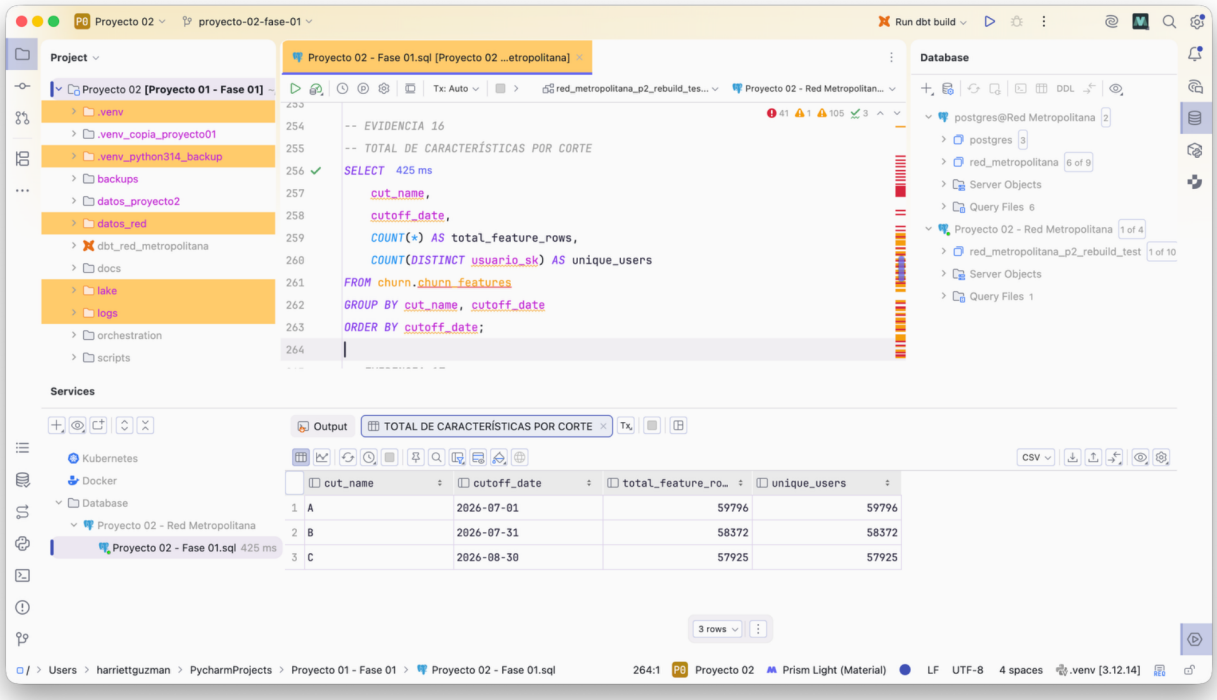
Se agrupan los registros según corte y valor de churn_label. Los cortes A y B contienen las clases 0 (usuario activo) y 1 (abandono), mientras que en C las etiquetas permanecen nulas para evitar utilizar información futura.



Anexo 15. Captura de ejecución en PyCharm y PostgreSQL.

Evidencia 16. Características por corte

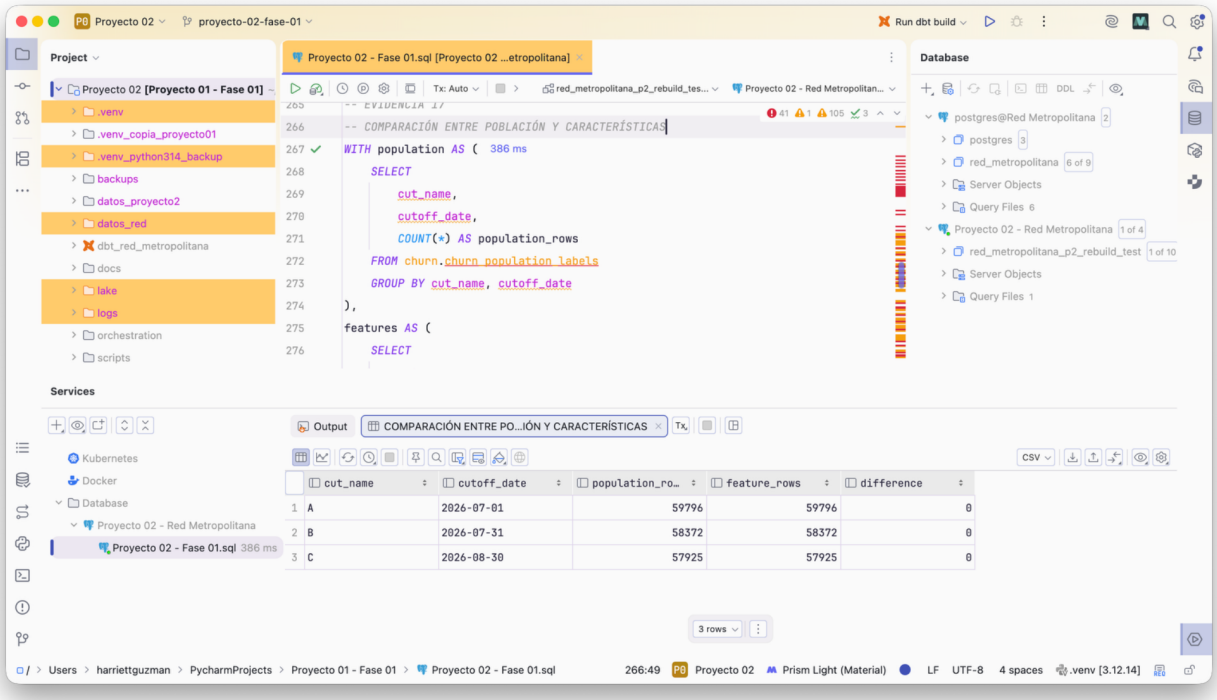
Se cuentan las filas de la tabla churn_features por fecha de corte y se comparan con los usuarios distintos. Los valores coinciden en A, B y C, lo que indica que se generó un registro de características por usuario y corte.



Anexo 16. Captura de ejecución en PyCharm y PostgreSQL.

Evidencia 17. Comparación de población y características

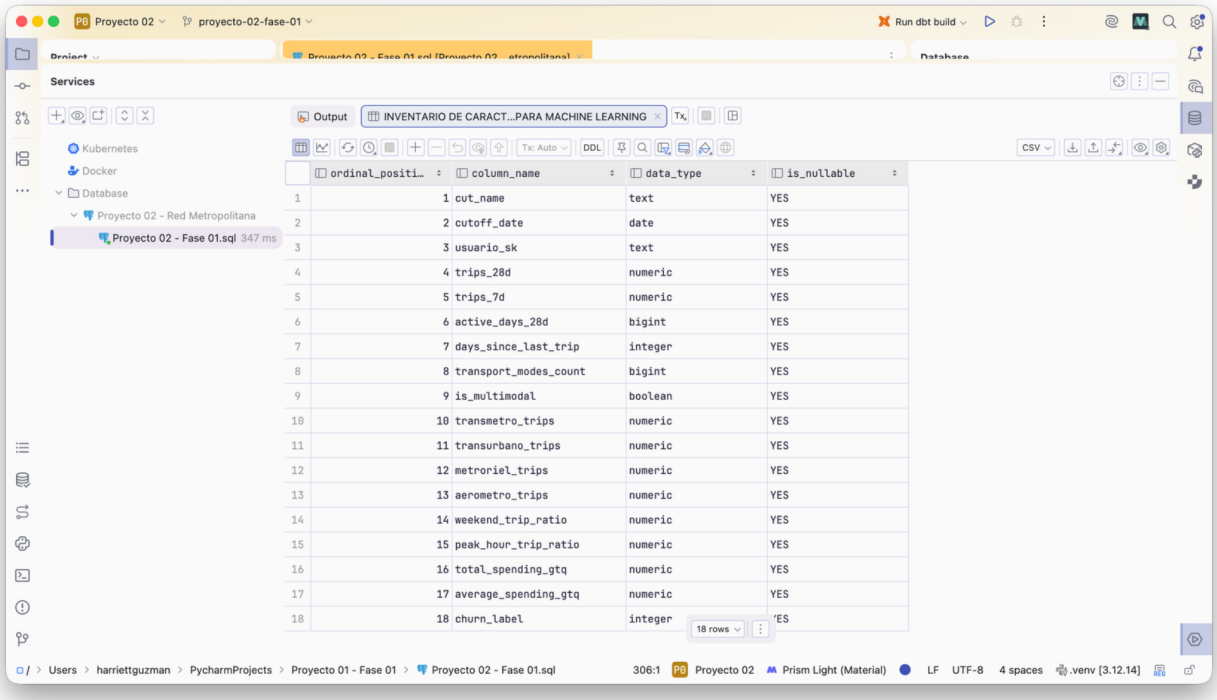
Se contrastan los conteos de churn_population_labels y churn_features para las tres fechas. La diferencia es cero en todos los casos, lo que indica que las poblaciones definidas están representadas en la tabla de características.



Anexo 17. Captura de ejecución en PyCharm y PostgreSQL.

Evidencia 18. Inventario de características

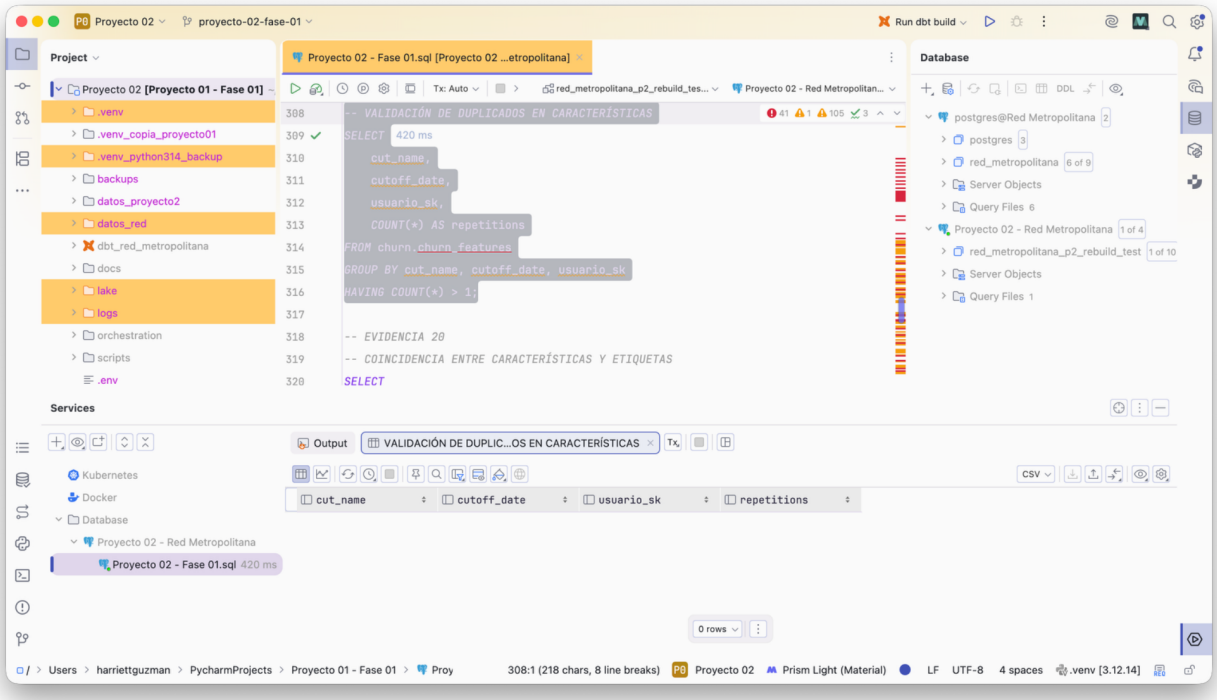
Se inspeccionan las 18 columnas de churn_features: tres campos de identificación, 14 variables predictivas y la etiqueta de abandono. La revisión permite comprobar los nombres y tipos de datos que se emplean en el modelo.



Anexo 18. Captura de ejecución en PyCharm y PostgreSQL.

Evidencia 19. Duplicados en características

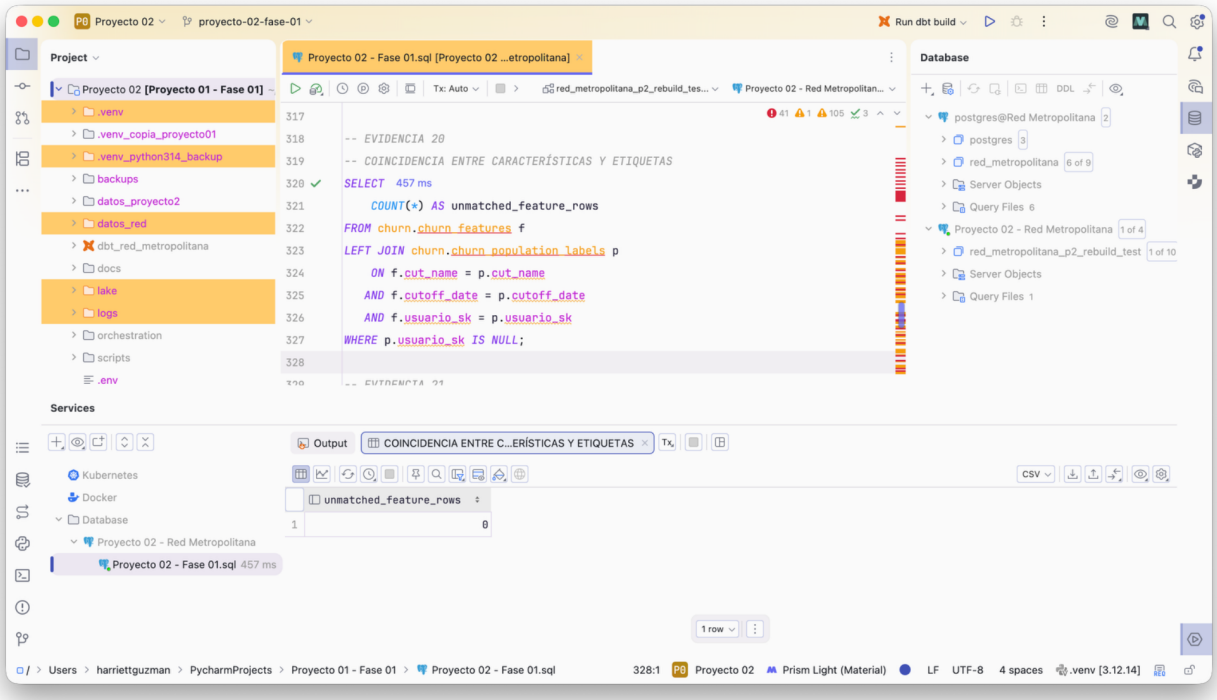
Se buscan combinaciones repetidas de usuario y fecha de corte dentro de churn_features. La consulta no devuelve filas, por lo que no se observan duplicaciones de unidades de análisis en esta tabla.



Anexo 19. Captura de ejecución en PyCharm y PostgreSQL.

Evidencia 20. Coincidencia entre features y etiquetas

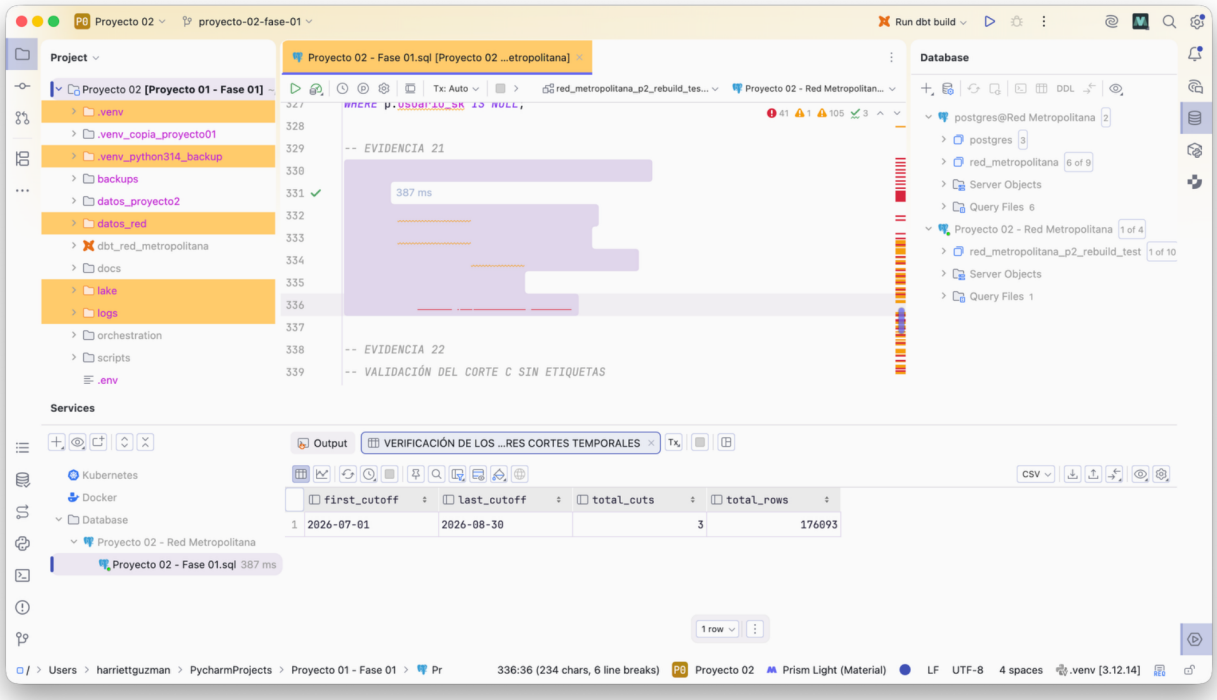
Se compara la tabla de características con la población etiquetada utilizando las claves de usuario y corte. El resultado de cero filas sin correspondencia confirma que no se encontraron características huérfanas respecto de la población.



Anexo 20. Captura de ejecución en PyCharm y PostgreSQL.

Evidencia 21. Verificación de los tres cortes

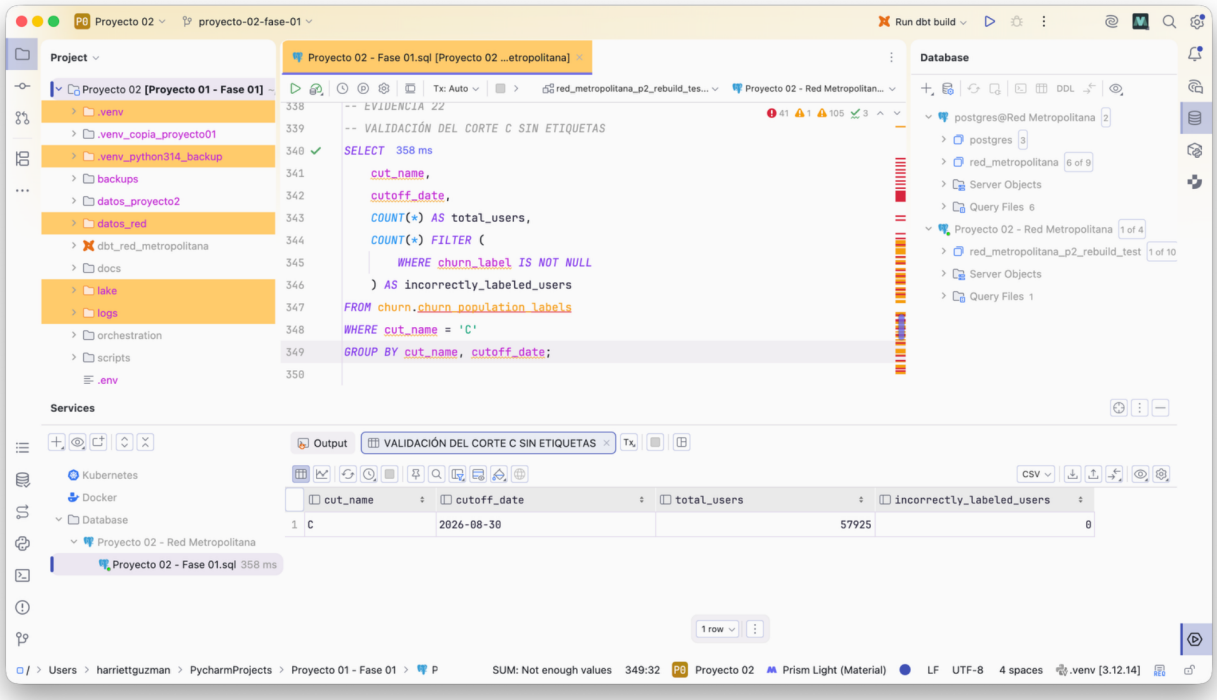
Se comprueba la existencia de los cortes temporales A, B y C, comprendidos entre el 1 de julio y el 30 de agosto de 2026. En conjunto se registran 176,093 observaciones, utilizadas en las distintas etapas del análisis.



Anexo 21. Captura de ejecución en PyCharm y PostgreSQL.

Evidencia 22. Corte C sin etiquetas

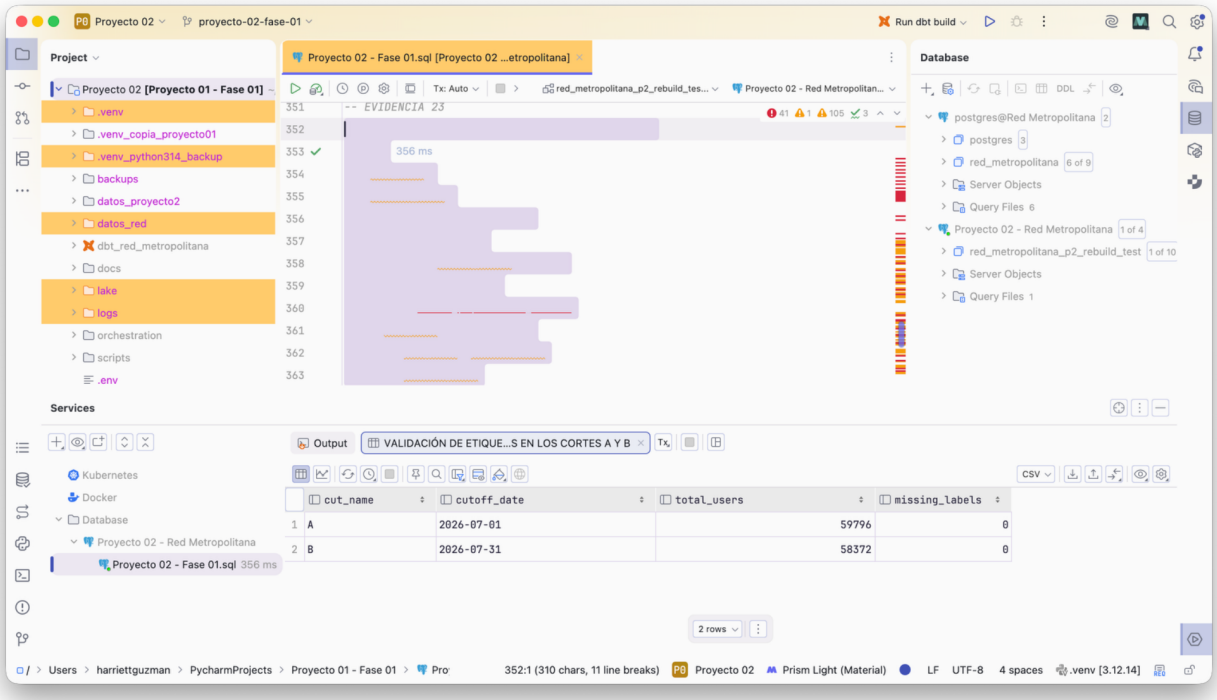
Se valida que los 57,925 usuarios del corte C tengan churn_label nulo. Esto es necesario porque no se cuenta con el período completo de 30 días posteriores al corte para determinar su abandono real.



Anexo 22. Captura de ejecución en PyCharm y PostgreSQL.

Evidencia 23. Etiquetas completas en A y B

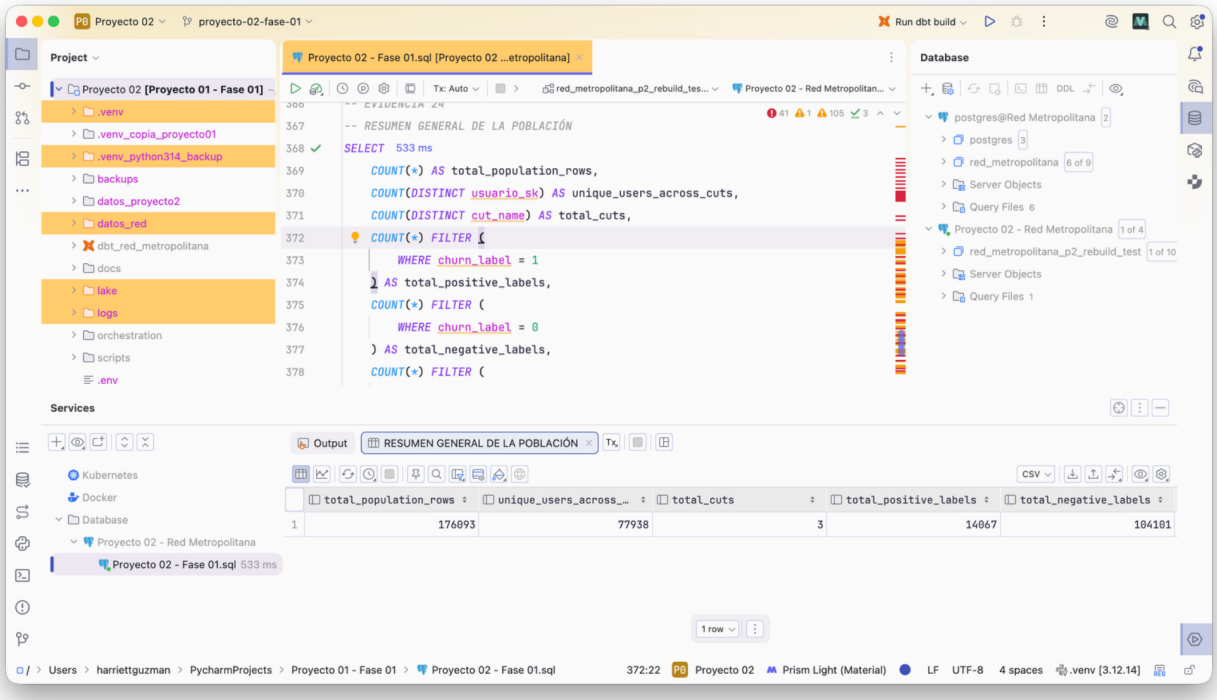
Se revisan los cortes A y B para comprobar que ningún usuario elegible tenga la etiqueta de abandono vacía. El resultado de cero etiquetas faltantes permite utilizar estos conjuntos en las evaluaciones supervisadas.



Anexo 23. Captura de ejecución en PyCharm y PostgreSQL.

Evidencia 24. Resumen general de población

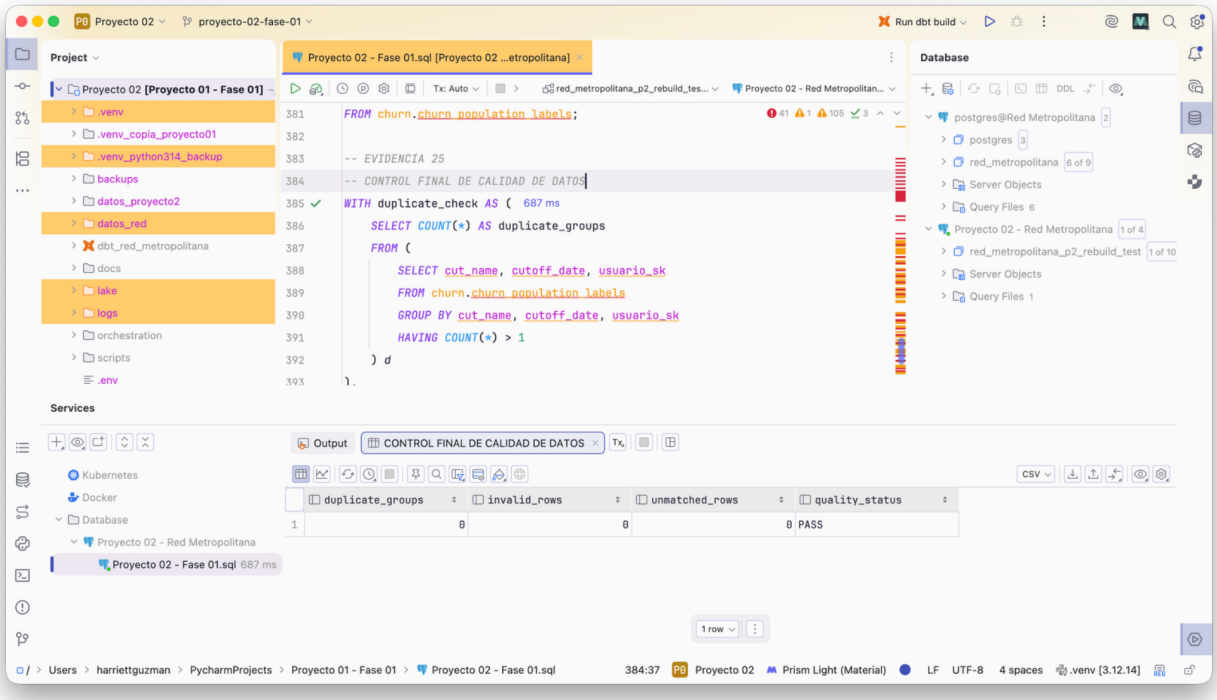
La consulta resume las tres fechas de corte y registra 176,093 filas, 77,938 usuarios distintos y 14,067 etiquetas positivas. Como una misma persona puede aparecer en varios cortes, el total de filas supera al número de usuarios únicos.



Anexo 24. Captura de ejecución en PyCharm y PostgreSQL.

Evidencia 25. Control final de calidad

Se ejecuta una verificación conjunta de duplicados, registros con campos esenciales inválidos y características sin población asociada. Los tres indicadores son cero y el resultado mostrado es PASS, respaldando la consistencia de las tablas analizadas.



Anexo 25. Captura de ejecución en PyCharm y PostgreSQL.