Universidad Rafael Landívar

Facultad Ingeniería

Ingeniería en Sistemas e Informática

Ciencia de Datos

Inge. Max Cerna

Proyecto 02

Agencia Metropolitana de Transporte

Rochelle Giulianne Esquivel Vargas – 1283220

Susana Paola García García – 1224323

Harriett Alexandra Guzmán López – 1112423

Guatemala, 12 de noviembre del 2026

Tabla de contenido

INTRODUCCIÓN **3**

OBJETIVOS **4**

METODOLOGÍA Y SEPARACIÓN TEMPORAL **4**

DESARROLLO DE LA FASE 02 ..... **5**

ENSEMBLE Y ANÁLISIS DE SESGO-VARIANZA 5

UMBRAL ECONÓMICO Y EVALUACIÓN TEMPORAL 5

SEGMENTACIÓN DE USUARIOS CON KMEANS Y PCA 6

MLOPS, PREDICCIÓN Y CONTROLES DE CALIDAD 6

RESULTADOS Y CONCLUSIONES **7**

ANEXOS **8**

POBLACIÓN DE USUARIOS EN LOS CORTES A, B Y C 8

DISTRIBUCIÓN DE ETIQUETAS Y TASA DE ABANDONO 9

VERIFICACIÓN DE USUARIOS DUPLICADOS 10

INTEGRIDAD DE IDENTIFICADORES Y FECHAS 11

POBLACIÓN DE EVALUACIÓN TEMPORAL DEL CORTE B 12

MUESTRA DE VARIABLES PREDICTORAS DEL CORTE A 13

POBLACIÓN FINAL DEL CORTE C 14

USUARIOS DEL CORTE C CON TARJETA CDC IDENTIFICADA 15

USUARIOS DEL CORTE C SIN TARJETA CDC IDENTIFICADA 16

GITHUB 16

PRESENTACIÓN 16

Introducción

El Proyecto 02 analiza el riesgo de abandono de usuarios de la Red Metropolitana de Transporte. En la Fase 02 se comparó un modelo ensemble con las referencias de la Fase 01, se definió una política de contacto con criterios económicos, se segmentó la población mediante KMeans y se implementó un proceso reproducible de predicción para el corte C.

Este informe integra los resultados técnicos descritos en la auditoría académica compartida y nueve capturas de consultas ejecutadas en PostgreSQL desde PyCharm. Las capturas comprueban población, etiquetas, integridad, características y cobertura de tarjetas; las métricas de aprendizaje automático proceden del informe de auditoría y de los artefactos del proyecto, no de estas consultas SQL.

Objetivos

- Comparar Random Forest con modelos de referencia utilizando PR-AUC y análisis de sesgo-varianza.
- Seleccionar y evaluar una política de contacto a partir de costos y beneficios, respetando la separación temporal A/B/C.
- Identificar segmentos de usuarios con KMeans y representarlos mediante PCA.
- Generar predicciones del corte C sin reentrenamiento, documentar el modelo y comprobar la integridad de los datos.

Metodología y separación temporal

Corte	Fecha	Usuarios	Uso en el proyecto
A	01/07/2026	59,796	Entrenamiento, validación y segmentación
B	31/07/2026	58,372	Evaluación temporal única
C	30/08/2026	57,925	Predicción final sin etiquetas

La tabla churn.churn_features reúne 176,093 registros en los tres cortes. La verificación SQL muestra 59,796 y 58,372 usuarios etiquetados en A y B, respectivamente, mientras que C contiene 57,925 usuarios sin etiqueta de abandono. Esta separación permite evaluar el comportamiento del modelo en un período posterior sin utilizar las etiquetas del corte de predicción.

Desarrollo de la Fase 02

Ensemble y análisis de sesgo-varianza

Se comparó Random Forest con regresión logística L2 y dos líneas base. Se utilizaron cinco folds estratificados con semilla 42. Random Forest alcanzó PR-AUC de validación de 0.435169 frente a 0.429148 de la regresión logística, una mejora de aproximadamente 0.0060. Su PR-AUC de entrenamiento fue 0.500067, con brecha de 0.064898, lo que sugiere sobreajuste moderado y exige interpretar la mejora con prudencia.

Modelo	PR-AUC entrenamiento	PR-AUC validación
Baseline constante	0.123687	0.123687
Baseline frecuencia	0.262446	0.262542
Regresión logística L2	0.428522	0.429148
Random Forest	0.500067	0.435169

En la importancia por permutación destacaron days_since_last_trip (+0.1581) y trips_7d (+0.0403). Esto indica que la recencia y la actividad reciente son señales relevantes para la predicción, sin que ello demuestre una relación causal.

Umbral económico y evaluación temporal

Se estableció un costo de Q5 por contacto, un valor de Q60 por usuario retenido y una efectividad estimada de 25 %. El beneficio esperado por verdadero positivo es Q15. Por ello, el umbral teórico de contacto es 5 / (0.25 × 60) = 0.333333.

La ganancia se calculó como: ganancia = (verdaderos positivos × Q15) − (contactos × Q5). La selección de la política se realizó con predicciones fuera de fold del corte A; después se evaluó en el corte B.

Indicador en corte B	Resultado
PR-AUC	0.399490
Precisión	0.432428
Recall	0.405786
TN / FP / FN / TP	48,148 / 3,553 / 3,964 / 2,707
Contactos seleccionados	6,260
Ganancia esperada	Q9,305.00

La evaluación en B mostró una ganancia esperada positiva, aunque inferior a la observada en A (Q12,715), coherente con la dificultad de generalizar entre períodos. El SHA del commit de referencia debe incorporarse al registro de evaluación una vez publicada la entrega.

Segmentación de usuarios con KMeans y PCA

Se estandarizaron 14 variables del corte A. El análisis de codo y silueta favoreció k = 2, con coeficiente de silueta 0.3361. La representación PCA de dos componentes explicó 47.54 % de la variación (31.78 % y 15.76 %).

Perfil	Segmento 0	Segmento 1
Usuarios	48,956 (81.87 %)	10,840 (18.13 %)
Abandono descriptivo	14.69 %	1.90 %
Mediana de viajes / 28 días	7	37
Mediana de días desde último viaje	4	1
Acción propuesta	Reactivación y bonos	Lealtad y beneficios por uso

Los perfiles sugieren campañas de reactivación para usuarios ocasionales y programas de fidelización para usuarios intensivos. Las diferencias entre segmentos son descriptivas; no prueban que pertenecer a un grupo cause abandono.

MLOps, predicción y controles de calidad

El predictor predecir.py puede ejecutarse desde la raíz del repositorio y utiliza el artefacto churn_pipeline_v1.joblib sin reentrenamiento. Las características se consultan desde PostgreSQL; el argumento --datos no implica que el script lea directamente archivos de esa carpeta. El CSV final predictions_C_phase2.csv contiene unidad_id, tarjetas, puntaje y contactar.

Control del corte C	Resultado
Usuarios predichos	57,925
Con tarjeta CDC identificada	27,200
Sin tarjeta CDC identificada	30,725
Seleccionados para contactar	6,385
Usuarios duplicados por corte	0
Identificadores o fechas nulos	0

la auditoría aportada también reporta una prueba de invariancia temporal con 600 abordajes sintéticos posteriores al corte C, sin cambios en las decisiones ni en las características. Esta prueba no aparece directamente en las nueve capturas SQL anexas y debe respaldarse con el archivo o registro de ejecución correspondiente.

Resultados y conclusiones

Los tres cortes presentan poblaciones consistentes y usuarios únicos, con 176,093 registros y sin identificadores ni fechas de corte nulos. El corte C permanece sin etiquetas, condición necesaria para simular una predicción prospectiva. En términos de negocio, el Random Forest ofrece una mejora moderada de discriminación y la política de contacto alcanza una ganancia esperada de Q9,305 en la evaluación temporal B.

La segmentación distingue un grupo de uso ocasional con mayor abandono descriptivo y otro de uso frecuente con menor abandono. Para la operación, se recomienda priorizar campañas con base en el puntaje y en la disponibilidad de identificación de tarjeta, documentando el tratamiento de los 30,725 usuarios sin tarjeta CDC identificada. Antes de la entrega final corresponde registrar el SHA del commit en evaluation_log.md y publicar la etiqueta fase-2.

Anexos

Población de usuarios en los cortes A, B y C

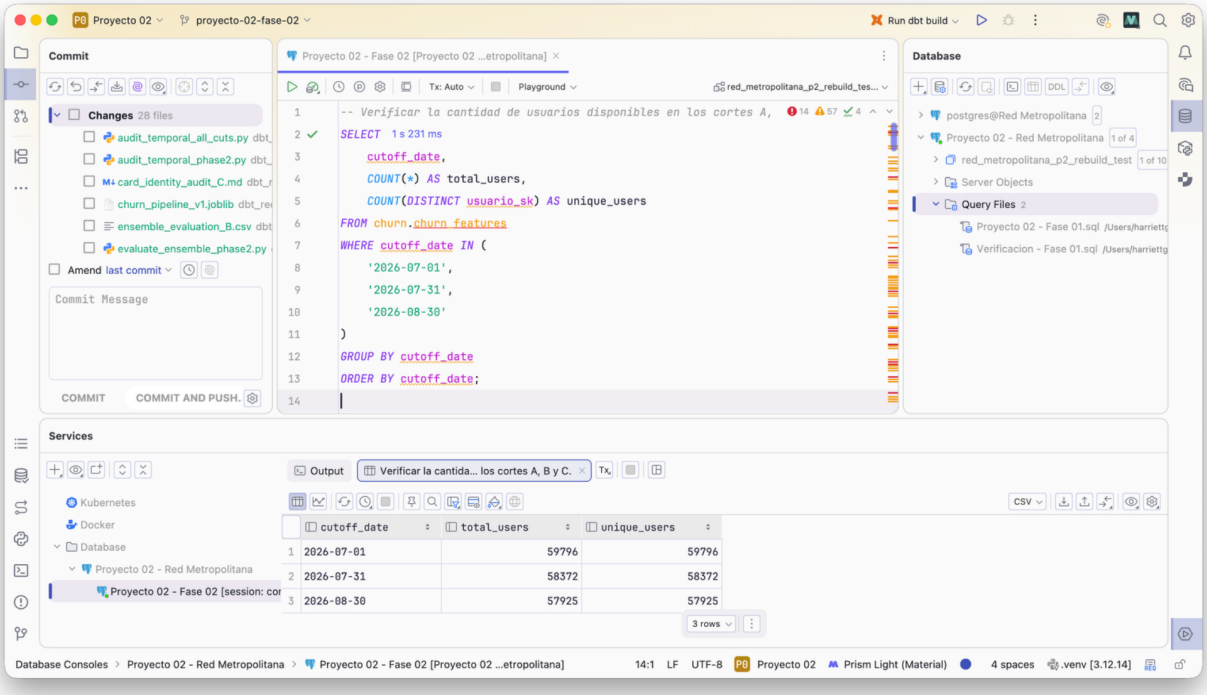


Figura 1. Población de usuarios en los cortes A, B y C.

Descripción: La consulta compara la cantidad total de registros con el número de usuarios únicos en cada corte temporal. Los resultados muestran 59,796 usuarios en A, 58,372 en B y 57,925 en C. Como ambas cifras coinciden en los tres cortes, se confirma que la población está identificada de manera consistente para los análisis posteriores.

Interpretación: Confirma el tamaño de las poblaciones y la unicidad de usuario por fecha de corte.

Distribución de etiquetas y tasa de abandono

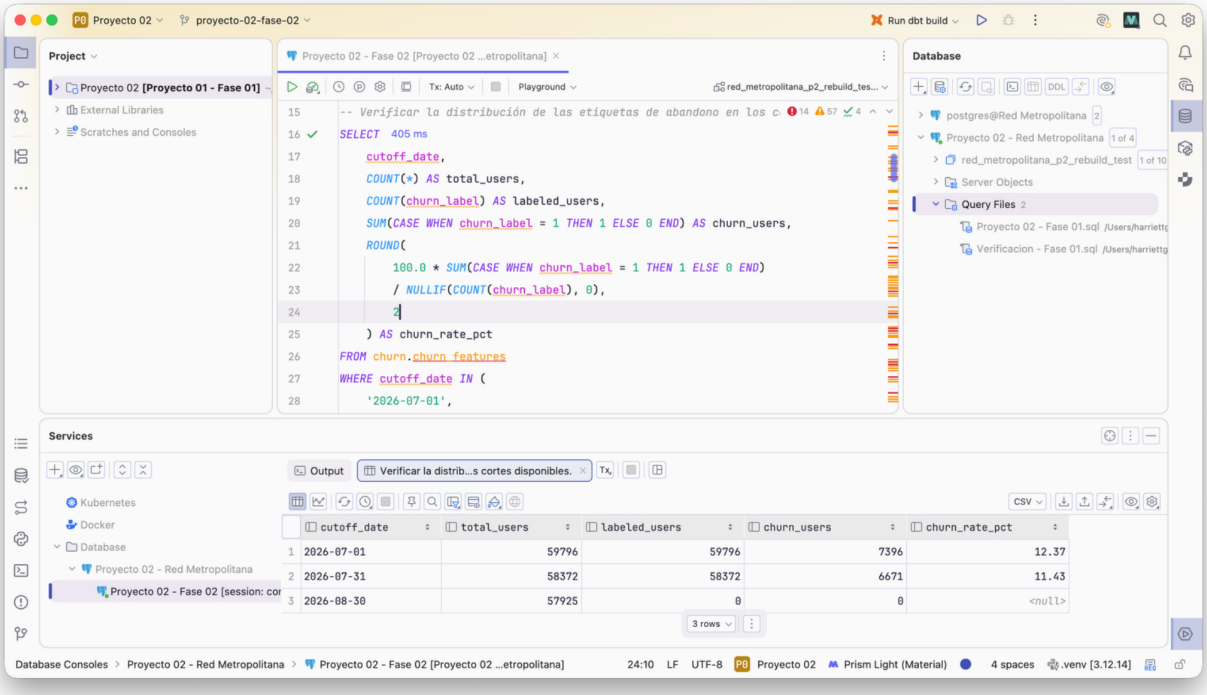


Figura 2. Distribución de etiquetas y tasa de abandono.

Descripción: Esta evidencia presenta la distribución de las etiquetas de abandono en los cortes A y B. En A se identificaron 7,396 usuarios que abandonaron el servicio, equivalentes al 12.37 %, mientras que en B fueron 6,671 (11.43 %). El corte C aún no tiene etiquetas, por lo que se utiliza para generar predicciones sin conocer el resultado futuro.

Interpretación: Sustenta la separación entre entrenamiento/evaluación y predicción futura sin etiqueta.

Verificación de usuarios duplicados

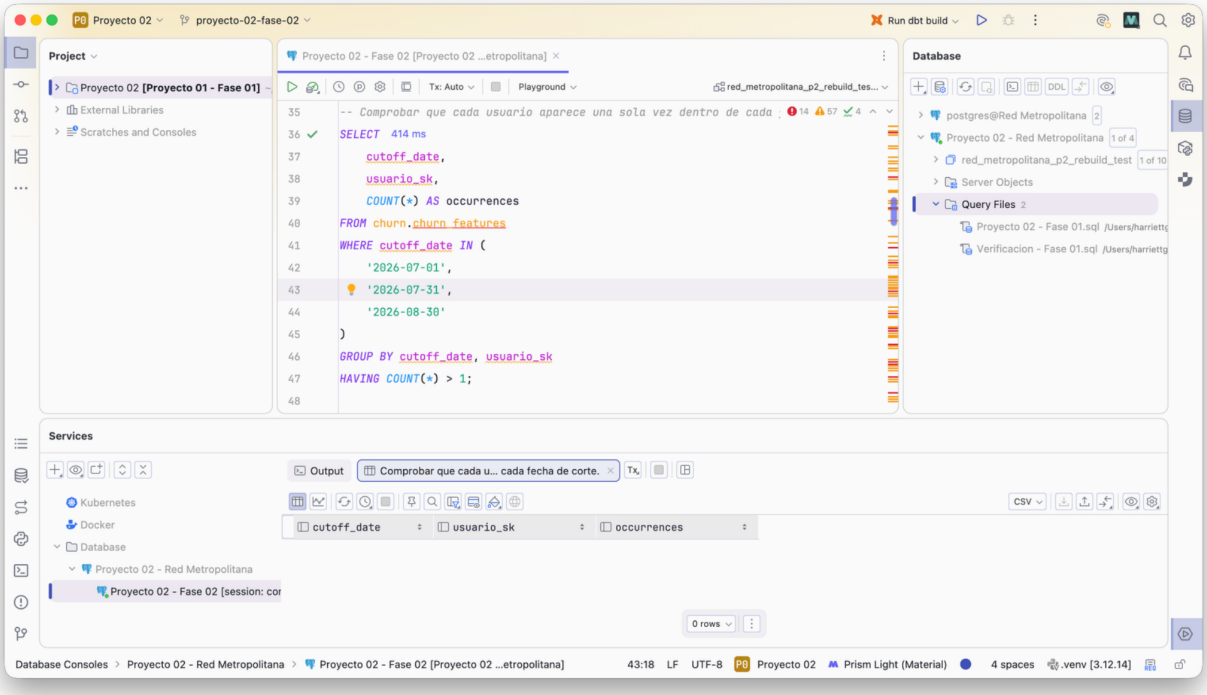


Figura 3. Verificación de usuarios duplicados.

Descripción: La consulta busca usuarios repetidos dentro de una misma fecha de corte, agrupando los registros por identificador y fecha. El resultado fue de cero filas, lo que indica que no se encontraron duplicados bajo este criterio. Esta comprobación es importante porque evita contar varias veces a un mismo usuario durante el entrenamiento, la evaluación y la predicción.

Interpretación: No se detectaron registros duplicados de un mismo usuario dentro de los cortes analizados.

Integridad de identificadores y fechas

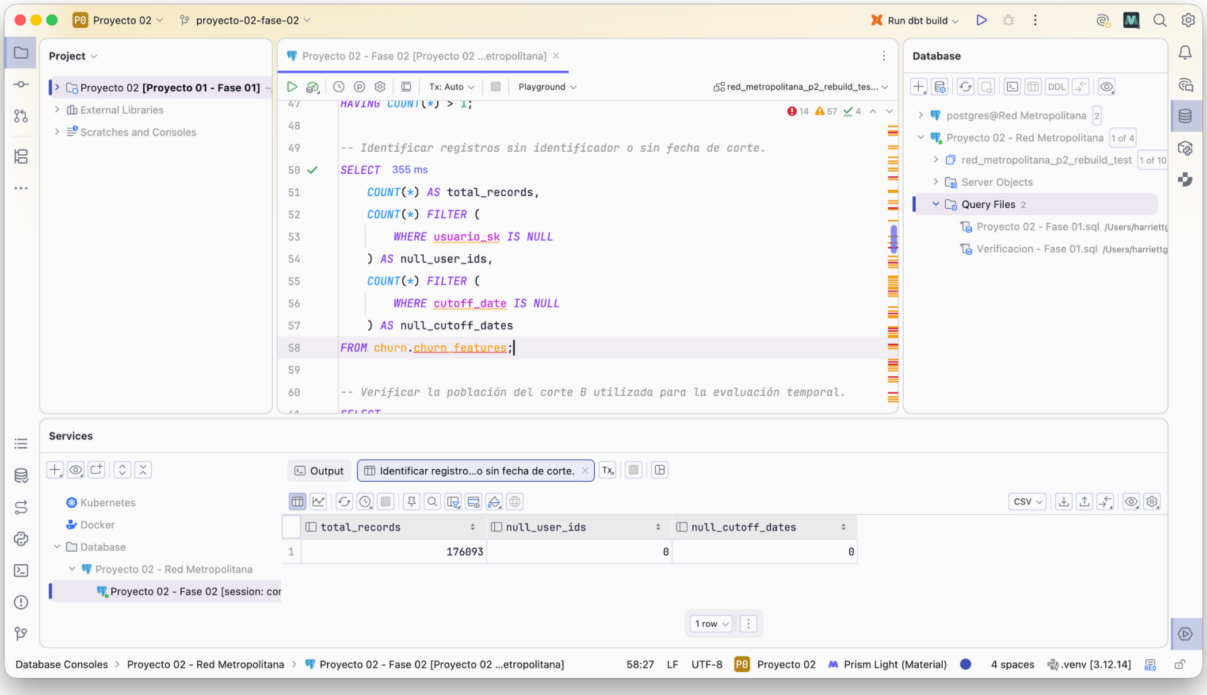


Figura 4. Integridad de identificadores y fechas.

Descripción: Se revisó la integridad de los identificadores de usuario y las fechas de corte en la tabla de características. De 176,093 registros evaluados, ninguno presentó valores nulos en estos dos campos. Esto respalda la consistencia básica del conjunto de datos y permite relacionar correctamente las observaciones con sus respectivos períodos de análisis.

Interpretación: Confirma la integridad de las claves de usuario y las fechas de corte.

Población de evaluación temporal del corte B

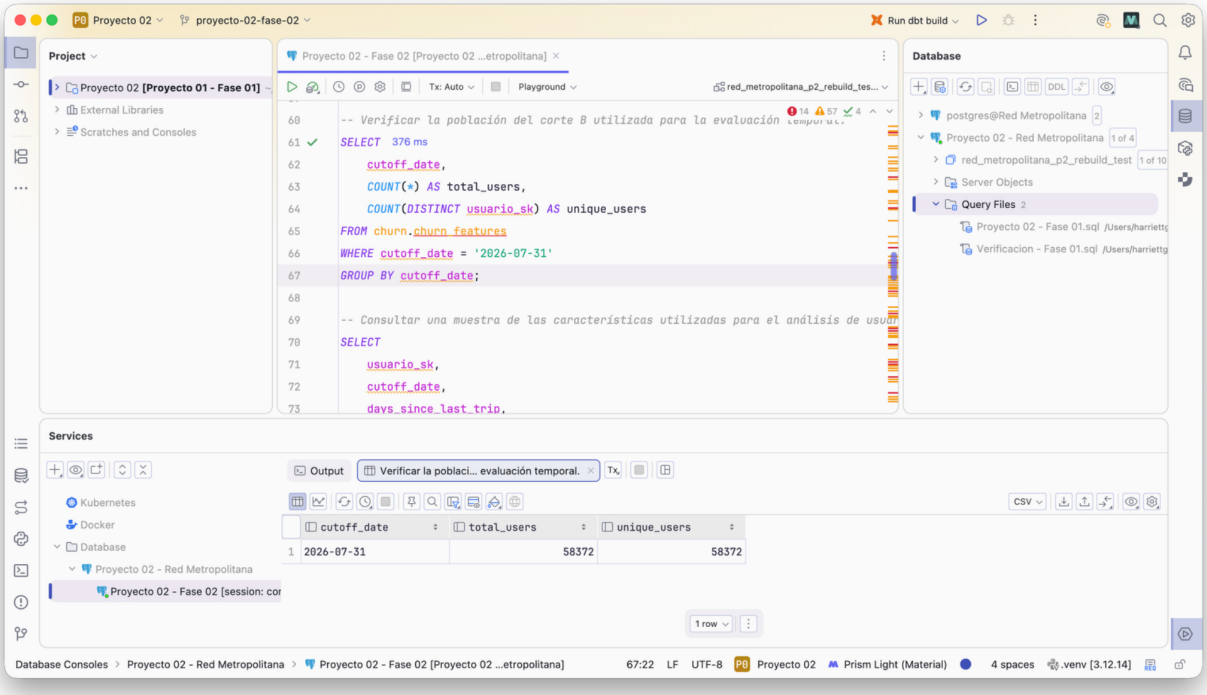


Figura 5. Población de evaluación temporal del corte B.

Descripción: Esta consulta confirma que el corte B, fechado el 31 de julio de 2026, contiene 58,372 registros correspondientes a 58,372 usuarios distintos. Dicho corte se empleó para la evaluación temporal del modelo después de definir la política con el corte A. La verificación ayuda a documentar el tamaño de la población utilizada en esa evaluación.

Interpretación: Valida el tamaño del conjunto utilizado en la evaluación temporal B.

Muestra de variables predictoras del corte A

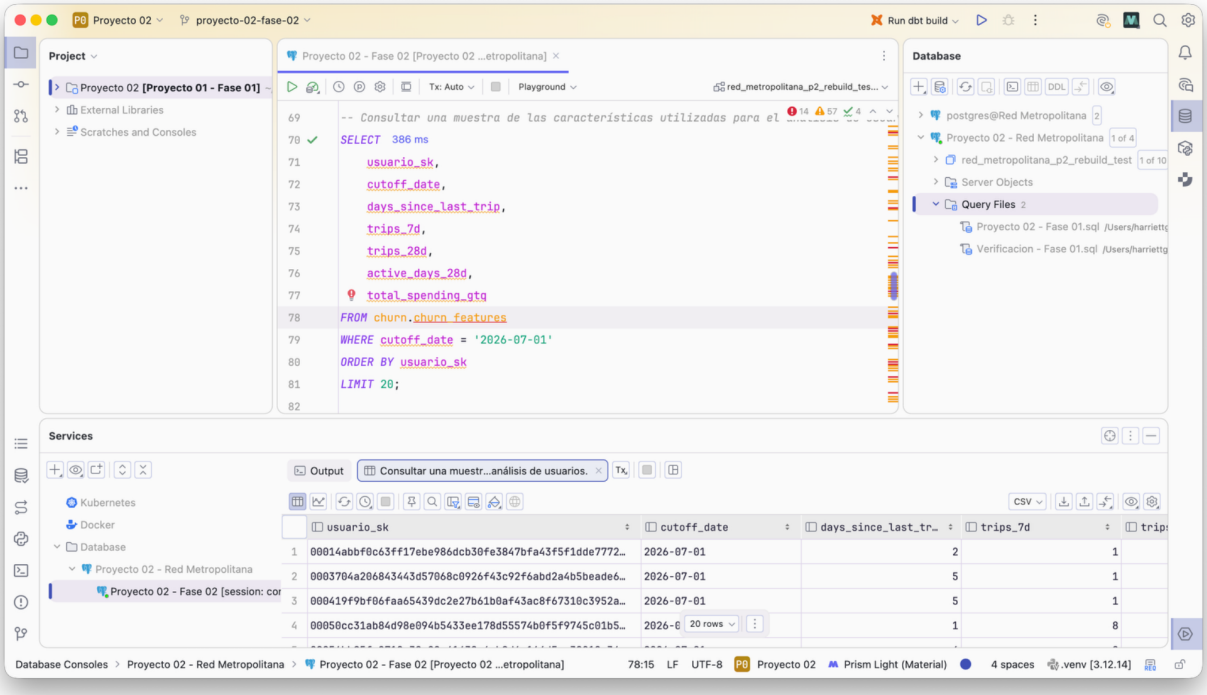


Figura 6. Muestra de variables predictoras del corte A.

Descripción: La captura muestra una muestra de veinte usuarios del corte A junto con variables relacionadas con su comportamiento de movilidad: días desde el último viaje, viajes recientes, días activos y gasto acumulado. Estas características permiten representar diferencias en la frecuencia e intensidad de uso del transporte y sirven como insumos para el modelado predictivo y la segmentación.

Interpretación: Ilustra las características de comportamiento disponibles para el modelado y la segmentación; no mide por sí sola la importancia predictiva.

Población final del corte C

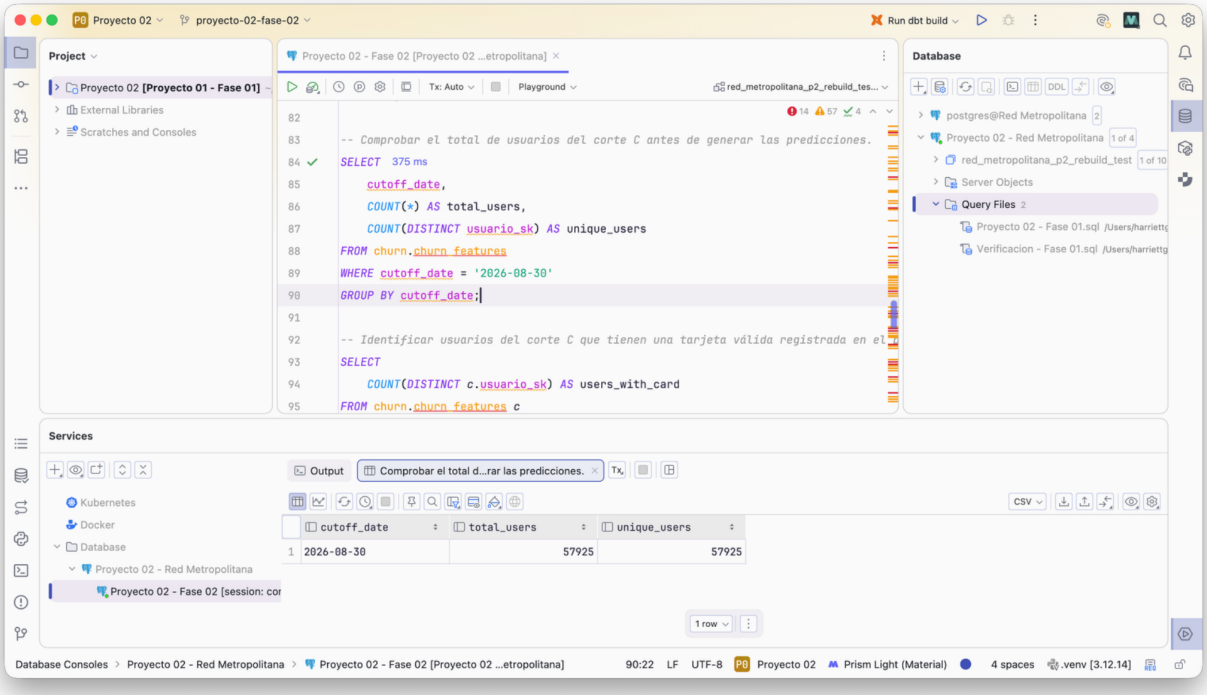


Figura 7. Población final del corte C.

Descripción: La consulta verifica la población disponible en el corte C, correspondiente al 30 de agosto de 2026. Se obtuvieron 57,925 registros y el mismo número de usuarios únicos. Este resultado coincide con la cantidad de filas del archivo final de predicciones, lo que permite comprobar que se generó una decisión de contacto por cada usuario considerado.

Interpretación: Comprueba el universo que debe recibir una predicción en el archivo final.

Usuarios del corte C con tarjeta CDC identificada

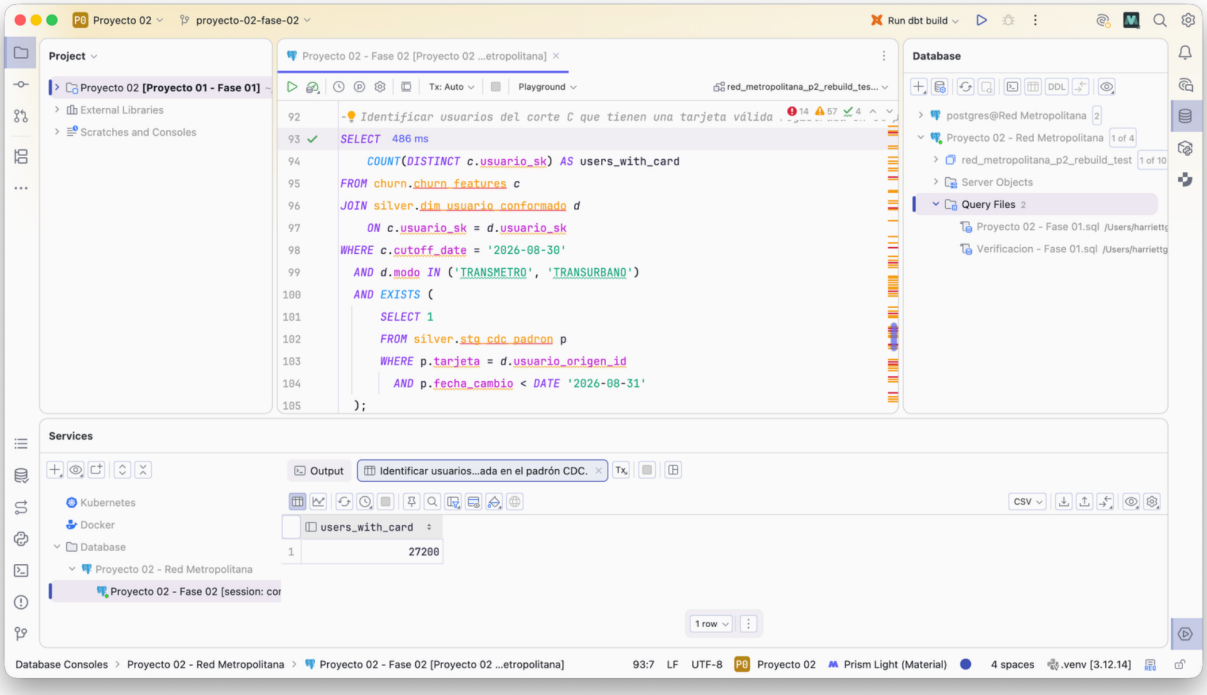


Figura 8. Usuarios del corte C con tarjeta CDC identificada.

Descripción: Para identificar usuarios con tarjeta se relacionaron las características del corte C con la dimensión de identidad conformada y el padrón CDC. La consulta consideró los modos Transmetro y Transurbano y registros de tarjeta anteriores al 31 de agosto de 2026. Se identificaron 27,200 usuarios con tarjeta asociada, información útil para preparar las acciones de contacto.

Interpretación: Valida la cobertura de tarjetas identificadas para posibles acciones de contacto.

Usuarios del corte C sin tarjeta CDC identificada

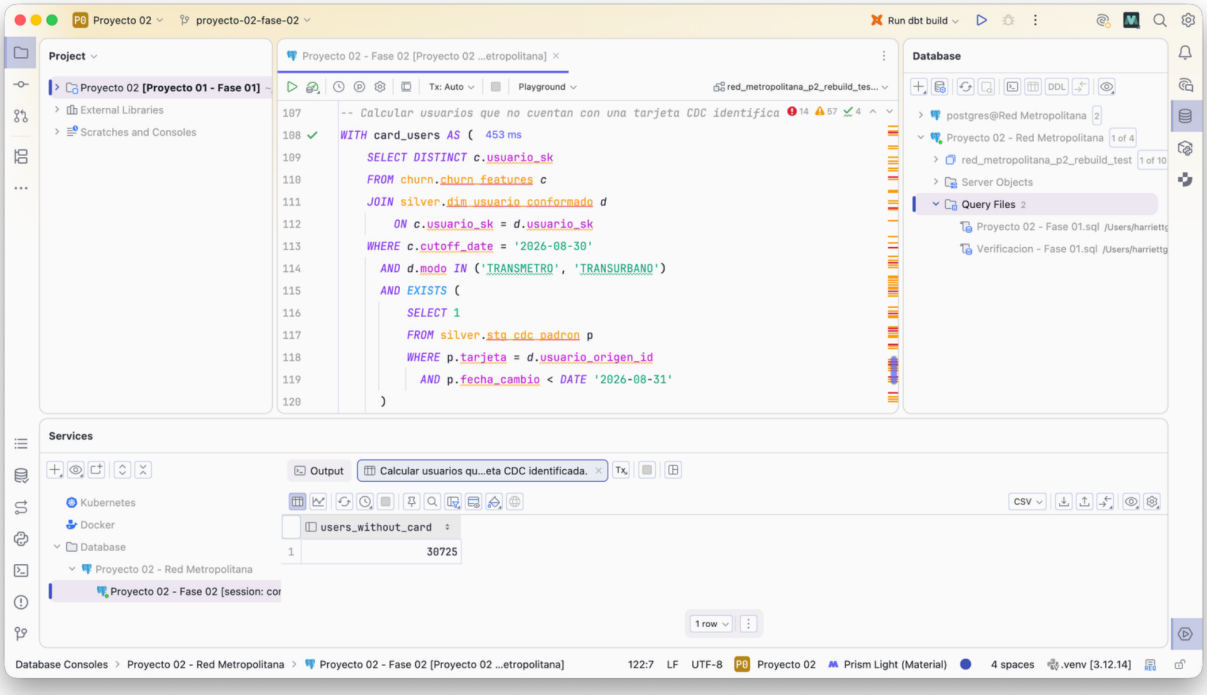


Figura 9. Usuarios del corte C sin tarjeta CDC identificada.

Descripción: La consulta identifica a los usuarios del corte C que no cuentan con una tarjeta CDC asociada bajo los criterios definidos. El resultado fue de 30,725 usuarios. Al sumarlos con los 27,200 que sí tienen tarjeta, se obtiene la población total de 57,925, confirmando que ambas categorías cubren el corte C sin dejar usuarios fuera del conteo.

Interpretación: Documenta la limitación operativa de identificación de tarjetas en la población a predecir.

GitHub

https://github.com/harriett-gl/Proyecto-02-CD.git

Presentación

https://canva.link/b9zlpeesvtb9gga